

智能体研究课题任务书

共 12 个课题 · 7 个核心治理智能体 + 5 个专项能力智能体

前言：课题总体说明

一、总体背景：数据治理与“数据预处理工厂”

在数字化转型中，企业积累了海量以非结构化、半结构化形式存在的数据资产，散落于 PDF（含扫描件）、Word、Excel、PPT、网页、图片等多种载体之中。这些数据格式各异、噪声严重、口径混乱、来源难溯，既难以直接支撑业务系统的入库、检索与分析，也无法直接喂给大语言模型用于知识库（RAG）构建、模型微调与数据合成。如何把“最脏、最重、最难标准化”的原始数据，自动加工为“结构统一、口径一致、质量可量化、来源可追溯”的高质量数据集，是企业数据治理的核心命题，也是大模型真正落地行业的前置瓶颈。

一条完整的数据治理流水线通常包含：**解析**（把任意格式还原为统一结构）→ **清洗**（去噪、修复、合规脱敏）→ **归一**（统一时间、数值、地名、实体、术语口径）→ **转换组织**（字段映射、面向下游的分段与打标）→ **质量校验**（评分与路由）→ **持续迭代**（沉淀评测、回归优化）。每个环节都可由一个“智能体”承担；智能体内部再编排若干原子能力（Skill）协同完成。本任务书所有课题，均设定在这一“数据治理 / 数据预处理工厂”的总体背景之下——它不直接“用数”，而是把用数之前最脏最重的清洗准备工作，做成平台化、可复用的能力。

二、课题构成：7 个核心智能体 + 5 个专项能力智能体

本任务书把上述能力拆解为 12 个相对独立、可独立研究与交付的智能体课题。其中课题 1-7 为贯穿整条流水线的“核心治理智能体”，每个承担流水线的一个关键环节；课题 8-12 为从核心智能体中抽离出来、难度较高、相对独立且研究价值高的“专项能力智能体”。

之所以把表格还原、图表数据化、实体链接、智能分段、保真度评估这五项“较难的能力”单独立题为“智能体”，是因为它们难度高、相对独立、且会被多个核心环节复用——把它们做成接口规范的独立服务后，核心智能体即可像“调用一个能力（Skill）”那样按需调用它们（例如解析智能体调用表格/图表智能体，归一与清洗智能体调用实体链接智能体，转换智能体调用智能分段智能体，质检智能体调用保真度评估智能体）。这样既便于分工研究，也便于后续灵活集成、热插拔上线。

需特别澄清一个易混点：文档智能中常被提及的“实体识别（识别出实体名称，NER）”是一个更基础、可作为公共能力横向复用的环节（脱敏、归一、打标都依赖它），本任务书不将其单列为课题；课题 10 研究的是“实体链接 / 消歧 / 标准化”，即“识别之后”如何把名称对齐到知识库中的唯一标准实体。两者层次不同，请勿混淆。

编号	课题名称	类型·环节	难度	一句话定位（含与其他课题的调用关系）
1	主控调度智能体（弱规划编排器）	核心·流程编排	中	按治理模板编排各智能体，管状态机、阈值路由、人机协同与全链路追踪
2	多源异构解析智能体	核心·解析	中-高	把任意格式文件还原为统一结构表示，并分

编号	课题名称	类型·环节	难度	一句话定位（含与其他课题的调用关系）
				离图/表/公式等多模态资产；可调用课题 8、9
3	通用数据清洗智能体	核心·清洗	中	去噪、结构修复、合规脱敏，改动全程留痕、不改语义口径；可调用课题 10
4	全域术语归一智能体	核心·归一	中-高	统一时间/数值/地名/实体/术语口径，产出可追溯映射；可调用课题 10
5	数据格式标准化转换智能体	核心·转换组织	中	字段映射 + 面向下游的分段打标摘要，封装双形态成果包；可调用课题 11
6	数据质量校验智能体	核心·质量校验	中	过程关卡 + 终检评分，输出锚点级质检报告与路由建议；可调用课题 12
7	Harness 自进化迭代智能体	核心·持续迭代	中-高	把执行轨迹与人工修正沉淀为评测集与回归基线，支撑能力升级与 badcase 闭环
8	智能表格识别与还原智能体	专项·被调用	高	复杂表格（合并单元格/无边框/跨页/扫描）结构还原，双形态输出；被课题 2 调用
9	图表数据化智能体	专项·被调用	高	把统计图表反解为带置信度的数据表（前沿方向）；被课题 2 调用
10	实体链接与知识对齐智能体	专项·被调用	中-高	把实体指称链接到知识库标准实体（消歧/标准化/NIL/共指）；被课题 3、4 调用
11	面向 RAG 的智能分段与内容组织智能体	专项·被调用	中-高	结构/语义感知分段 + 打标摘要，以下游检索指标闭环评估；被课题 5 调用
12	内容保真度与治理质量评估智能体	专项·被调用	中-高	治理前后语义比对、过度清洗识别、可读性评估（LLM-as-Judge）；被课题 6 调用

三、与开源 / 通用智能体的根本区别（贯穿全部课题）

当前主流的开源自主智能体（强调自主规划、自由探索、动态决定下一步的开放式智能体）适合开放式任务，却难以满足数据治理对“结果可复现、过程可审计、改动可回滚”的硬性要求。本任务书的智能体整体强调三点：**弱自主规划、强流程约束、全程可追溯**——主流程由可配置模板固化，自主性仅保留在异常分支；并要求对每一次数据改动尽量留痕（原值 → 新值 → 依据）。这是与通用智能体在设计理念上的根本不同，也是各课题需要重点体现的研究价值。

此外，许多通用框架/工具在“输入形态”上也有局限：不少对话式智能体仅支持纯文本或单张图片输入，难以直接处理常见的复杂办公文档格式；通用解析/清洗/质检工具也多停留在格式或结构化规则层面，难以胜任版面理解、语义保真、口径统一、语义质量评估等治理级要求。需要强调的是，**基础解析能力（文本抽取、版面切分）当前已有成熟方案**，本任务书的研究价值不在“复现已有开源能力”，而在于：把这些能力升级为面向治理、可控、可追溯、可集成的智能体，并在各课题指出的“难点”上有所推进。各课题应在“课题背景 / 研究重点”中清晰说明本智能体相较通用方案的差异与攻关点。

四、通用交付要求（适用于全部课题）

- **服务化、可集成：**交付一个对外暴露统一标准接口（建议 HTTP API 或等价形式）、可独立部署、可被流水线以注册制热插拔集成的可用智能体，而非一次性脚本；输入/输出遵循清晰、稳定、可版本化的数据规范，便于与上下游解耦。
- **实现方式自主、按需选型：**内部能力（Skill）可用确定性规则/脚本、本地小模型、大模型提示词、规则与模型混合、或外部知识检索工具实现；遵循“能用确定性规则解决就不消耗大模型算力”的原则，并为每个能力标注实现类型、适用数据形态与性能/成本特征，说明“为什么这一步可以不用大模型”。
- **可追溯、可回放：**对数据的每一次加工尽量留痕（原值 → 新值 → 依据），支持回放与回滚，契合治理场景的可审计要求。
- **可评测、可复现：**自建或采用公开数据集，给出量化指标与可复现的评测脚本，支撑“改前改后”的回归对比；鼓励同时报告失败案例（badcase）分析。
- **可私有化部署：**在数据不出域前提下可运行；外部大模型调用可关闭或替换为本地模型。
- **建议交付物：**可运行代码、接口与数据规范文档、评测报告、典型样例与失败案例分析、部署与使用说明，以及一份简要技术报告（方法选型、与开源方案的差异、难点与解决思路、指标结果与不足）。

五、任务书阅读方式

课题 1-12 各自独立成篇、可独立阅读：每个课题统一包含“**课题背景、研究目标与功能描述、核心能力与 Skill 示例、研究重点与难点（含与开源方案的区别）、期望的输入与输出、技术指标与验收标准、交付物**”七个部分；课题标题下方的说明行标注了其类型、环节、难度、建议方向与调用关系，供指导教师分配选题参考。

其中“**Skill 示例**”仅为提示与参考，并非完整清单——请在充分调研后自主设计、增补、裁剪所需能力。“**技术指标**”为建议达成目标，可结合所用数据集与具体场景由指导教师商定具体阈值，但应保证指标可度量、可验证；专项课题（8-12）建议优先在公开数据集上验证，再迁移到治理场景数据。

第一部分 核心治理智能体（课题 1-7）

课题 1-7 贯穿数据治理流水线，每个课题承担“解析 → 清洗 → 归一 → 转换组织 → 质量校验 → 持续迭代”中的一个关键环节，并由主控调度智能体按治理模板编排协同。各课题相对独立，亦可组合研究。

课题 1 主控调度智能体（弱规划编排器）

一、课题背景

在企业数据治理中，原始文件要经过“解析 → 清洗 → 归一 → 转换组织 → 质量校验”等多个环节，才能加工为可用的高质量数据集。这一串环节需要一个“总指挥”来按既定流程依次调度各专职智能体、在它们之间传递数据、管理任务进度、处理异常并决定成果去向。与开放式对话场景不同，数据治理对结果有一条硬性要求：**可复现、可审计、可回滚**——同样的输入与同样的治理配置，必须能稳定产出一致的结果，且每一步都可被追溯。

当前主流的开源自主智能体大多强调“自主规划、自由探索、动态决定下一步做什么”，适合开放式任务，却恰恰不适合治理场景：自由规划会导致执行路径不稳定、同一输入多次运行结果不一致，难以审计。本课题研究的是一种“**弱自主规划、强流程约束**”的编排器——主流程由可配置的“治理模板/剧本”固化，编排器自身的判断力只用于**异常分支**（失败重试、超时熔断、能力降级、人工路由）。如何在“足够的自动化”与“严格的可控性”之间取得平衡，是本课题的核心命题。

为便于理解，可把它想象成一条数据加工流水线的“**总控台 + 总导演**”：剧本（治理模板）已经写好每一道工序的顺序与参数，总控台只负责按剧本派工、盯着每道工序的状态灯、在某道工序出故障时决定“重做 / 降级 / 叫人”，并最终根据质检打分决定这批货是“直接出库 / 送人工复检 / 打回返工”。它本身不动手加工任何数据。

二、研究目标与功能描述

设计并实现一个面向数据治理流水线的主控调度智能体：依据外部传入的“治理模板/流程配置”，按序调用各业务智能体并在它们之间传递统一的数据载体与上下文参数；全程维护任务状态机，依据质量校验结果做阈值路由（自动发布 / 转人工审核 / 打回重跑），并支持断点续跑与人机协同。智能体对外暴露简洁稳定的接口（如：创建任务、查询状态、获取成果、回写审核结论），自身不直接改写任何业务数据，也不感知各 Skill 的内部实现，从而保证编排层与执行层解耦、可独立替换升级。

为把“弱规划、强约束”讲具象，给出一个声明式“治理模板（剧本）”的示意（YAML 风格，仅为示例）：

```
template_id: 通用文档治理模板_v1
pipeline: [ 解析, 清洗, 归一, 转换, 质检 ]      # 工序顺序固定，模型不得自行增删/重排
清洗:      启用[字符清洗, 格式噪声清洗, 结构修复, 合规脱敏]; 脱敏策略=保留后四位
归一:      行业词库=能源行业_v3
转换:      分段目标长度=768token; 打标体系=默认_v1
质检路由: 自动发布 >=85; 转人工 [60,85]; 打回重跑 <60 (最多 2 次)
```

对应的任务状态机（示意）：排队 → 执行中 →（每道工序后落 UIR 快照）→ 待审核 ⇌ 执行中 → 已完成 / 失败（→ 重试 / 降级 / 转人工）。任意环节中断后，应能从最近一次工序快照精确续跑，不丢任务、不重复发布。

主控的职责边界（DO / DON'T）——这正是“弱规划”的工程化定义：

主控负责 (DO)	主控不做 (DON'T)
按治理模板顺序调用业务智能体，传递统一中间表示与上下文参数	不自主增删、重排业务智能体的调用顺序
维护任务状态机（排队/执行中/待审核/完成/失败），支持断点续跑	不直接调用任何具体 Skill，不感知 Skill 内部逻辑
依据质检分数与阈值执行路由：自动发布 / 转人工 / 打回重跑	不改写任何数据内容（数据只在业务智能体中被加工）
失败重试、超时熔断、能力降级（如扫描件解析失败转人工）	不做开放式任务规划，不接受自由文本指令改变主流程
为全链路分配并透传 trace_id，落库 Skill 级执行轨迹	不绕过质检关卡发布任何成果

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **治理模板解析与合法性校验：**解析声明式流程配置，校验工序合法性，按配置驱动业务智能体，禁止自由文本指令改变主链路。
- **任务状态机管理：**覆盖排队、执行中、待审核、已完成、失败、重试等状态，杜绝非法状态跃迁，支持断点续跑。
- **质检阈值路由决策：**依据质量评分与阈值，决策自动发布 / 转人工 / 打回重跑，决策过程可审计回放。
- **异常处理策略：**失败重试、超时熔断、能力降级（某能力失败时切换兜底方案或转人工），单点能力失败不导致整任务失败。
- **人机协同回调：**审核结论回写后，从断点续跑并触发增量复检。
- **全链路可观测：**为每个任务分配贯穿始终的 trace_id，落库各环节执行轨迹（输入输出摘要、耗时、成本、状态），供溯源与审计。
- 可自行补充：并发任务调度与优先级队列、超大文件拆分子任务与结果合并、任务级耗时与成本统计等。“声明式配置 vs 模型判断”的边界划分本身就是研究重点。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点在于“自主性与可控性的平衡”：**主链路完全由模板固化、不可被自由指令改变，而异常分支需要一定判断力（哪些异常可自动恢复、哪些必须转人工）；研究如何界定二者边界并保证整体可复现、可审计。
- **与开源自主智能体（自由规划型）的根本区别：**本课题是“弱规划编排器”，研究重点是状态机设计、断点续跑、阈值路由策略、降级与熔断、人机协同与全链路追踪，而非“让模型自由决定流程”。刻意收窄智能体的自主性，把确定性流程交给配置，把判断力只留给异常，以换取治理结果的可复现与可审计。

- **强调“能力热插拔”**：新增/替换某个业务智能体不应改动编排器本体，研究以注册制与标准接口实现可插拔编排。
- **可观测性与可审计性是硬指标**：任一任务可下钻到“任务 → 智能体 → 能力 → 模型调用”四级，异常重试/降级/人工路由全部事件化、可回放。

五、期望的输入与输出

期望输入	期望输出
治理任务请求（待治理文件的引用、选用的治理模板 ID 与参数）；运行过程中接收各业务智能体的执行结果与状态，以及质检智能体输出的质检报告。	编排各业务智能体按序产生的端到端治理成果；任务状态与最终路由决策记录；贯穿全链路的执行轨迹与调度日志（ <code>trace_id</code> 贯穿四级，可供溯源、审计与回放）。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
流程可复现性	相同输入 + 相同模板多次运行，处理路径完全一致；结构化结果完全一致、语义结果一致率 ≥ 99%（核心考核项）。
状态机完备性	覆盖全部任务状态，无非法状态跃迁；任意环节中断后断点续跑成功率 100%，不丢任务、不重复发布。
阈值路由正确率	依据质检分数与阈值（自动发布 / 转人工 / 打回）做出的路由决策与配置严格一致，正确率 = 100%，可审计回放。
异常处理覆盖	失败重试、超时熔断、能力降级、人工路由策略齐备；无未处理异常导致任务卡死；单点能力失败不致整任务失败。
全链路可追溯	任务 → 智能体 → 能力 → 模型四级可下钻，执行轨迹完整率 100%，可回放。
并发与开销	支持并发治理任务 ≥ 10；编排调度本身耗时占端到端总耗时比例 ≤ 5%。

七、交付物

可运行的调度智能体一套，含治理模板定义规范、状态机实现、阈值路由与异常处理逻辑；对外暴露单一标准入口，可被平台以注册制集成，并附接口文档与可复现的运行示例。

课题 2 多源异构解析智能体

一、课题背景

企业数据资产大量沉淀在格式各异的文件中：PDF（含扫描件）、Word、Excel、PPT、网页、图片等。它们版式复杂（多栏排版、图文表混排）、噪声严重、结构隐性，既无法直接入库检索，也无法直接喂给大模型。要把它们纳入统一治理，第一步就是“解析”：把任意格式的原始文件，忠实还原为一种结构统一、可被机器处理的中间表示，并把其中的图片、表格、公式等多模态内容分离外置。**解析质量是整条治理流水线的“天花板”**——解析丢失或错乱的信息，后续环节无法凭空补回。

值得注意的是，许多通用的智能体框架与对话式工具仅支持“纯文本或单张图片”作为输入，无法直接处理上述常见的复杂办公文档格式；而通用的解析库往往只做“文本提取”，丢弃版面结构与多模态内容，且其输出未必携带治理所需的“**锚点级溯源信息**（源页码、坐标）”。需要说明的是，基础文本抽取与版面切分目前已有较成熟的开源方案，因此本课题的研究价值不在复现这些基础能力，而在于把解析升级为一个“**格式无关、版面感知、多模态资产分离、质量可自评**”的解析智能体：不仅取出文字，还要恢复阅读顺序与标题层级、保留每块内容的来源位置，把图/表/公式抽取为可复用的独立资产，并对低置信结果主动预警。这正是它区别于通用方案的研究重点。

二、研究目标与功能描述

设计并实现一个多源异构解析智能体：输入任意受支持格式的原始文件，输出一份统一的结构化中间表示（建议为按阅读顺序排列的“内容块”序列，每块标注类型、层级与来源锚点），并将图片、表格、公式等多模态资产抽取后外置存储、在正文中以占位符回链。智能体应内置“解析质量自评”能力，对低置信结果（如乱码率高、结构残缺的页）主动预警，便于下游降级处理或人工抽检。对于复杂表格、统计图表等高难度多模态内容的深度还原，可调用专项能力智能体（见课题 8、9）。

- **多格式接入**：数字版 PDF、扫描版 PDF（OCR）、Word/PPT、Excel/CSV、HTML、纯文本/Markdown、图片等；文件类型自动识别与解析策略选择（数字 PDF 直抽文本层 vs 扫描件走 OCR）。
- **统一中间表示生成**：按阅读顺序排列的内容块（标题/段落/列表/表格/图片/公式/代码），每块携带锚点（源页码 + 坐标）。
- **多模态资产外置**：图片/表格/公式抽取后独立存放，正文以占位符回链；资产配套元数据（来源、说明、置信度）。
- **解析质量自评**：字符置信度、乱码率、结构完整度打分，对低分页/块预警；按需调用课题 8、9 处理高难度内容。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- 多格式接入与解析策略选择；扫描件预处理（去噪、纠偏、二值化）以提升 OCR 输入质量。

- 版面分析与区块检测（正文/标题/表格/图片/页眉页脚/脚注）；多栏、图文混排场景下的阅读顺序还原。
- 标题层级识别（基于字号/编号/样式推断多级标题树）；页眉页脚与页码剔除，避免污染正文。
- 多模态资产抽取与外置（图片切片、表格结构化、公式识别），配套来源元数据与占位符回链（深度还原可调用课题 8、9）。
- 统一结构表示组装与 Schema 校验（按阅读顺序成文，做结构与锚点完整性检查）；解析质量自评。
- 可自行补充：字符编码探测、超大文件分页流式处理等。**统一中间表示的 Schema 设计（如何承载锚点与资产回链）是本课题的设计核心。**

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心痛点：**真实企业文件格式繁多、版式复杂，而通用智能体/工具常只接受纯文本或单图、或只做文本提取；解析是全流水线质量的上限。
- **与通用方案的区别：**要求“**格式无关 + 版面感知 + 多模态资产分离 + 保留来源锚点（页码+坐标）**”，以支撑后续的原文对照、瑕疵定位与血缘追溯。输出不是“一段文本”，而是“可溯源、可下游消费、可被治理流水线逐环节读改写”的结构化载体。
- **研究难点**集中在复杂版面（多栏/图文混排/跨页）、扫描质量参差、隐性结构（标题层级、阅读顺序）的稳健还原。
- **强调“可降级、可预警”：**对低置信结果主动标记（自评低分能命中真实解析错误），而非默默输出错误结果——这正是多数固定解析管线所缺失的。

五、期望的输入与输出

期望输入	期望输出
任意受支持格式的原始文件（PDF / Word / Excel / PPT / HTML / 图片等），单文件规模可较大（如数百页）。	统一的结构化中间表示（按阅读顺序排列的内容块，含类型、标题层级、来源锚点）；外置的多模态资产（图片/表格/公式）及其来源元数据与正文占位符回链；解析质量自评与低置信预警清单。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
格式覆盖	覆盖数字/扫描 PDF、Word、Excel、PPT、HTML、图片等主流格式，端到端可跑通。
文本还原准确率	数字版字符准确率 ≥ 99%；扫描版 OCR 字符错误率（CER）控制在业界可比水平（如 ≤ 5%）。

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
阅读顺序正确率	多栏/图文混排场景阅读顺序正确率 $\geq 90\%$ 。
标题层级还原	标题树还原准确率 $\geq 85\%$ 。
结构与锚点完整	统一结构表示通过结构校验 100%；每块来源锚点（页码+坐标）完整率 100%，资产与占位符一一对应。
资产抽取与回链	图片/表格/公式正确抽取并在正文正确回链的比例 $\geq 95\%$ ，无遗漏。
质量自评有效性 / 性能	对实际低质量页的预警召回率 $\geq 90\%$ ；100 页数字 PDF 解析耗时 ≤ 3 分钟。

七、交付物

可运行的解析智能体一套，输入文件、输出统一中间表示与外置资产，并附解析质量自评报告；对外暴露标准入口，预留对课题 8、9 的调用接口，附接口文档与示例数据。

课题 3 通用数据清洗智能体

一、课题背景

解析得到的结构化文本往往仍然“脏”：夹杂不可见字符、乱码、冗余空白、残留标签与水印、广告与版权套话；标题、段落、列表、表格的结构可能错乱；句子被错误截断；还可能含有手机号、身份证、邮箱、银行卡、人名地址等需要合规脱敏的敏感信息。清洗的目标，是在“**不改变内容语义口径**”的前提下（口径统一是归一智能体的职责），完成去噪、结构修复与合规脱敏三类动作，把数据洗干净、修整齐、脱合规。

数据治理对清洗有两条特殊要求，使它区别于一般的文本清洗脚本或“让大模型整段重写一遍”的做法：其一是“**可追溯、可回滚**”——每一处改动都要留痕（原值 → 新值 → 依据），任何自动改动都可被复核与撤销；直接用大模型重写存在幻觉与不可审计风险。其二是“**合规底线**”——对手机号、身份证等敏感信息，规则类脱敏要求“**零漏检**（召回 100%）”，同时尽量“**零误伤**”（如避免把普通 18 位数字误判为身份证）。如何兼顾彻底清洗与语义保真、兼顾零漏检与零误伤，是本课题的研究重点。开源清洗工具通常是无状态的函数式处理，既不产出“锚点级变更明细（diff）”，也不区分“确定性规则清洗”与“需要语义判断的清洗”，更没有“清洗是否过度”的自检——这正是本课题要补齐的差距。

二、研究目标与功能描述

设计并实现一个通用数据清洗智能体：在解析输出的结构化中间表示上执行“去噪、修复、合规”三类动作，所有改动产出可追溯的锚点级变更明细（原值 → 新值 → 依据），并保证不改变内容的语义口径。对高风险动作（如严重失序文档的整体结构重建、广告判别）采用“**规则优先、模型兜底**”的混合策略以控制幻觉。智能体应区分“面向文本”与“面向表格/结构化数据”的两套修复逻辑：仅当输入含表格/电子表格数据时，才启用结构化数据修复（缺失值、异常值、重复行、类型校正等），避免文本与表格逻辑互相纠缠。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **字符级清洗**：不可见/控制字符、BOM、冗余空格与空行、全半角统一、特殊符号规整等。
- **格式噪声清洗**：残留 HTML/Markdown 标记、水印残留、广告与推广话术（规则召回 + 模型判别）、转义字符还原等。
- **结构修复**：标题/段落/列表/表格结构修正、断句修复；必要时整体结构重建（仅低置信文档触发并全量留痕）。
- **语义内容清洗**：目录页、参考文献、重复内容去重、低信息密度套话过滤（按配置保留或剥离）。
- **合规脱敏**：规则类 PII（手机/身份证/邮箱/银行卡，正则+校验位，召回 100%）、基于实体识别的姓名/机构/地址脱敏（可调用课题 10 做实体定位）、企业自定义敏感词脱敏（词库可热更新）。

- **结构化数据修复（仅含表格时启用）**：缺失值检测与填充（填充值全部标记）、异常值检测与修复、重复行去重、列类型校正。
- 每个能力须标注实现类型（规则/模型/混合），并说明“为什么这一步可以不用大模型”。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：在“彻底清洗”与“语义保真”之间把握分寸——清洗只去噪修复，不得改变口径；过度清洗/误删是严重缺陷。
- **与开源方案的区别**：不同于一把梭的正则清洗脚本，也不同于“让大模型整段重写”（存在幻觉与不可审计风险）；本课题强调治理级可追溯（每处改动留痕、可回滚）与合规级脱敏（规则类 PII 召回 100%），以及“规则优先、模型兜底”的可控幻觉混合清洗。
- **合规脱敏是底线能力**：需兼顾“零漏检”与“零误伤”，并在质检阶段接受强制复核。
- **文本与结构化数据“两套逻辑分离”**，按输入数据形态条件触发，是本课题的工程设计要点。

五、期望的输入与输出

期望输入	期望输出
解析智能体输出的结构化中间表示（含正文内容块与外置资产引用）；（可选）企业自定义敏感词库与清洗策略配置。	经去噪、结构修复与合规脱敏后的结构化中间表示；全量锚点级改动明细（diff/ 血缘记录，含原值 → 新值 → 依据，可逐条回滚）。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
脱敏召回率	规则类 PII（手机/身份证/邮箱/银行卡）召回率 = 100%（合规硬指标，强制复核）；误伤率 ≤ 1%。
改动可追溯	所有改动产出锚点级明细并可回滚，留痕完整率 100%。
语义保真 / 过度清洗防控	清洗前后语义一致（不改口径，抽样评估）；过度清洗/误删率 ≤ 1%，无明显有效信息损失。
噪声清除率	各类字符/格式噪声清除率 ≥ 95%，同时严控误删（不可误删正文）。
结构修复准确率	标题/段落/列表/表格结构修复准确率 ≥ 85%。
结构化修复	缺失值/异常值检出准确率达标，且所有自动填充/修复值 100% 标记可识别。
实现类型分层	明确各能力用规则/模型/混合，遵循“规则优先”原则降低模型调用占比。

七、交付物

可运行的清洗智能体一套，输入中间表示、输出清洗结果与全量 diff；对外暴露标准入口，预留对课题 10（实体定位）的调用接口，附接口文档与示例数据。

课题 4 全域术语归一智能体

一、课题背景

同一事物在不同文件中常有多种写法：日期有“2026 年 6 月 11 日 / 6.11 / 2026-06-11”等；单位有“万千瓦 / MW”；机构有“国网 / 国家电网 / 国家电网有限公司”。这种“口径混乱”会让数据无法对账、无法关联、无法可靠检索。归一的目标，是让“同一事物在全库只有一种标准说法”：统一时间、数值、单位、货币、地名、实体与术语的口径。这是数据可用、可关联、可分析的前提，也是高质量知识库与训练语料的基础。

与简单的“查找替换”或通用文本规范化不同，口径统一需要知识驱动与上下文判断：要处理别名、简称、曾用名，要区分“同名异指”，要在专业术语与易混词之间做保护性校对；并且每一次归一都必须可解释、可追溯（原值 → 标准值 → 依据）。通用的实体识别工具只负责“识别”实体，并不负责“统一口径”；通用文本规范化多停留在格式层；它们也缺乏对“行业可配置知识库”的支持，以及“映射留痕”“知识查询与数据改写相分离”的治理约束。这正是本课题区别于通用方案、需要重点攻关的地方。其中较难的实体消歧与实体标准化，可调用专项的实体链接智能体（见课题 10）。

二、研究目标与功能描述

设计并实现一个全域术语归一智能体：在清洗后的结构化中间表示上，统一时间、数值、单位、货币、地名、实体、术语等口径；所有归一动作产出映射记录（原值 → 标准值 → 依据来源），保证可解释、可追溯。知识支撑类能力（图谱/本体/行业词库/标准术语库查询）只提供“查询”、不直接改写数据，作为外部知识源被治理动作类能力调用；行业词库/术语库应以可热插拔的知识库形态挂载，便于行业快速适配。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **时间数值归一**：日期/时间/时区、数值格式（千分位/科学计数/中文数字）、单位换算、货币与金额规范化（如日期统一为 ISO 8601）。
- **地名归一**：行政区划规范名与代码对齐（处理简称/旧称）、地址要素解析与标准化拼装。
- **实体治理**：实体消歧（区分同名异指）、实体标准化（别名/简称/曾用名 → 标准全称与实体 ID）、共指消解（可调用课题 10 的实体链接智能体）。
- **术语治理**：错别字修正（专业词保护名单防误改）、同义词映射、缩写扩展、口语标准化（语义不变）、行业术语归一。
- **知识支撑（只查询不改写）**：图谱/本体查询、行业词库查询、国标/行标/企标术语库查询，作为归一的外部依据。
- 需特别区分“治理动作类（改写数据）”与“知识查询类（只读）”两类能力，避免分类交叉与重复建设。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点：**“同一事物全库唯一标准说法”需知识驱动与上下文判断，处理别名/简称/曾用名/同名异指，且归一须可解释。
- **与通用方案的区别：**通用 NER 只“识别”不“统一口径”，通用文本规范化多停留在格式层；本课题研究知识库/词库驱动、上下文感知的口径统一，并强制产出映射依据。差异化在于面向行业的可热插拔知识驱动，以及每一次口径统一都可解释、可回溯。
- **职责分离：**“知识支撑（只查询）”与“治理动作（改写数据）”分离，是本课题的设计原则。
- **行业适配性：**行业差异应收敛为可热插拔的词库/术语库，新增行业不应改动智能体本体。

五、期望的输入与输出

期望输入	期望输出
清洗后的结构化中间表示；（可选）可挂载的行业词库、术语库、知识图谱/本体等外部知识源（知识库形态）。	口径统一后的结构化中间表示；完整的归一映射记录（原值 → 标准值 → 依据来源），可供审计、回放与反哺词库。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
口径一致率	同一实体/术语在全文（全库）口径一致率 ≥ 95%（可由质检一致性抽检验证）。
映射留痕	所有归一动作产出“原值 → 标准值 → 依据”记录，留存率 100%。
规则类归一准确率	时间/数值/单位/货币等规则类归一准确率 ≥ 98%。
实体治理准确率	实体消歧准确率 ≥ 85%；实体标准化（映射到标准全称/ID）准确率 ≥ 85%。
专业词保护	误改专业术语率 ≤ 1%（错别字修正不得伤及受保护术语）。
词库热插拔 / 职责分离	新增/替换行业词库无需改动智能体代码，配置后即生效；知识查询类能力对数据零改写。

七、交付物

可运行的归一智能体一套，输入中间表示 + 知识库、输出归一结果与映射记录；对外暴露标准入口，知识库可热插拔，预留对课题 10 的调用接口。

课题 5 数据格式标准化转换智能体

一、课题背景

治理后的数据要真正被“消费”，往往还需要最后一步“适配”：一方面要把内容按目标数据结构（Schema）做字段对齐，服务业务系统的入库、检索与分析；另一方面要把内容组织成适合大模型消费的颗粒度——合理分段、自动打标、生成摘要，服务知识库（RAG）构建与训练语料生产。这一步是治理的“最后一公里”，决定了治理成果能否被下游“开箱即用”。

与纯手工 ETL 字段映射或仅做格式转换的工具不同，本课题要研究“同时服务两类下游”的标准化转换：在真实异构表头下，字段语义对齐歧义多，需要“规则优先、大模型兜底疑难并给出置信度”的半自动映射；同时要把治理结果封装为既能“给人读”（如 Markdown 全文）又能“给机器读”（如结构化 JSON、分段文件）的标准成果包，并保证 Schema 合规与目录完整性。开源的格式转换/导出工具通常只做“形态搬运”，不涉及语义字段映射，也不内置面向 RAG 的内容组织与多级标签体系。其中面向 RAG 的智能分段，可调用专项的分段智能体（见课题 11）。

二、研究目标与功能描述

设计并实现一个数据格式标准化转换智能体：把归一后的结构化中间表示，按目标 Schema 完成字段识别与映射、字段重命名/合并/拆分与校验（服务结构化用数）；并完成面向下游的内容组织（分段、打标、摘要、关键词），最终组装为人读与机读双形态的标准化治理成果包。字段映射应“规则词表优先、大模型处理疑难映射并给出置信度”；内容组织中的分段策略可调用专项分段智能体（课题 11），保证 chunk 内口径已统一、可直接供下游消费。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **模板与字段映射**：目标 Schema/映射规则加载、字段识别、源字段 → 目标字段对齐（规则优先 + 大模型兜底并给置信度）、字段重命名/合并/拆分、Schema 校验。
- **面向下游的内容组织**：智能分段（可调用课题 11）、自动打标（内容/管理/质量三级标签）、chunk 级与文档级摘要、关键词抽取、标准实体标签写入。
- **成果封装**：机读视角结构化序列化（如 JSON / 分段文件）、人读视角全文渲染（如 Markdown，资产占位+内联表格）、成果包组装与完整性（清单与校验和）校验。
- （扩展，按需，默认关闭）面向训练语料合成的问答对生成。
- **多级标签体系的设计**（内容/管理/质量分别由谁生成）是本课题的组织重点。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：既要服务“结构化精确入库”（字段映射），又要服务“大模型消费”（分段打标）；真实异构表头下字段语义对齐歧义多。
- **与开源方案的区别**：不同于纯手工 ETL 或仅做格式转换的工具，本课题研究“规则优先 + 大模型兜底疑难并给置信度”的半自动语义映射，以及面向下游消费颗粒度的内容组织与双形态封装。差异化在于把“导出”做成“面向下游消费颗粒度的智能组织 + 标准封装”。

- “双形态、可消费”是**关键产物**：同一成果既要可读又要可机器解析，且二者内容一致、可相互回链。
- 强调成果的“开箱即用”：输出应能一键转为下游入库格式或训练语料格式。

五、期望的输入与输出

期望输入	期望输出
归一后的结构化中间表示；目标数据结构（Schema）/元数据模板与映射规则；内容组织（分段/打标）相关参数。	标准成果包：字段对齐后的结构化数据（机读JSON）+ 人读全文（Markdown）+ 分段文件（chunks，含标签/实体/摘要/原文回链）+ 文档级元数据 + 清单与校验和，可被业务系统与大模型直接消费。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
字段映射准确率	源 → 目标字段自动映射准确率 ≥ 85%，疑难项给出置信度并可人工复核。
Schema 校验	类型/必填/值域校验完整，不合格项定位率 100%。
字段操作准确率	字段重命名/合并/拆分（规则类）准确率 ≥ 95%。
打标质量 / 摘要忠实度	内容标签准确率 ≥ 85%，管理标签按规则正确生成；摘要不引入原文没有的信息（可抽样核对）。
双形态一致 / 成果包规范	人读与机读两种产物内容一致率 100%、可相互回链；成果包结构完整、清单与校验和正确率 100%。
下游可用	输出可一键导出为下游入库格式或训练语料格式，可被 RAG 入库或训练语料流程直接读取使用。

七、交付物

可运行的转换智能体一套，输入中间表示 + 配置、输出标准成果包；对外暴露标准入口，预留对课题 11 的调用接口，附接口文档与示例数据。

课题 6 数据质量校验智能体

一、课题背景

自动化治理流水线必须有“**质量关卡**”，产出才可信、可发布。治理需要一个独立的质检智能体：在每个环节完成后做轻量过程校验，在成果发布前做全面终检评分；据此给出质量评分与等级，并决定成果去向——达标自动发布、介于阈值之间转人工审核、过低打回重跑。没有这道关卡，治理结果的质量就无法量化、无法把关。**质检自身不修改数据**，只“打分、定位问题、给路由建议”。

数据治理的质量校验有其特殊性，使它区别于通用的数据质量工具：通用工具（如基于规则的断言框架）主要校验结构化数据的取值规则，难以评估非结构化文本的“**语义质量**”——例如治理前后语义是否一致（有无过度清洗/误改）、可读性与结构是否合理、同一实体/术语口径是否一致。而若简单地“让大模型当裁判”，又会面临评分漂移、不可校准、不可审计的问题。如何做出“**可校准、锚点级、可路由**”的质量评估，并把合规脱敏复核设为“**一票否决**”的强制项，是本课题的研究重点。其中较难的“内容保真度/语义一致性评估”，可调用专项的评估智能体（见课题 12）。

二、研究目标与功能描述

设计并实现一个数据质量校验智能体：提供“过程关卡（每个环节后的轻量校验）+ 终检评分（发布前全面体检）”两类能力，输出结构化质检报告（含维度评分、锚点级瑕疵清单、路由建议）；质检自身不改写数据。评分应稳定、可校准（与人工评分有较强相关性）、可定位（瑕疵能落到具体内容块/位置）；其中合规脱敏复核为强制项，漏检即“一票否决”，禁止发布。支持人工修正后仅对受影响范围做增量复检。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补充）

- **规则校验**：完整性校验（页/块对账、资产回链、必填齐备）、格式合规校验（Schema/编码/命名规范）、脱敏合规复核（敏感信息全量复扫，强制项，漏检即一票否决）。
- **模型评估**：内容保真度评估（治理前后语义一致性，识别过度清洗/误改，可调用课题 12）、可读性与结构质量评估、归一一致性抽检（同一实体/术语口径一致性）。
- **报告与路由**：维度加权得总分并映射质量等级（如 A/B/C）、生成锚点级瑕疵清单、按阈值输出路由建议（自动发布/转人工/打回）。
- **维度体系与权重设计、阈值与路由策略是本课题的研究核心。**

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：非结构化/语义质量难以用传统规则衡量（保真度、可读性、口径一致性）；评分须稳定、可校准、可定位，并承担“关卡”职责。
- **与开源方案的区别**：通用数据质量工具主要校验结构化取值规则，难评估语义质量；“大模型当裁判”若不加约束则评分漂移、不可审计。本课题研究可校准、锚点级、可路由的评估，把

“质检”做成既有刚性合规底线、又有语义柔性评估、还能驱动自动/人工分流的“裁判 + 关卡”。

- **强制合规项：**脱敏复核为“一票否决”，是与一般质量评估的关键差异。
- **“评分稳定性/可校准性”是研究重点：**需给出与人工评分的相关性、同样本多次评分的一致性 etc 可验证证据。

五、期望的输入与输出

期望输入	期望输出
各环节产出（结构化中间表示、治理成果包）及治理前后对照数据；治理过程记录（diff、归一映射、执行轨迹）。	结构化质检报告（各维度评分、质量等级、锚点级瑕疵清单、路由建议）；不改写任何业务数据。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
评分稳定与可校准	同一样本多次评分一致（方差可控）；与人工评分相关性 ≥ 0.8 。
脱敏复核	敏感信息漏检率 = 0（一票否决，漏检即不可发布）。
内容保真识别	识别过度清洗/误改的 F1 ≥ 0.8 。
一致性抽检	同一实体/术语口径不一致的检出率 $\geq 90\%$ 。
瑕疵定位	瑕疵清单可定位到具体内容块/位置，便于人工审核直接跳转，定位准确率 $\geq 90\%$ 。
路由正确性 / 零改写	按阈值输出的路由建议正确率 = 100%，可审计；质检过程对数据零修改。

七、交付物

可运行的质检智能体一套，输入治理产出、输出质检报告与路由建议；对外暴露标准入口，预留对课题 12 的调用接口，附接口文档与示例数据。

课题 7 Harness 自进化迭代智能体

一、课题背景

一个治理系统要持续变好，必须能“**从自己的运行中学习**”：把每一次治理的执行轨迹与人工修正行为，沉淀为评测样本与回归基线，用来量化对比某个能力（Skill）升级前后的效果，并周期性产出“失败案例（badcase）”分析与优化建议。其中，**人工修正记录是“最高价值的免费标注”**——专家修正前的值是错误样本输入、修正后的值是标准答案输出，必须 100% 回收利用。

与通用的模型运维/评测框架不同，通用框架多面向“单个模型”的离线基准跑分，而本课题面向“**由众多能力组成的治理流水线**”：要研究如何低成本地把生产环境轨迹与人工修正转化为高质量评测集，如何按能力维度组织金标集与回归评测，以及如何保证“**任一能力升级先过回归、指标不回退方可上线**”的工程门禁。开源评测框架普遍缺乏“从生产轨迹与人工修正自动沉淀评测集”的闭环，也缺乏上线门禁。这种“自进化引擎”的设计，是本课题区别于通用评测工具的研究重点。

二、研究目标与功能描述

设计并实现一个离线运行的 Harness 自进化迭代智能体：采集全量能力级执行轨迹（输入/输出/参数/耗时/成本），把轨迹与人工修正转化为版本化评测集与回归基线；支撑某能力升级前后的量化对比，并周期产出 badcase 聚类与优化建议，构建“生产 → 沉淀 → 评测 → 优化”的自进化闭环。人工修正记录应自动转化为最高优先级金标样本（修正前值 = 错误输入，修正后值 = 标准输出）；任一能力升级（换模型/改提示词/改规则）必须先跑对应回归评测，指标不回退方可上线，结果留档。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **轨迹采集**：全量能力调用的输入/输出/参数/耗时/成本入库。
- **样本清洗与脱敏**：把原始轨迹转为可用评测样本（去重、脱敏、质量过滤）；人工修正记录自动转金标样本。
- **评测集/金标集构建**：按能力/智能体维度组织并版本化管理。
- **回归评测执行**：能力新版本在历史评测集上运行，自动产出指标对比报告（指标不回退方可上线）。
- **badcase 分析与优化建议**：失败模式聚类，生成可执行的提示词/规则/词库优化建议。
- 如何让“人工修正自动变成金标”、如何设计回归门禁，是本课题的工程核心。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：如何低成本地把“生产轨迹 + 人工修正”转化为高质量评测集与回归基线，并支撑能力升级的量化对比与 badcase 闭环。
- **与开源方案的区别**：通用 MLOps/评测框架多面向单模型离线基准测试；本课题面向“多能力治理流水线”的自动化评测沉淀，核心洞见是“**人工修正即最高价值的免费金标**”，并把“评测”做成“与生产闭环、由人工修正反哺、带上线门禁”的持续进化机制。

- “先回归、不回退才上线”是硬约束：研究如何把回归评测制度化、自动化，防止能力升级带来隐性退化。
- 强调“可持续”：评测集应随系统使用持续扩充、覆盖率持续提升，形成正向飞轮；离线运行不影响在线治理性能。

五、期望的输入与输出

期望输入	期望输出
全量能力级执行轨迹（输入/输出/参数/耗时/成本）；人工审核与修正记录（修改前/后值、锚点、理由）。	版本化评测集/金标集；能力升级前后的回归评测对比报告；badcase 聚类与可执行优化建议。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
轨迹采集完整	全量能力调用的输入/输出/参数/耗时/成本入库完整率 100%。
金标自动化	人工修正记录自动转化为金标样本的转化率（回收率）100%。
回归可拦截	能力升级前后自动产出指标对比；指标回退可被识别并拦截上线（门禁生效）。
badcase 闭环	失败模式聚类有效、反映真实失败模式，产出的优化建议可被执行并验证效果。
评测集成长 / 可复现	评测集随使用持续扩充、覆盖率随时间提升；同一能力版本在同一评测集上结果稳定可复现。
离线无干扰	运行不影响在线治理性能；评测集、金标、对比报告均版本化、可追溯。

七、交付物

可运行的 Harness 智能体一套，含评测集自动构建与回归评测能力；对外暴露标准入口，离线调度运行，附接口文档与示例数据。

第二部分 专项能力智能体（课题 8–12）

课题 8–12 是从核心智能体中抽离出来、难度较高且相对独立的“专项能力智能体”。它们被设计为接口规范的独立服务，核心智能体可像调用一个能力（Skill）那样按需调用它们，从而便于分工研究与灵活集成、热插拔上线。

课题 8 智能表格识别与还原智能体

一、课题背景

表格是文档中信息密度最高、也最难还原的内容之一。把一页文档（或一张图片）里的表格，准确地还原为“可计算、可入库”的行列结构，长期是文档智能领域的难题（表格结构识别，Table Structure Recognition, TSR）：现实中的表格大量存在**合并单元格、无边框或少线、跨页续表、多级/嵌套表头以及扫描噪声**等复杂情况，简单依赖线条检测的传统工具在这些场景下精度急剧下降。一旦表格还原错误，其中承载的数据就会失真或丢失。

在数据治理中，表格需要“**双形态**”输出：既要有便于阅读与检索的形态（如 Markdown 表），又要有便于统计分析与入库的结构化形态（如 CSV/JSON 行列模型）。由于该能力难度高、且会被解析等多个环节复用，适合独立成一个可被调用的“专项智能体”。开源方案在简单有线框表上表现尚可，但在合并单元格、跨页合并、无线框表上仍易错乱，且较少处理“跨页表的语义合并”。本课题区别于通用表格工具的研究重点，正在于**复杂表格的稳健结构还原（含合并单元格与跨页合并）、双形态输出与置信度评估**。

二、研究目标与功能描述

设计并实现一个智能表格识别与还原智能体：输入含表格的文档页（图像或带版面坐标的区域），输出结构化的表格（正确还原行列、合并单元格与多级表头），并同时产出可读形态与结构化形态；对低置信结果给出置信度与预警。智能体应能作为服务被解析等环节按需调用，接口稳定、输入输出规范，便于集成到治理流水线中。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **表格区域检测**：定位页面中的表格区域。
- **表格结构识别**：单元格/行列边界识别、合并单元格还原、多级/嵌套表头探测。
- **复杂表格处理**：无边框/少线表格识别、跨页续表合并（把被分页切断的同一张表拼接还原）、扫描噪声鲁棒性。
- **双形态输出**：结构化（CSV/JSON 行列模型）+ 可读（内联 Markdown 表）一致输出。
- **置信度评估**：输出带置信度，低置信表格主动预警。
- 可自行补充：单元格内 OCR、表头语义识别与单元格内容对齐等。**复用现成 TSR 模型还是自研改进**，由同学权衡。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：合并单元格、无边框/少线、跨页续表、扫描噪声等复杂表格的结构还原；并需同时产出可读与可计算双形态。
- **与开源方案的区别**：通用表格抽取工具（如依赖线条检测的方案）在无边框/扫描/跨页场景退化严重；本课题研究稳健的表格结构识别、双形态输出与置信度评估。差异化在于产出“既能入库统计、又能 RAG 召回”的双形态表格，并把跨页表当作一张完整表来还原。

- 可作为“被调用的服务”设计：接口与输入输出规范是工程重点，便于被解析等环节复用。
- 建议以可量化的结构相似度指标（如表格结构树相似度 TEDS、单元格邻接关系）评估还原质量，而非字面匹配。

五、期望的输入与输出

期望输入	期望输出
含表格的文档页（图像，或带版面坐标的表格区域）。	结构化表格（行列模型 + 合并信息 + 多级表头结构）+ 内联 Markdown 表；每个表格的置信度与必要的低置信预警。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
简单表结构	结构还原相似度（如 TEDS） ≥ 0.90 。
复杂表结构	含合并单元格/复杂表头的结构相似度 ≥ 0.80 。
跨页合并	跨页续表正确合并率 $\geq 85\%$ 。
无边框表	无边框/少线表格结构识别准确率 $\geq 80\%$ 。
双形态一致 / 鲁棒性	结构化与可读两种形态内容一致率 100%；覆盖有线框/无线框、扫描/数字、简单/复杂表。
置信度有效	对实际还原错误的表格，低置信预警召回率 $\geq 85\%$ 。

七、交付物

可运行的表格识别智能体一套，对外暴露标准接口供解析流水线调用，输入表格区域、输出结构化表格与 Markdown 表，附评测集与示例数据。

课题 9 图表数据化智能体

一、课题背景

文档中的统计图表（柱状图、折线图、饼图、散点图等）以“**像素**”形式承载着大量数据，人能看懂，但机器无法直接统计、大模型也无法直接推理；绝大多数文档处理流程会直接丢弃这些信息——因为把“一张图”反解为“一张数据表”非常困难：需要联合识别图表类型、坐标轴与刻度、图例与数据系列，再从图形几何关系反推出具体数值，并对反解结果的不确定性做出量化。这是多模态文档智能中较为前沿、且通用工具近乎缺失的能力（**chart-to-table / chart understanding**）。

在数据治理中，若能把图表反解为结构化数据，就能让图表承载的信息不再丢失，既可用于统计分析与入库，也可用于多模态训练。由于该能力难度高、相对独立，适合作为一个可被解析环节调用的“专项智能体”。本课题区别于一般 OCR/解析的研究重点，在于“**图表理解 + 数值反解 + 不确定性量化**”——这也是其前沿性与挑战性所在。本课题探索性较强，允许“**尽力还原 + 明确标注不确定性**”。

二、研究目标与功能描述

设计并实现一个图表数据化智能体：输入统计图表图像，识别图表类型、坐标轴、刻度、图例与数据系列，反解出对应的数据表，并输出带置信度/误差区间的结果（尽力而为，明确标注不确定性）。智能体应作为服务被解析环节按需调用，对无法可靠反解的图表如实给出低置信标记，而非输出看似精确实则错误的数据。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补充）

- **图表类型识别**：柱状/折线/饼图/散点/堆叠图等。
- **坐标系解析**：坐标轴、刻度、单位、网格识别。
- **图例与系列识别**：多系列/堆叠图的系列分离。
- **数值反解**：从图形几何关系反推数据点数值，还原为数据表（系列 × 类别 × 数值）。
- **不确定性量化**：输出置信度与误差区间，低置信预警。
- 可自行补充：坐标轴非线性还原、与上下文图注/题注文本的联合解析等。可基于现成图表理解模型做适配与改进。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：把“像素化的统计图”反解为“结构化数据”，需联合识别类型/坐标轴/刻度/图例/系列并量化不确定性；复杂图例、多数据系列、密集数据点尤其困难。
- **与开源方案的区别**：该能力在通用工具中近乎缺失，属前沿方向；本课题研究图表理解与数据反解，输出带置信度/误差区间的结构化数据表，使图表信息不再丢失。差异化在于不追求“完美还原”，而追求“**尽力还原 + 诚实标注不确定性**”，让下游能据置信度决定是否采用。
- “**尽力而为 + 如实标注不确定性**”是设计原则：宁可低置信预警，也不输出看似精确实则错误的数据。

- 可作为被调用的服务设计，接口与输入输出规范是工程重点。

五、期望的输入与输出

期望输入	期望输出
统计图表图像（柱状/折线/饼图/散点等，来自解析阶段外置的图片资产）。	反解出的结构化数据表（含坐标轴、图例、数据系列）+ 图表类型 + 置信度/误差区间（含低置信预警标记）。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
类型识别	图表类型识别准确率 $\geq 90\%$ 。
坐标/图例解析	坐标轴、刻度、图例解析准确率 $\geq 85\%$ 。
数值反解误差	可反解图表的数值相对误差 $\leq 5\%$ （如柱状图；可在公开图表数据集上评估）。
多系列分离	多系列/堆叠图系列正确分离率 $\geq 80\%$ 。
不确定性标注	输出携带置信度/误差区间；对不可靠反解低置信预警召回 $\geq 85\%$ 。
覆盖范围	明确支持的图表类型与边界；图 $\rightarrow$ 数据表的整体结构正确率达标，可供下游消费。

七、交付物

可运行的图表数据化智能体一套，对外暴露标准接口供解析流水线调用，输入图表图像、输出数据表与置信度，附评测集与示例数据。

课题 10 实体链接与知识对齐智能体

一、课题背景

在文本中“识别出一个实体的名字”只是第一步；更难、也更有价值的是把这个名字“**链接**”到知识库中唯一确定的标准实体上——即区分“**同名异指**”（如不同语境下的“国网”指代不同主体）、把别名/简称/曾用名映射到标准全称与唯一 ID、并在知识库中不存在该实体时正确判定为“**无对应（NIL）**”。这一步称为实体链接与知识对齐，是让数据可关联、可消歧、口径统一的关键。

需要特别说明（与公共基础能力的边界）：本课题并非研究“实体识别”本身——识别实体名称（NER）是一个更基础、可作为公共能力横向复用的环节，**不单列为课题**；本课题聚焦于“**识别之后**”的链接、消歧与标准化，这恰恰是通用实体识别工具不覆盖的部分，也是难点所在。通用方案多面向开放域、缺乏对行业可配置知识库的支持。研究重点包括：候选实体生成与上下文消歧、无候选（NIL）检测、共指消解，以及在缺乏标注的行业领域上的迁移/少样本表现。该能力可作为服务被归一、清洗等环节调用（例如归一智能体的实体消歧与标准化、清洗智能体的人名/机构脱敏定位）。

二、研究目标与功能描述

设计并实现一个实体链接与知识对齐智能体：在已给定文本与实体指称（mention）的前提下，把每个指称链接到知识库中的标准实体（标准全称 + 唯一 ID），完成消歧、别名/简称/曾用名标准化、NIL 检测与共指消解，并保留链接依据以供追溯。明确建立在“实体识别”能力之上，聚焦“链接 / 消歧 / 标准化”层；作为服务被归一、清洗等环节按需调用。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **候选实体生成/检索：**为指称从知识库中召回候选。
- **上下文消歧：**结合上下文区分同名异指。
- **实体标准化：**别名/简称/曾用名 → 标准全称 + 唯一 ID。
- **NIL 检测：**正确识别知识库中不存在的实体。
- **共指消解：**代词/指代短语回链到具体实体（按需启用）。
- **低资源/少样本迁移：**在缺乏标注的行业域上的适配；链接依据留痕。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点：**在缺乏候选、低资源行业域、同名异指等条件下，把指称稳定映射到知识库标准实体，并处理别名/简称/曾用名与共指。
- **与通用方案及“实体识别”的区别：**本课题明确建立在实体识别之上，研究的是更难的“链接/消歧/标准化”层——通用 NER 工具只识别、不链接、不统一口径。
- **NIL（无对应）检测与低资源迁移是研究亮点：**现实知识库往往不完备、行业标注稀缺。
- **链接结果可追溯**（链接到哪个实体、依据是什么），契合数据治理对可审计的要求。

五、期望的输入与输出

期望输入	期望输出
文本 + 已识别的实体指称（mention）+ 知识库/词库（含标准实体、别名、上下位等）。	每个指称链接到的标准实体（标准全称 + 唯一ID）；消歧与共指结果；NIL 判定；链接依据（可追溯）。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
链接准确率	指称 → 标准实体链接准确率 ≥ 85%。
消歧准确率	同名异指消歧准确率 ≥ 85%。
NIL 检测	知识库中不存在实体的 NIL 检测 F1 ≥ 0.80。
别名标准化	别名/简称/曾用名映射召回率 ≥ 85%。
共指消解	代词/指代回链准确率 ≥ 80%（按需启用时）。
可追溯	链接结果均留存依据，可审计、可回放。

七、交付物

可运行的实体链接智能体一套，对外暴露标准接口供归一、清洗流水线调用，输入文本 + 指称 + 知识库、输出链接结果与依据，附评测集与示例数据。

课题 11 面向 RAG 的智能分段与内容组织智能体

一、课题背景

把长文档喂给大模型构建知识库（RAG）时，如何“分段（chunking）”直接决定了检索与回答的质量：分得太碎会割裂语义，分得太粗会引入噪声、超出长度限制；在不该断的地方断句，或把一张表、一段公式从中截开，都会严重影响下游召回。朴素的“固定长度切分”虽然简单，却往往不是好的策略。如何做“结构/语义感知”的智能分段，是大模型数据准备中的关键且活跃的研究方向。

在数据治理中，分段发生在口径已统一之后、成果封装之时，以保证每个片段（chunk）内部术语口径一致、可直接供下游消费。除分段外，还需为片段做内容组织：自动打标（主题/关键词）、生成摘要、写入标准实体标签，并保留到原文的回链。开源切分器多为基于分隔符或定长窗口的机械切分，语义感知弱；语义分段虽被提出，但在“标题层级利用”“表格/公式保护”“长度约束与语义完整的平衡”上仍无统一最优解。由于该能力专门、且效果可用下游检索指标闭环验证，适合作为一个可被调用的“专项智能体”。本课题区别于朴素分段的研究重点，在于“结构/语义感知的分段策略 + 以下游检索指标闭环评估”；进阶可探索面向微调的高质量问答对/指令数据合成。

二、研究目标与功能描述

设计并实现一个面向 RAG 的智能分段与内容组织智能体：输入治理后、口径已统一的结构化全文，按“结构/语义感知”的策略分段（保证不破句、表格/公式整体成块、长度可控），并为每个片段生成标签、摘要、实体标签与原文回链。分段质量应能用下游检索指标闭环评估（相对固定长度基线的提升）；进阶可探索面向训练语料合成的高质量问答对/指令数据生成（明确标注可答性与忠实度）。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **结构/语义感知分段**：标题边界优先 + 语义完整 + 长度约束（目标长度可配，如 512~1024 token，不破句，表格/公式/代码整体成块不截断）。
- **长度与重叠控制**：目标长度区间、片段重叠等参数化（过长拆分、过短合并）。
- **内容打标**：主题/关键词等内容标签，结合规则的管理标签。
- **摘要生成**：片段级与文档级摘要（要求忠实、不臆造）。
- **实体标签写入与原文锚点回链**（每个 chunk 可溯源到来源块/页码）。
- （进阶）面向微调的问答对/指令数据合成，并对可答性、忠实度做校验；（可选）父子块/多粒度分段、面向不同下游（检索 vs 训练）的策略切换。
- **以下游检索指标（如 Recall@k、nDCG）闭环评估分段效果**。分段策略与下游检索效果的关系，是本课题最值得做实验验证的部分。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点：**分段策略直接决定下游 RAG 的召回与回答质量，需在“语义完整、边界不破坏、长度可控”之间权衡，并能用检索指标闭环验证。
- **与开源方案的区别：**不同于朴素的固定长度切分，本课题研究结构/语义感知的分段与内容组织，并以下游检索指标闭环评估分段效果。差异化在于以“下游检索/生成效果”为优化目标，而不仅是“切得整齐”。
- **“闭环评估”是研究方法上的关键：**用下游检索/回答质量来反向衡量分段好坏，而非只看分段本身是否“看起来合理”。
- **进阶方向（数据合成）契合大模型训练语料生产，**是可选的加分研究点；需严控生成内容的忠实度，避免幻觉。

五、期望的输入与输出

期望输入	期望输出
治理后、口径已统一的结构化全文（含内容块与外置资产引用，带结构与锚点）；分段策略与下游消费相关参数。	语义完整的分段结果（每个片段含文本、长度、标签、摘要、实体标签、原文锚点回链）；（进阶，可选）问答对/指令数据。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
分段边界质量	不破句率 100%；表格/公式/代码整体成块率 ≥ 95%；目标长度区间命中率 ≥ 90%。
下游检索提升	相对固定长度分段基线，RAG 检索 Recall@k / nDCG 提升 ≥ 10%（或给出显著提升证据）。
语义完整	片段内语义完整性（人工评估）≥ 85%。
打标与摘要	内容标签准确率 ≥ 85%；摘要忠实度 ≥ 90%（无臆造）。
原文回链	片段 → 原文锚点回链完整率 100%。
（进阶）QA 合成	若实现：生成问答对可答性 ≥ 90%、忠实度 ≥ 90%。

七、交付物

可运行的分段智能体一套，对外暴露标准接口供转换流水线调用，输入结构化全文、输出 chunk 序列；附与定长切分的下游检索对比实验与示例数据。

课题 12 内容保真度与治理质量评估智能体

一、课题背景

自动化治理会改写文本（去噪、修复、归一），但“改写”有风险：可能过度清洗删掉有效信息，可能误改语义。要让治理结果可信，必须有一种能力来评估“**治理前后语义是否一致、是否过度改写、可读性与结构是否合格**”。用大模型做裁判（**LLM-as-Judge**）是当前评估范式的前沿，但其“评分稳定性、与人类判断的一致性、可解释性、抗偏置”是公认难点。

在数据治理中，这类“语义质量评估”难以用传统规则衡量，是质检环节中最难、最依赖语义理解的部分，适合从质检智能体中抽出、做成可被调用的专项能力。开源评测多面向“生成质量打分”，较少针对“**治理保真度（前后比对）**”这一特定场景，也缺乏“锚点级瑕疵定位”与“评分可复现”的约束。本课题区别于一般生成打分的研究重点，在于：面向“治理前后比对”这一特定场景，把“**裁判本身的可信度（稳、准、可解释、可复现）**”作为研究对象，并要求评估结果可锚点定位。

二、研究目标与功能描述

设计并实现一个内容保真度与治理质量评估智能体：抽样比对治理前后文本，判定语义一致性、识别过度清洗与误改、评估可读性与结构质量，输出可锚点定位、可复现的评估结果（维度评分 + 锚点级瑕疵清单 + 判定理由）。作为服务被质检环节按需调用。

三、核心能力与 Skill 示例（非完整清单，鼓励自主设计补全）

- **语义一致性评估**：治理前后比对，判定是否保真。
- **过度清洗/误改识别**：定位被错误删除或改写的内容。
- **可读性与结构质量评估**：标题树合理性、段落连贯性、表格可读性。
- **锚点级瑕疵定位**：评估结果可回溯到具体位置。
- **评分稳定性与可解释性**：降低评分波动、给出判定理由。
- 可自行补充：评分稳定化（多次采样/投票）、与人工标注的一致性校准、抗位置/长度偏置等。如何让大模型裁判“**稳、准、可解释**”，是本课题的研究核心。

四、研究重点、难点与差异化（含与开源/通用方案的区别）

- **核心难点**：LLM-as-Judge 的评分稳定性与人类一致性是公认难点；要面向“治理保真度”这一特定场景，做前后比对、过度清洗识别与可读性评估，并可锚点定位。
- **与开源方案的区别**：开源评测多面向一般生成打分；本课题专门服务“治理前后比对”这一场景，并把“裁判可信度”本身作为研究对象（评分稳定性、与人类一致性、抗偏置、可解释、可复现）。
- **“评分稳定化 + 一致性校准”是研究亮点**：需给出与人工标注的相关性、同输入多次评估的方差等可验证证据。
- **可作为被调用的服务设计**，输出需可被质检智能体直接消费并驱动路由。

五、期望的输入与输出

期望输入	期望输出
治理前后文本对（带锚点）。	保真度/可读性等维度评分 + 锚点级瑕疵清单 + 判定理由（可复现）。

六、技术指标与验收标准

指标项	目标值与说明（建议值，可结合数据集与场景调整，但须可度量、可验证）
与人工一致性	评分与人工评估的相关性/一致率达标（如相关性 ≥ 0.8 ，核心考核项）。
评分稳定性	同一输入多次评估的方差足够小（低温度/固定策略下可复现）。
瑕疵检出	过度清洗/误改识别的 precision / recall 达标（如 $F1 \geq 0.8$ ）。
可解释性	判定理由合理、可被人工复核。
瑕疵可定位	评估结果均可锚点定位到具体位置，定位准确率 $\geq 90\%$ 。
可复现	评估过程可复现（固定策略、留存判定依据）。

七、交付物

可运行的评估智能体一套，对外暴露标准接口供质检流水线调用，输入前后文本对、输出评分与瑕疵清单，附评测集与示例数据。

结语

请各选题同学在动手前充分调研同类开源方案与最新研究进展，明确本智能体相较通用 / 开源方案的差异与攻关点（即“为什么值得研究”），并在最终技术报告中清晰回答：做了什么、为什么这样做、与已有方案差在哪、指标如何、还有哪些不足。基础解析能力已有成熟方案，研究价值在于把它升级为面向治理、可控、可追溯、可集成的智能体。

最终交付应为“可运行、可集成、可评测、可复现”的智能体服务，对外暴露稳定的标准接口；后续将按需接入统一治理平台，因此接口与数据规范的清晰、稳定、可版本化尤为关键。各项技术指标为建议达成目标，可结合所用数据集与具体场景，由指导教师与同学共同商定具体阈值，但须保证指标可度量、可验证。