

基于多任务联合学习与自适应融合的多模态情感分析模型*

樊继冬^a, 仲兆满^{a,b†}, 韩天乐^a, 李梦晗^a, 崔心如^a, 徐瑾^a

(江苏海洋大学 a. 计算机工程学院; b. 江苏省海洋资源开发研究院, 江苏 连云港 222005)

摘要: 针对多模态情感分析中模态异质性特征关注不足导致的特征冗余和噪声干扰问题,提出了一种基于多任务联合学习与自适应融合的多模态情感分析模型(MTL-SAF)。该模型创新性地构建了多任务联合情感分析模块,通过同时处理多模态和单模态任务来全面捕捉模态间异质性特征,并引入动态权重分配的自适应融合机制以抑制冗余噪声。模型采用多尺度特征提取策略,有效融合低级与高级特征以增强情感信息表达能力。在SIMS、MOSI和MOSEI数据集上的实验结果表明,MTL-SAF在情感分类准确率和 F_1 值等指标上均显著优于现有基线模型,验证了其在处理模态异质性和增强特征表达方面的优越性。

关键词: 多模态情感分析; 多任务学习; 异质特征; 自适应融合; 多尺度特征; 多模态融合

中图分类号: TP391 **文献标志码:** A **文章编号:** 1001-3695(2025)09-003-2583-07

doi:10.19734/j.issn.1001-3695.2025.03.0038

Multimodal sentiment analysis model based on multi-task joint learning and adaptive fusion

Fan Jidong^a, Zhong Zhaoman^{a,b†}, Han Tianle^a, Li Menghan^a, Cui Xinru^a, Xu Jin^a

(a. School of Computer Engineering, b. Jiangsu Institute of Marine Resources Development, Jiangsu Ocean University, Lianyungang Jiangsu 222005, China)

Abstract: To address feature redundancy and noise caused by modal heterogeneity in multimodal sentiment analysis, this paper proposed a novel model named MTL-SAF. The model built a multi-task sentiment analysis module to process multimodal and single-modal tasks simultaneously. This design captured inter-modal heterogeneous features more comprehensively. It introduced a self-adaptive fusion mechanism with dynamic weight allocation to suppress redundant information. It applied a multi-scale feature extraction strategy to integrate both low-level and high-level features, enhancing sentiment representation. Experiments on SIMS, MOSI, and MOSEI datasets show that MTL-SAF achieves higher accuracy and F_1 scores than existing baseline models. Results demonstrate strong performance in handling modal heterogeneity and confirm the model's effectiveness in improving feature representation.

Key words: multimodal sentiment analysis; multi-task learning; heterogeneous characteristics; self-adaptive fusion; multi-scale feature; multimodal fusion

0 引言

随着社交媒体、在线评论和视频内容的爆炸式增长,多模态情感分析(MSA)^[1]已成为自然语言处理领域的重要研究方向。多模态情感分析旨在通过整合文本、音频和视觉等多种模态信息^[2],实现对用户情感的精准识别与分类。与传统的单模态情感分析相比,多模态方法能够利用不同模态之间的互补性提升情感分析的准确性和鲁棒性。然而,多模态数据之间存在显著的异质性差异,不同模态的表达方式、信息粒度和噪声特征各不相同,使得模态融合面临复杂的特征对齐与信息冗余问题。当前研究多采用跨模态融合模型实现特征交互,但多数方法对模态异质性关注不足^[3]。例如,基于张量的融合方法虽然能够实现模态间的特征交互,但其固定的融合机制难以适应不同模态间的动态关联,从而限制了模型的性能。同时,现

有的多任务学习方法虽然能够增强模型的泛化能力,但往往未能充分利用单模态与多模态任务之间的结构互补性,在刻画模态异质性和构建判别性情感特征方面仍存在不足^[4]。此外,部分方法未能有效整合不同语义层级的信息,导致模型难以全面捕捉情感表达的多层次特征。

为解决上述问题,需要一种能够充分感知模态异质性、动态适应模态关联性,并整合多尺度特征信息的模型框架。在此背景下,本文提出了一种基于多任务联合学习与自适应融合的多模态情感分析模型(MTL-SAF)。该模型的核心思想是通过多任务学习框架同时优化多模态和单模态情感分析任务,从而更全面地捕捉模态间的异质性特征。与现有方法不同,MTL-SAF模型引入了一种动态权重分配的自适应融合机制,能够根据模态间的关联度自动生成权重矩阵,有效抑制融合过程中的冗余噪声;此外,模型采用多尺度特征提取策略,通过同时捕获低级特征(如局部纹理和音调)与高级特征(如语义和情感倾

收稿日期: 2025-03-04; 修回日期: 2025-04-14

基金项目: 国家自然科学基金资助项目(72174079);江苏省“青蓝工程”大数据优秀教学团队资助项目(2022-29);连云港市重点研发计划(产业前瞻与关键核心技术)资助项目(CG2323)

作者简介: 樊继冬(1999—),男,江苏连云港人,硕士,主要研究方向为多模态情感分析;仲兆满(1977—),男(通信作者),江苏连云港人,教授,硕导,博士,主要研究方向为大数据采集与挖掘应用、自然语言处理、社交网络分析(zhongzhaoman@163.com);韩天乐(1999—),男,江苏南京人,硕士,主要研究方向为多模态反讽识别;李梦晗(2000—),女,内蒙古赤峰人,硕士,主要研究方向为数据集应用;崔心如(1999—),女,安徽蚌埠人,硕士,主要研究方向为事件预测;徐瑾(2001—),女,江苏南京人,硕士,主要研究方向为高校舆情分析。

向)确保情感信息的全面表达。

本研究的贡献主要体现在以下三个方面:a)提出了一种多任务联合情感分析框架,通过多模态和单模态任务学习模态间异质特征,显著提升了模型的情感分类能力;b)设计了一种基于动态权重分配的自适应融合机制,有效解决了模态融合中的噪声干扰问题;c)通过多尺度特征提取策略,实现了对情感信息的全面表达,进一步提升了模型的性能。实验结果表明,本文方法在多个主流多模态情感分析数据集上均取得了优异的性能,验证了其在处理模态异质性和增强特征表达方面的有效性和优越性。

1 相关工作

多模态情感分析作为情感计算领域的重要研究方向,近年来受到了广泛关注,其核心目标是通过融合文本、语音、视觉等多种模态的信息,实现对人类情感的全面理解和分析。本章从多模态特征提取、跨模态融合方法以及多任务学习三个方面对相关研究进行综述,并分析现有方法的局限性及其未来发展方向。

1.1 多模态特征提取

多模态情感分析的核心任务是从不同模态中提取有效的特征表示。早期研究主要依赖于手工设计的特征,例如文本的 TF-IDF、语音的 MFCC 以及视觉的 HOG 等^[5]。这类方法虽然能够表征模态信息,但其性能严重依赖领域知识,且难以捕捉模态间的复杂关联。近年来,随着深度学习技术的快速发展,基于神经网络的特征提取方法逐渐成为主流,并在各模态中取得了显著进展。在文本模态方面,预训练语言模型(如 BERT^[6]、RoBERTa^[7])通过在大规模语料库上进行预训练,能够捕捉丰富的语义信息,显著提升了文本情感分析的性能。此外,GPT 系列模型^[8]和最新的 LLaMA^[9]通过生成式预训练进一步扩展了文本特征的表达能力。在语音模态方面,基于卷积神经网络(CNN)和循环神经网络(RNN)模型被广泛应用于语音特征的提取,例如通过 CNN 提取频谱特征或利用 RNN 建模时序依赖关系^[10]。近年来,Radford 等人^[11]预训练语音模型,通过大规模数据学习显著提升了语音特征的泛化能力。在视觉模态方面,深度卷积神经网络(如 ResNet^[12]、VGG^[13])通过端到端的学习方式,在面部表情识别和情感分析任务中表现出色。此外,CLIP^[14]等视觉-语言预训练模型通过跨模态对齐学习,进一步增强了视觉特征的语义表达能力。

尽管上述方法在单模态特征提取方面取得了显著成果,但现有研究大多独立处理各模态的特征,未能充分考虑模态间的关联性。例如,文本和语音在情感表达上可能存在语义互补性,而视觉和语音则可能共享某些情感线索。针对这一问题,部分研究尝试通过联合学习或多任务学习的方式提取跨模态共享特征^[15],但这些方法在模态异质性特征的挖掘方面仍存在不足。未来研究可以结合预训练模型与领域知识进一步提升特征表达能力,并探索如何更有效地建模模态间的差异性。

1.2 跨模态融合方法

跨模态融合是多模态情感分析的核心环节,旨在将不同模态的特征进行有效整合。早期的融合方法主要采用特征拼接、加权求和等简单策略^[16],这些方法虽然实现简单,但往往忽视了模态间的异质性,导致融合特征存在冗余和噪声干扰。近年来,基于注意力机制的融合方法受到广泛关注。例如,Zadeh 等人^[17]提出了记忆融合网络(MFN),通过引入记忆模块捕捉模态间的动态交互信息。Tsai 等人^[18]则提出了多模态 Transformer 模型,利用自注意力机制实现模态间的对齐和融合,显著提升了跨模态交互的效果。与 MFN 相比,多模态 Trans-

former 能够更好地建模长距离依赖关系,但其计算复杂度较高。此外,图神经网络(GNN)也被引入到多模态融合任务中,通过构建模态间的图结构来建模复杂的依赖关系^[19]。例如,一些研究利用 GNN 将不同模态表示为图中的节点,通过消息传递机制实现模态间的信息交互。然而,GNN 的计算开销较大,难以扩展到大规模数据集。

尽管这些方法在一定程度上提升了融合效果,但仍存在一些局限性:a)注意力机制可能过度依赖单一模态的主导信息,导致其他模态的特征被弱化或忽略;b)现有方法大多仅关注高级语义特征的融合,忽略了低级特征(如文本的词向量、语音的频谱特征、视觉的边缘信息)中蕴涵的丰富情感线索。未来研究可以探索层次化融合机制,结合低级特征与高级特征以更全面地捕捉情感信息。此外,设计轻量化的融合方法以降低计算复杂度,也是一个重要的研究方向。

1.3 多任务学习

多任务学习通过共享相关信息,能够有效提升模型的泛化能力和鲁棒性。在多模态情感分析领域,多任务学习被广泛应用于挖掘模态间的共享特征和独有特征。例如,Hazarika 等人^[2]提出了 MISA 模型,通过引入模态不变表示和模态特定表示的双重学习机制,实现了对模态异质性的有效建模;Sun 等人^[20]则设计了一种多任务学习框架,通过同时优化情感分类任务和情感强度预测任务,显著提升了模型的情感分析性能。然而,现有多任务学习方法仍存在一些局限性:a)大多数方法采用简单的共享参数机制,难以充分建模模态间复杂的交互关系;b)由于不同任务的目标可能存在冲突,如何动态调整任务权重以避免负迁移现象,仍然是一个具有挑战性的问题;c)现有方法通常缺乏对任务间依赖关系的显式建模,限制了模型在多模态场景下的性能提升。因此,设计更高效的多任务学习机制以更好地平衡模态共享特征与特有特征的学习,是未来研究的重要方向之一。

针对现有方法在多模态情感分析中存在的模态异质性特征挖掘不足、融合过程中冗余噪声干扰以及情感信息表达不充分等问题,本文提出了一种结合多任务联合学习、跨模态门控机制和多尺度特征提取的多模态情感分析模型。该模型通过设计多任务联合模块,分别学习不同模态的独有特征和共享特征,充分挖掘模态间的异质性信息;引入自适应融合模块,通过计算模态间关联性动态调整特征权重,有效降低融合过程中的冗余噪声干扰;采用多尺度特征提取策略,同时捕获低级特征与高级特征,全面表达情感信息,显著增强了模型对多模态情感数据的表征能力。

2 MTL-SAF 模型

为了充分挖掘模态间的异质特征信息和减少多模态融合带来的噪声问题,本文提出了基于多任务联合学习与自适应融合的多模态情感分析模型(MTL-SAF)。MTL-SAF 模型结构如图 1 所示,主要分为单模态特征提取、自适应融合模块和多任务情感分析三部分。

单模态特征提取中利用特征提取器分别提取音频、文本和视觉模态的特征向量作为初始特征。利用 CNN 提取特征的低级信息,利用 LSTM 网络提取特征的高级信息。在多尺度特征融合部分,考虑到低级特征在情感预测中起到特征补充的作用,将低级特征与高级情感特征拼接得到多尺度特征,使得特征中情感信息更加完整。自适应融合模块通过模态与模态之间的关联性赋予不同的权重信息,利用注意力机制完成情感融合。此外,多任务情感分析任务中有效地考虑到模态间异质特征是特有的有效信息,通过损失调优的方式来完成最终情感预测。




图1 MTL-SAF 模型结构

Fig. 1 Structure of MTL-SAF model

2.1 单模态特征提取

对于给定的视频片段 $u = \{a, t, v\}$, 其中 a 示音频模态, t 表示文本模态, v 表示视觉模态。分别使用 librosa^[21] 提取音频初始特征 X_a , BERT 提取文本初始特征 X_t , OpenFace^[22] 提取视觉初始特征 X_v , 公式如下:

$$X_a = \text{LibROSA}(a) \quad (1)$$

$$X_t = \text{BERT}(t) \quad (2)$$

$$X_v = \text{Openface}(v) \quad (3)$$

将初始特征 X_a, X_t, X_v 作为输入张量, 其形状为 (B, L, Din) , 分别通过卷积神经网络 (CNN) 进行卷积操作, 获得低级特征 X_{ca}, X_{ct}, X_{cv} , 如式 (4) 所示。

$$X_{cm} = \text{Dropout}(\text{ReLU}(\sum_{i=0}^{K-1} w_i \cdot x_{m+i} + b)), m \in (a, t, v) \quad (4)$$

其中: B 是批量大小; L 为序列长度; Din 是输入特征维度; K 为卷积核大小; w_i 是卷积核的权重; b 为偏置项。

将低级特征 X_{ca}, X_{ct}, X_{cv} 通过一个双向的长短时记忆网络 (LSTM) 获得上下文感知的高级语义特征, 计算公式如下:

$$\vec{h}_t^m, \vec{c}_t^m = \text{LSTM}(x_t^m, \vec{h}_{t-1}^m, \vec{c}_{t-1}^m), m \in (a, t, v) \quad (5)$$

$$\overleftarrow{h}_t^m, \overleftarrow{c}_t^m = \text{LSTM}(x_t^m, \overleftarrow{h}_{t+1}^m, \overleftarrow{c}_{t+1}^m), m \in (a, t, v) \quad (6)$$

$$X_{lm} = [\vec{h}_t^m; \overleftarrow{h}_t^m], m \in (a, t, v) \quad (7)$$

其中: x_t^m 是时间步 t 的输入向量; $\vec{h}_t^m, \vec{c}_t^m$ 分别表示前向 LSTM 在时间步 t 的隐藏状态和细胞状态; $\overleftarrow{h}_t^m, \overleftarrow{c}_t^m$ 分别表示后向 LSTM 在时间步 t 的隐藏状态和细胞状态; X_{lm} 表示高级特征。将 X_{lm} 通过 MLP 后与低级特征拼接形成多尺度情感特征 X_{cat_m} 。

$$X_{cat_m} = \text{MLP}(X_{lm}) \oplus X_{cm}, m \in (a, t, v) \quad (8)$$

2.2 自适应融合模块

自适应融合模块旨在解决任意两模态在跨模态融合过程中产生的噪声干扰问题, 该模块主要由关联性计算和多头注意力融合两部分组成。以下以文本模态和视觉模态为例, 详细阐述该模块的设计原理。

首先, 将文本高级特征 X_{lt} 和视觉高级特征 X_{lv} 通过线性层映射到相同的特征空间中。为了量化文本和视觉模态之间的相似性, 计算其余弦相似度 S ^[23], 该相似度反映了两个模态在

情感空间的角度关系。余弦相似度 S 计算公式如下:

$$S = \frac{X_{lt} \cdot X_{lv}}{\|X_{lt}\| \|X_{lv}\|} \quad (9)$$

其中: $\cdot$ 表示向量点积; $\|\cdot\|$ 表示欧几里德范数。该相似度 S 的值在 $[-1, 1]$ 间, 值越接近 1 表示两个模态在情感空间中越相似, 值越接近 0 表示两个模态的情感特征相差较大。

在计算了模态间的相似度后, 将文本高级特征与视觉高级特征进行拼接以构建联合特征表示。拼接后的特征向量为

$$z = [X_{lt}; X_{lv}] \in \mathbb{R}^{d_{lt} + d_{lv}} \quad (10)$$

其中: z 表示联合特征。然后通过线性变换矩阵 W_1 和偏置向量 b_1 将联合特征映射到一个隐藏层表示, 该隐藏层表示捕获了两个模态的共享信息, 并通过 ReLU 激活函数引入非线性, 从而使模型能够学习更复杂的模态交互模式。

$$h = \text{ReLU}(W_1 \cdot z + b_1) \quad (11)$$

在共有信息 h 的基础上, 引入相似度 S 来进一步调整模态间的融合。通过全连接网络, 将相似度 S 与共有信息 h 综合, 计算得到最终的门控权重 α 。

$$\alpha = \sigma(W_3 \cdot S + W_2 \cdot h + b_2) \quad (12)$$

其中: W_2 和 W_3 为可学习的权重矩阵; b_2 为偏置项; σ 为 sigmoid 激活函数。通过 sigmoid 激活函数, 门控值 α 会限制在 $(0, 1)$ 内, 用于表示文本和视觉模态在融合过程中的相对权重。具体而言, 当两个模态之间的相似度较高时, 门控值 α 较大, 意味着两个模态应该被更强地融合; 而当模态之间的相似度较低时, 门控值 α 会较小, 表明两个模态的融合贡献相应减弱。这种设计能够自适应地调整模态间的融合强度, 从而有效抑制噪声干扰并增强关键信息的表达。

在多头注意力融合部分, 分别对文本模态和视觉模态的多尺度特征 $X_{cat_v} \in \mathbb{R}^{b \times d_1}$ 和 $X_{cat_t} \in \mathbb{R}^{b \times d_2}$ 进行线性变换, 以得到查询 Q 、键 K 和值 V , 计算公式如下:

$$Q_i = W_{\text{query}_i} \cdot X_{cat_t} \in \mathbb{R}^{B \times \text{num_heads} \times \text{head_dim}} \quad (13)$$

$$K_i = W_{\text{key}_i} \cdot X_{cat_v} \in \mathbb{R}^{B \times \text{num_heads} \times \text{head_dim}} \quad (14)$$

$$V_i = W_{\text{value}_i} \cdot X_{cat_v} \in \mathbb{R}^{B \times \text{num_heads} \times \text{head_dim}} \quad (15)$$

其中: d_1 和 d_2 分别表示文本模态和视觉模态的多尺度特征维度; num_heads 为注意力头的数量; $i = 1, 2, \dots, \text{num_heads}$,

$head_dim$ 是每个注意力头的维度。

计算查询 Q 和键 K 的点积,得到注意力得分 $scores_i$ 。

$$scores_i = \frac{Q_i \cdot K_i^T}{\sqrt{head_dim}} \quad (16)$$

通过对得分 softmax 操作,得到归一化的注意力权重 att_w_i 。

$$att_w_i = \text{softmax}(scores_i) \quad (17)$$

然后,注意力权重对值 V_i 进行加权,得到注意力输出 att_out_i ,将所有注意力头输出拼接得到最终的多头注意力输出,计算公式如下:

$$att_out_i = att_w_i \cdot V_i \quad (18)$$

$$att_out = \text{concat}(att_out_1, att_out_2, \dots, att_out_{num_heads}) \quad (19)$$

将式(12)中计算得到的门控值 α 应用于加权融合的多头注意力机制的输出特征 att_out 。具体地,将 α 与 att_out 相乘,得到加权后的融合特征;同时,通过残差连接对文本多尺度特征进行加权,其中残差连接的加权系数由 $1 - \alpha$ 控制,确保了当文本与视觉模态关联性低时,文本模态信息仍能有效传递。最后,将融合后的特征通过一个线性变换层进行变换,得到最终的输出特征 $output$,具体计算过程如式(20)所示。

$$output = W_{out}(\alpha \cdot att_out) + (1 - \alpha)X_{cat_t} \quad (20)$$

其中: W_{out} 是可训练的线性变化矩阵。基于上述融合原理,模型能够对任意两个模态进行自适应融合,分别得到文本音频融合特征 X_{ta} 、文本视觉融合特征 X_{tv} 以及视觉音频融合特征 X_{va} 。

在三模态的跨模态融合^[24]中,首先将三组双模态特征拼接成三模态特征 X_{atv} 作为键 K 和值 V ,双模态特征作为查询 Q ;然后通过多头注意力实现跨模态融合;最后,将跨模态特征拼接后经过 MLP 得到多模态最终特征用于情感分类。

$$X_{atv} = \text{concat}(X_{ta}, X_{tv}, X_{va}) \quad (21)$$

$$X_{ta_atv} = \text{multi_head_attention}(X_{ta}, X_{atv}, X_{atv}) \quad (22)$$

$$X_{tv_atv} = \text{multi_head_attention}(X_{tv}, X_{atv}, X_{atv}) \quad (23)$$

$$X_{va_atv} = \text{multi_head_attention}(X_{va}, X_{atv}, X_{atv}) \quad (24)$$

$$X_{mult} = \text{MLP}(\text{concat}(X_{ta_atv}, X_{tv_atv}, X_{va_atv})) \quad (25)$$

2.3 多任务情感分析

对于单模态的情感任务,数据集中缺少单模态情感标签。为此,本文利用互信息最大化(MIM)原理进行单模态标签生成,使其既能反映各自单模态情感信息,又能与多模态情感标签保持相关性,同时减少不同单模态之间的冗余信息。

下面以文本标签生成任务为例,详细阐述基于互信息最大化的标签生成原理。首先,最大化单模态标签与单模态特征的互信息,最大化单模态标签与多模态标签的互信息,最小化单模态标签与单模态特征之间的互信息。

$$\max I(Y^T; X^T) + \max I(Y^T; Y^M) - I(Y^T; X^M), m \in \{V, A\} \quad (26)$$

其中: $I(Y^T; X^T)$ 表示文本模态情感标签 Y^T 与文本情感特征 X^T 之间的互信息; $I(Y^T; Y^M)$ 表示文本模态情感标签 Y^T 与多模态情感标签 Y^M 之间的互信息; $I(Y^T; X^M)$ 表示文本情感标签 Y^T 与单模态特征 X^M 之间的互信息。

因此,优化目标 $\mathcal{L}$ 的公式如下:

$$\mathcal{L} = I(Y^T; X^T) + \lambda_1 I(Y^T; Y^M) - \lambda_2 \sum_{m \in \{V, A\}} I(Y^T; X^m) \quad (27)$$

其中: λ_1 和 λ_2 是权重值,分别控制单模态标签对多模态标签的相关性和不同单模态之间的冗余信息。

由于互信息的计算涉及到难以求解的概率分布,直接优化互信息比较困难,引入变分分布 $q(Y|X)$ 近似 $p(Y|X)$,并假设先验分布 $r(Y)$ 近似 $p(Y)$ 。通过变分信息下界(VIB)^[25]进行优化:

$$I(Y; X) = \mathbb{E}_{p(X, Y)} [\log \frac{p(Y|X)}{p(Y)}] = \mathbb{E}_{p(X, Y)} [\log \frac{p(Y|X)}{q(Y|X)} \cdot \frac{q(Y|X)}{r(Y)} \cdot \frac{r(Y)}{p(Y)}] =$$

$$\mathbb{E}_{p(X, Y)} [\log \frac{q(Y|X)}{r(Y)}] + \mathbb{E}_{p(X)} [D_{KL}(p(Y|X) \| q(Y|X))] -$$

$$D_{KL}(p(Y) \| r(Y)) \quad (28)$$

因为 KL 散度非负,最终变分下界为

$$I(Y; X) \geq \mathbb{E}_{p(X, Y)} [\log q(Y|X)] - \mathbb{E}_{p(Y)} [\log p(Y)] \quad (29)$$

其中: $-\mathbb{E}_{p(Y)} [\log p(Y)]$ 表示边缘熵,与输入数据 X 和模型参数无关可忽略。

最后,根据式(28)和(29),得到式(27)的最终优化目标公式:

$$\mathcal{L} = -\mathbb{E}[\log q(Y^T|X^T)] - \lambda_1 (\mathbb{E}[\log q(Y^T|Y^M)]) + \lambda_2 \sum_{m \in \{V, A\}} \mathbb{E}[\log q(Y^T|X^m)] \quad (30)$$

式(30)中,第一项是重构误差,确保文本标签 Y^T 能准确地生成出来;第二项是对齐,确保与多模态情感保持相关性;第三项是冗余抑制,减少其他单模态对文本标签的干扰。

根据最小化损失函数 $\mathcal{L}$ 训练神经网络,使其学习从文本特征 X^T 到文本标签 Y^T 的映射关系,最终得到文本情感标签。

$$Y^T = f(X^T) \quad (31)$$

其中: $f(\cdot)$ 是训练好的神经网络模型。根据上述文本标签生成原理,依次生成视觉和音频标签。最后,联合单模态情感预测和多模态情感预测 MTL-SAF 模型训练最终总损失为

$$\mathcal{L}_{total} = \mathcal{L}_{mul} + \mathcal{L}_a + \mathcal{L}_v + \mathcal{L}_t \quad (32)$$

其中: $\mathcal{L}_{total}$ 表示最终总损失; $\mathcal{L}_{mul}$ 表示多模态情感预测损失; $\mathcal{L}_a$ 表示音频情感预测损失; $\mathcal{L}_v$ 表示视觉情感预测损失; $\mathcal{L}_t$ 表示文本情感预测损失。

3 实验结果与分析

3.1 数据集与评价指标

本文将在公开数据集 CMU-MOSI^[26]、CMU-MOSEI^[27] 和 CH-SIMS^[28] 进行实验验证。CMU-MOSI 数据集来自 YouTube 的 93 名不同发言者的视频,涵盖电影评论、产品评价等,主要包含文本、视觉、音频三种模态信息,情感强度标签为 $[-3, 3]$,可用于二分类、三分类、五分类或七分类任务。CMU-MOSEI 是 CMU-MOSI 的扩展版本,来自 3 000 多个视频片段,包含各种日常对话、演讲等,跨多个主题。CH-SIMS 数据集是一个中文的多模态情感分析数据集,从各类短视频、访谈、综艺节目、新闻等不同场景的视频中采样。与 MOSEI 和 MOSI 数据集不同, SIMS 数据集提供单模态情感标签,情感强度在 $[-1, 1]$,适用于二分类和三分类任务。实验过程中数据集分别按照 6:2:2 的比例划分成训练集、验证集和测试集。

为了确保模型性能评估的客观性和全面性,在三个独立的数据集上分别进行了回归和分类任务的性能测试。在回归任务中,采用平均绝对误差(MAE)和皮尔森相关系数(Corr)作为评估指标,以衡量模型对情感强度的预测精度及其与真实标签的线性相关性。对于分类任务,选取二分类准确率(Acc2)、三分类准确率(Acc3)、七分类准确率(Acc7)以及 F_1 值(F_1 -score)作为评价标准,以综合考量模型在不同分类场景下的准确性和稳健性。

3.2 实验细节与参数设置

实验的硬件配置和软件环境如表 1 所示。

表 1 硬件配置与软件环境

Tab. 1 Hardware configuration and software environment

硬件	型号	软件	版本
CPU	16 vCPU Intel®	Torch	2.1
	Xeon® Gold 6430	Python	3.8
GPU	RTX 4090 24 GB	CUDA	11.8

模型优化器选择 Adam,分类任务使用交叉熵损失函数(CE),回归任务使用平均绝对误差损失函数(MAE),其他超

参数根据验证集表现设置如表2所示。

表2 模型参数
Tab. 2 Model parameters

参数	数值		
	CMU-MOSI	CMU-MOSEI	CH-SIMS
学习率	3E-5	2E-5	2E-5
特征序列长度	50	50	80
批处理大小	32	64	64
卷积核大小	5×5	5×5	5×5
LSTM 隐藏层维度	256	256	256
注意力头数量	4	4	6
Dropout	0.2	0.15	0.22

3.3 对比实验与结果分析

为了验证 MTL-SAF 模型的性能,将以下基线模型作为参考基准,用于对比实验。

a) TFN^[29]:一种基于张量融合的多模态建模方法。该方法通过对提取的单模态特征进行交替笛卡尔积运算,构建多维张量,从而同时捕捉模态内和模态间的动态交互信息。

b) LMF^[30]:TFN 的改进版本,通过引入低秩多模态融合机制,利用特定模态因子对多模态特征进行高效融合,生成多模态输出表示。

c) MFN^[17]:一种基于多视图门控记忆模块的多模态融合方法。该方法通过提取不同子模态的相邻时序特征,实现特定视图内与跨视图的交互。此外,MFN 引入了一种特殊的注意力机制,构建多视图门控记忆模块,以增强模型对多模态动态特征的建模能力,同时提高模型的可解释性。

d) MMATR^[31]:一种基于注意力的张量融合方法,用张量收缩和张量回归层替换通常的池化和扁平化操作以及线性层,能够减少参数数量,同时保持多模态数据的高阶结构,使用双模注意力学习更多的多模态特征。

e) FmlMSN^[32]:一种基于模态标签的多阶段学习网络。该模型通过设计六项单模态任务和三项双模态任务,分阶段学习模态内和模态间的特征表示,从而提升最终情感预测的性能。FmlMSN 的多阶段学习框架有效增强了模型的鲁棒性,使其能够更好地适应多模态情感分析任务中的复杂场景。

f) CMHFN^[24]:一种跨模态分层融合方法,充分考虑了不同层次中模态的独特提示、模态间的共同信息以及不同层次的情感变化。结合了单模态、双模态和三模态任务,分层次提取并融合多模态特征,从而增强最终情感预测的特征表示能力。

g) Self-MM^[33]:一种基于自监督学习的多任务模型。该模型通过自动生成单模态情感标签,结合多任务学习框架实现了对多模态情感数据的有效建模。

h) MTSA^[34]:一种基于多任务学习与层叠 Transformer 的模态情感分析模型。通过累加辅助模态任务损失以筛除噪声并保留模态特征异质性,使用多任务门控机制和层叠 Transformer 结构融合文本、音频与视觉模态特征,提升融合深度,避免融合特征冗余。

i) CUW-MSA^[35]:一种单项加权的多模态情感分析方法。单向加权模块进行模态内信息提取与多模态信息交互,KL 散度对比学习减少冗余信息提取,含过滤门控的时间卷积网络(TCN)增强单模态特征表达能力。

表3~5分别展示了 MTL-SAF 模型在 CMU-MOSI、CMU-MOSEI 和 CH-SIMS 三个基准数据集上的实验结果。实验结果表明,在分类任务中,MTL-SAF 模型相较于最优基线模型取得了显著提升:在 MOSI 数据集上,Acc2、 F_1 和 Acc7 分别提升了 1.17、0.47 和 0.4 个百分点;在 MOSEI 数据集上,这三个指标分别提升了 0.12、0.24 和 2.44 个百分点。在回归任务中,MTL-SAF 模型在 MAE 和 Corr 指标上也表现出色。

表3 MOSI 数据集实验结果
Tab. 3 Experimental results on MOSI dataset

模型	Acc2/%	F_1 /%	Acc7/%	MAE	Corr
TFN	74.62	74.51	28.75	1.040	0.587
LMF	76.42	76.41	33.84	0.912	0.668
MFN	77.14	77.32	34.11	0.965	0.632
MMATR	83.80	83.72	—	—	—
FmlMSN	78.11	77.95	34.37	0.939	0.658
CMHFN	80.18	40.82	45.97	0.840	0.722
Self-MM	84.42	84.41	47.62	0.706	0.798
CUW-MSA	84.52	84.14	46.68	0.701	0.794
MTL-SAF	85.69	84.88	48.02	0.692	0.792

表4 MOSEI 数据集实验结果
Tab. 4 Experimental results on MOSEI dataset

模型	Acc2/%	F_1 /%	Acc7/%	MAE	Corr
TFN	80.95	81.18	47.32	0.657	0.618
LMF	78.65	79.32	47.63	0.660	0.623
MFN	79.92	79.19	47.45	0.646	0.626
MMATR	84.81	84.62	—	—	—
FmlMSN	82.87	82.50	50.91	0.578	0.726
CMHFN	84.09	83.83	52.39	0.560	0.733
Self-MM	83.87	83.65	—	0.546	0.765
MTSA	83.51	83.38	—	0.557	0.735
CUW-MSA	82.85	82.81	54.24	0.535	0.756
MTL-SAF	84.93	84.86	56.68	0.543	0.769

表5 SIMS 数据集实验结果
Tab. 5 Experimental results on SIMS dataset

模型	Acc2/%	F_1 /%	Acc3/%	MAE	Corr
TFN	78.38	78.62	65.12	0.432	0.591
LMF	79.43	79.75	66.52	0.411	0.630
MFN	80.02	79.74	68.01	0.436	0.574
FmlMSN	83.59	83.71	70.90	0.385	0.680
CMHFN	84.46	84.08	68.27	0.380	0.685
Self-MM	80.04	80.44	65.47	0.424	0.569
MTSA	84.18	83.98	71.42	0.388	0.649
MTL-SAF	84.65	84.88	72.24	0.386	0.695

通过对比分析不同融合方法的性能表现,可以得出以下结论:首先,相较于 TFN 和 LMF 等采用传统张量融合方法的模型,基于注意力机制的融合方法(如 MFN 和 MMATR)能够更有效地降低模态融合过程中的噪声干扰。这是因为传统张量融合方法采用固定的特征交互方式,难以动态适应不同模态之间的关联关系,而注意力机制可以根据模态的重要性自适应地调整特征权重,从而增强有效信息的传递,提高模型的鲁棒性和表达能力。其次,与多任务情感分析网络相比,仅依赖注意力融合的网络无法充分挖掘单模态内部的情感信息,可能导致关键特征的丢失或弱化,从而影响最终的情感分类效果。

相比之下,MTL-SAF 模型在多任务情感分析网络中的表现最优,验证了其在单模态特征建模和多模态融合方面的有效性。互信息最大化策略的核心思想是利用单模态与多模态间的信息一致性来生成单模态标签,从而使模型在情感分析任务中能够有效考虑单模态特征的异质性。在训练过程中,该策略不仅增强了单模态情感信息的监督信号,还使得单模态特征在融合时具备更强的判别力,从而提升最终的情感分析性能。另一方面,自适应融合机制能够根据模态间的相关性动态调整权重,使得信息融合更加精准,有效减少无关特征带来的干扰,提高情感分类的鲁棒性和泛化能力。此外,MTL-SAF 模型采用多尺度特征提取策略,通过同时建模局部和全局特征来提高情感信息的表达能力。具体而言,低层特征(如局部纹理和音调)有助于捕捉细粒度的情感线索,而高层特征(如语义信息和情感倾向)则能提供更具全局性的情感表达。这种多尺度建模方式能够进一步提升模型对复杂情感模式的捕捉能力,使其在不同模态的融合过程中更加稳健,从而提升整体的情感分类性能。

在 SIMS 数据集的实验中,相较于最优基线模型,MTL-SAF 模型在 $Acc2$ 、 F_1 和 $Acc3$ 三个指标上分别提升了 0.19、0.8 和 0.82 个百分点。尽管相较于 MOSI 和 MOSEI 数据集性能提升幅度相对较小,这主要是由于 SIMS 数据集本身提供了单模态标签,无须依赖神经网络生成标签,从而降低了互信息最大化策略带来的额外优势。然而,该实验结果进一步验证了 MTL-SAF 模型通过生成单模态标签并结合多任务情感分析策略,能够有效捕捉单模态异质特征,从而提升模型的性能。此外,MTL-SAF 模型在 SIMS 数据集上相较于其他对比模型表现最优,充分证明了其具有较强的泛化能力和鲁棒性。

3.4 消融实验

为了进一步验证 MTL-SAF 模型中各关键组件的有效性,本文设计了一系列消融实验,分别对多任务联合学习模块、自适应融合机制以及多尺度特征提取策略进行了单独移除或替换,以评估其对模型性能的贡献。消融实验在 CMU-MOSEI 数据集上进行,实验结果如表 6 所示。

表 6 MOSEI 数据集消融实验结果
Tab. 6 Results of ablation experiment on MOSEI dataset

模型	$Acc2/\%$	$F_1/\%$	$Acc7/\%$	MAE	Corr
MTL-SAF	84.93	84.86	56.68	0.543	0.769
-多任务联合	83.07	82.74	54.56	0.573	0.753
-自适应融合	83.36	83.87	54.93	0.562	0.759
-多尺度特征提取	84.30	84.31	55.86	0.555	0.762
Base	81.91	82.18	52.23	0.596	0.715

为验证多任务联合学习模块的有效性,移除了该模块,仅保留多模态情感分析任务。实验结果表明,移除多任务联合学习模块后,模型在 MOSEI 数据集上的性能明显下降。具体而言, $Acc2$ 、 F_1 和 $Acc7$ 分别下降了 1.86、2.12 和 2.12 个百分点。这一结果充分证明了多任务联合学习模块在捕捉单模态异质特征和提升模型泛化能力方面的重要作用。

为评估自适应融合机制的性能贡献,将其替换为注意力权重融合方法。实验结果显示,移除自适应融合机制后,模型在 MOSEI 数据集上的性能有所下降。 $Acc2$ 、 F_1 和 $Acc7$ 分别下降了 1.57、0.99 和 1.75 个百分点。这一结果表明,自适应融合机制通过动态分配模态权重,能够有效抑制融合过程中的噪声干扰,从而提升模型的整体性能。

为验证多尺度特征提取策略的有效性,将其替换为单一尺度特征提取方法。实验结果表明,移除多尺度特征提取策略后,模型在 MOSEI 数据集上的性能出现下降。 $Acc2$ 、 F_1 和 $Acc7$ 分别下降了 0.63、0.55 和 0.82 个百分点。这一结果证实了多尺度特征提取策略在同时捕获低级特征与高级特征、全面表达情感信息方面的重要作用。




为进一步评估各组件之间的协同作用,进行了综合消融实验(Base),即同时移除多任务联合学习模块、自适应融合机制和多尺度特征提取策略。实验结果显示,模型性能在 MOSEI 数据集上出现显著下降。 $Acc2$ 、 F_1 和 $Acc7$ 分别下降了 3.02、2.68 和 4.45 个百分点。这一结果表明,MTL-SAF 模型的各组件之间存在显著的协同效应,共同提升了模型的整体性能。消融实验的结果充分验证了 MTL-SAF 模型中各关键组件的有效性及其对整体性能的重要贡献。

3.5 实例分析

为了验证 MTL-SAF 模型在考虑模态异质特征后对情感预测准确率提升效果,本文在 CMU-MOSEI 数据集上进行了实例情感预测分析。表 7 展示了具体的预测结果,其中视频 ID 代表数据集中视频片段的唯一标识;多模态信息中 T 表示文本信息,V 表示视觉信息,A 表示音频信息;真实值为标注的情感标签,其取值为 $[-3,3]$;预测值中 T、V、A 分别表示文本、视

觉和音频模态的单独预测值,M 表示多模态融合预测值,F 表示 MTL-SAF 模型的最终预测值。

表 7 MOSEI 数据集实例预测结果
Tab. 7 Instance prediction results on MOSEI dataset

视频 ID	多模态信息	真实值	预测值
0DBfvv1VmqY-8	T:Starbuck's salted caramel, hot chocolate		T:2.115
	V:面部表情微笑		V:2.689
		2.333	A:1.563
			M:2.456
	A:语调平稳,情感倾向积极		F:2.327
0EAAflCQabY-0	T:hearing loss when I was four to the time I was like in my twenties		T:-1.325
	V:面带微笑,扬眉		V:2.889
		-0.333	A:-0.241
			M:0.452
	A:语音平缓然后略微下降		F:-0.121
0YdYFtVdlWE-15	T:oh my gosh,I really need to take time to explain everything we're doing, why we're doing it before we leave the house		T:-1.155
	V:摇头,眼神不定		V:-0.129
		0	A:0.023
			M:-0.456
	A:语调平缓		F:-0.227
0BVed2nBq1g-3	T:Like for example,a friend of mine lost her wallet		T:-1.155
	V:面带微笑,手部动作较多		V:1.244
		-0.667	A:-0.143
			M:-0.374
	A:语调略带调侃		F:-0.446

从预测结果可以看出,多模态特征预测值 M 与真实值之间的偏差普遍大于最终预测值 F 与真实值之间的偏差。特别是在第二组和第三组实例中,多模态特征预测值 M 未能准确预测真实情感,这是由于文本、视觉和音频模态表达的情感倾向不一致,导致融合过程中引入了显著的噪声干扰。例如,在第三组实例中,MTL-SAF 模型的多模态预测值 M 错误地将情感预测为消极,而真实值为中性。尽管如此,通过对比预测值与真实值可以发现,考虑模态异质特征的最终预测值 F 的误差显著小于多模态特征预测值 M 的误差。这一结果表明,MTL-SAF 模型通过引入模态异质特征,能全面地考虑情感信息,从而提升情感预测的准确性。

4 结 束 语

本文提出了一种基于多任务联合学习与自适应融合的多模态情感分析模型(MTL-SAF),通过多任务联合情感分析模块、动态权重分配的自适应融合机制以及多尺度特征提取策略,有效解决了多模态情感分析中模态异质特征利用不足和融合过程中噪声干扰的问题。实验结果表明,MTL-SAF 模型在 CMU-MOSI、CMU-MOSEI 和 CH-SIMS 数据集上的情感分类与回归任务中均显著优于现有基线模型。消融实验和实例分析进一步验证了各关键组件的有效性,同时揭示了模型在模态情感不一致时的局限性。未来研究将聚焦于模态间一致性检测、高效特征提取方法以及跨场景应用,以进一步提升模型的鲁棒性和泛化能力。

参考文献:

- [1] Zhu Linan, Zhu Zhechao, Zhang Chenwei, *et al.* Multimodal sentiment analysis based on fusion methods: a survey[J]. *Information Fusion*, 2023, 95:306-325.
- [2] Hazarika D, Zimmermann R, Poria S. MISA: modality-invariant and -specific representations for multimodal sentiment analysis[C]//Proc of the 28th ACM International Conference on Multimedia. New York: ACM Press, 2020:1122-1131.
- [3] Sun Jun, Han Shoukang, Ruan Yuping, *et al.* Layer-wise fusion with modality independence modeling for multi-modal emotion recognition[C]//Proc of the 61st Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2023:658-670.
- [4] 刘倩, 白志豪, 程春玲, 等. 基于多尺度跨模态特征融合的图文情感分类模型[J]. *计算机科学*, 2024, 51(9):258-264. (Liu Qian, Bai Zhihao, Cheng Chunling, *et al.* Image-text sentiment classification model based on multi-scale cross-modal feature fusion[J]. *Computer Science*, 2024, 51(9):258-264.)
- [5] 郭续, 买日旦·吾守尔, 古兰拜尔·吐尔洪. 基于多模态融合的情感分析算法研究综述[J]. *计算机工程与应用*, 2024, 60(2):1-18. (Guo Xu, Mairidan·Wushuer, Gulanbeyar·Turhong. Survey of sentiment analysis algorithms based on multimodal fusion[J]. *Computer Engineering and Applications*, 2024, 60(2):1-18.)
- [6] Devlin J, Chang M W, Lee K, *et al.* BERT: pre-training of deep bidirectional Transformers for language understanding[C]//Proc of Conference of the North American Chapter of the Association for Computational Linguistics; Human Language Technologies. Stroudsburg, PA: Association for Computational Linguistics, 2019:4171-4186.
- [7] Liu Yinhan, Ott M, Goyal N, *et al.* RoBERTa: a robustly optimized BERT pretraining approach[EB/OL]. (2019-07-26). <https://arxiv.org/abs/1907.11692>.
- [8] Brown T, Mann B, Ryder N, *et al.* Language models are few-shot learners[J]. *Advances in Neural Information Processing Systems*, 2020, 33:1877-1901.
- [9] Touvron H, Lavril T, Izacard G, *et al.* LLaMA: open and efficient foundation language models[EB/OL]. (2023-02-27). <https://arxiv.org/abs/2302.13971>.
- [10] 陶建华, 陈俊杰, 李永伟. 语音情感识别综述[J]. *信号处理*, 2023, 39(4):571-587. (Tao Jianhua, Chen Junjie, Li Yongwei. Review on speech emotion recognition[J]. *Journal of Signal Processing*, 2023, 39(4):571-587.)
- [11] Radford A, Kim J W, Xu Tao, *et al.* Robust speech recognition via large-scale weak supervision[C]//Proc of the 40th International Conference on Machine Learning. [S. l.]: PMLR, 2023:28492-28518.
- [12] He Kaiming, Zhang Xiangyu, Ren Shaoqing, *et al.* Deep residual learning for image recognition[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2016:770-778.
- [13] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[EB/OL]. (2015-04-10). <https://arxiv.org/abs/1409.1556>.
- [14] Radford A, Kim J W, Hallacy C, *et al.* Learning transferable visual models from natural language supervision[C]//Proc of International Conference on Machine Learning. [S. l.]: PMLR, 2021:8748-8763.
- [15] 缪裕青, 董晗, 张万楨, 等. 一种多任务学习的跨模态视频情感分析方法[J]. *计算机工程与应用*, 2023, 59(12):141-147. (Miao Yuqing, Dong Han, Zhang Wanzhen, *et al.* Cross-modal video emotion analysis method based on multi-task learning[J]. *Computer Engineering and Applications*, 2023, 59(12):141-147.)
- [16] 仲兆满, 黄贤波, 熊玉龙. 基于混合融合的突发事件多模态情感分析[J]. *江苏海洋大学学报: 自然科学版*, 2023, 32(1):1-8. (Zhong Zhaoman, Huang Xianbo, Xiong Yulong. Multimodal emotion analysis of emergencies based on hybrid fusion[J]. *Journal of Jiangsu Ocean University: Natural Science Edition*, 2023, 32(1):1-8.)
- [17] Zadeh A, Liang P P, Mazumder N, *et al.* Memory fusion network for multi-view sequential learning[C]//Proc of the 32nd AAAI Conference on Artificial Intelligence and the 30th Innovative Applications of Artificial Intelligence Conference and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence. Palo Alto, CA: AAAI Press, 2018:5634-5641.
- [18] Tsai Y H, Bai Shaojie, Liang P P, *et al.* Multimodal Transformer for unaligned multimodal language sequences[C]//Proc of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2019:6558.
- [19] 李丽, 李平. 基于交互图神经网络的方面级多模态情感分析[J]. *计算机应用研究*, 2023, 40(12):3683-3689. (Li Li, Li Ping. Aspect-level multimodal sentiment analysis based on interaction graph neural network[J]. *Application Research of Computers*, 2023, 40(12):3683-3689.)
- [20] Sun Z, Sarma P K, Sethares W A, *et al.* Graph neural networks for multimodal sentiment analysis[C]//Proc of Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2021:8554-8566.
- [21] McFee B, Raffel C, Liang Dawen, *et al.* librosa: audio and music signal analysis in Python[C]//Proc of the 14th Python in Science Conference. 2015:18-24.
- [22] Baltrušaitis T, Robinson P, Morency L P. OpenFace: an open source facial behavior analysis toolkit[C]//Proc of IEEE Winter Conference on Applications of Computer Vision. Piscataway, NJ: IEEE Press, 2016:1-10.
- [23] Li Manling, Xu Ruochen, Wang Shuohang, *et al.* CLIP-event: connecting text and images with event structures[C]//Proc of IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway, NJ: IEEE Press, 2022:16399-16408.
- [24] Wang Lan, Peng Junjie, Zheng Cangzhi, *et al.* A cross modal hierarchical fusion multimodal sentiment analysis method based on multi-task learning[J]. *Information Processing & Management*, 2024, 61(3):103675.
- [25] Han Wei, Chen Hui, Poria S. Improving multimodal fusion with hierarchical mutual information maximization for multimodal sentiment analysis[C]//Proc of Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2021:9180-9192.
- [26] Zadeh A, Zellers R, Pincus E, *et al.* MOSI: multimodal corpus of sentiment intensity and subjectivity analysis in online opinion videos[EB/OL]. (2016-08-12). <https://arxiv.org/abs/1606.06259>.
- [27] Zadeh A B, Liang P P, Poria S, *et al.* Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C]//Proc of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018:2236-2246.
- [28] Yu Wenmeng, Xu Hua, Meng Fanyang, *et al.* CH-SIMS: a Chinese multimodal sentiment analysis dataset with fine-grained annotation of modality[C]//Proc of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2020:3718-3727.
- [29] Zadeh A, Chen Minghai, Poria S, *et al.* Tensor fusion network for multimodal sentiment analysis[C]//Proc of Conference on Empirical Methods in Natural Language Processing. Stroudsburg, PA: Association for Computational Linguistics, 2017:1103-1114.
- [30] Liu Zhun, Shen Ying, Lakshminarasimhan V B, *et al.* Efficient low-rank multimodal fusion with modality-specific factors[C]//Proc of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg, PA: Association for Computational Linguistics, 2018:2247-2256.
- [31] Koromilas P, Nicolau M A, Giannakopoulos T, *et al.* MMATR: a lightweight approach for multimodal sentiment analysis based on tensor methods[C]//Proc of IEEE International Conference on Acoustics, Speech and Signal Processing. Piscataway, NJ: IEEE Press, 2023:1-5.
- [32] Peng Junjie, Wu Ting, Zhang Wenqiang, *et al.* A fine-grained modal label-based multi-stage network for multimodal sentiment analysis[J]. *Expert Systems with Applications*, 2023, 221:119721.
- [33] Yu Wenmeng, Xu Hua, Yuan Ziqi, *et al.* Learning modality-specific representations with self-supervised multi-task learning for multimodal sentiment analysis[C]//Proc of AAAI Conference on Artificial Intelligence. Palo Alto, CA: AAAI Press, 2021:10790-10797.
- [34] 陈巧红, 孙佳锦, 漏杨波, 等. 基于多任务学习与层叠 Transformer 的多模态情感分析模型[J]. *浙江大学学报: 工学版*, 2023, 57(12):2421-2429. (Chen Qiaohong, Sun Jiajin, Lou Yangbo, *et al.* Multimodal sentiment analysis model based on multi-task learning and stacked cross-modal Transformer[J]. *Journal of Zhejiang University: Engineering Science*, 2023, 57(12):2421-2429.)
- [35] 王有康, 程春玲. 基于跨模态单向加权的多模态情感分析模型[J/OL]. *计算机科学*. (2024-09-13). <http://kns.cnki.net/kcms/detail/50.1075.TP.20240912.1917.043.html>. (Wang Youkang, Cheng Chunling. Multi-modal sentiment analysis model based on cross-modal unidirectional weighting[J/OL]. *Computer Science*. (2024-09-13). <http://kns.cnki.net/kcms/detail/50.1075.TP.20240912.1917.043.html>.)