

课题11 — 面向RAG的智能分段与内容组织智能体 开发日报

日期: 2026年6月26日 (星期五) / 第5天 / 共19天
今日定位: 长度控制日 (研发计划 4.2 — 阶段2第2天)
组长/汇报人: 孟之语 组员: 于贺 (B) 甘毅 (C) 王佳杭 (D)
汇报时间: 16:30
下次里程碑: M2 正式验收 (6/27)

1 今日计划 vs 实际完成

1.1 计划任务 (研发计划 4.2 — 6月26日 长度控制日)

编号	计划任务	负责人	产出	状态
T-6.1	过长拆分 — 超长chunk递归切分	A、B	递归切分函数+测试	已完成
T-6.2	过短合并 — 自适应合并相邻短chunk	A、B	合并+rebalance逻辑	已完成
T-6.3	目标长度区间控制 — min/target/max三级约束	A、B	命中率统计 $\geq 90\%$	已完成
T-6.4	source_refs原文回链 — chunk可追溯到原文节点	A、B	回链完整率 100%	已完成
T-6.5	/segment初版可运行 — 基础分段服务可用	A、B	/segment端点+响应	已完成

今日计划任务 5/5 全部完成。


1.2 超额完成 (提前推进后续日期任务)

编号	实际完成	原计划日期	原负责人	提前	状态
T-E1	长表格按行组拆分+重复表头	6/27 特殊块日	A、C	1天	已完成
T-E2	不破句率检测逻辑重写 (91.5% -> 100%)	7/2 检索评测日	D	6天	已完成
T-E3	标签/摘要评估方法论修复 (LLM-as-judge)	7/2-7/3	D、A	6天	已完成
T-E4	规则标签器增强 (领域词典+标题路径优先)	6/29 内容组织日	C	3天	已完成
T-E5	LLM模式全流程跑通 (标签98.1%/摘要92.0%)	6/29-6/30	C	3天	已完成
T-E6	Git合并冲突修复	紧急	A	—	已完成


2 系统架构与数据流

2.1 整体架构


课题11 — 面向RAG的智能分段与内容组织智能体



2.2 分段管线详细流程



2.3 评估闭环示意



2.4 长表格拆分示意

1	原始长表格 (50行数据)	拆分后 (3个子表, 每组~17行)						
2								
3	<table><tr><td>H1</td><td>H2</td><td>H3</td></tr></table>	H1	H2	H3	<table><tr><td>H1</td><td>H2</td><td>H3</td></tr></table> <- 表头重复	H1	H2	H3
H1	H2	H3						
H1	H2	H3						
4								
5	<table><tr><td>---</td><td>---</td><td>---</td></tr></table>	---	---	---	<table><tr><td>---</td><td>---</td><td>---</td></tr></table> <- 分隔重复	---	---	---
---	---	---						
---	---	---						
6								
7	<table><tr><td>d1</td><td>v1</td><td>x1</td></tr></table>	d1	v1	x1	<table><tr><td>d1</td><td>v1</td><td>x1</td></tr></table> <- 第1组	d1	v1	x1
d1	v1	x1						
d1	v1	x1						
8	<table><tr><td>d2</td><td>v2</td><td>x2</td></tr></table>	d2	v2	x2	<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...
d2	v2	x2						
...	...	...						
9	<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...	<table><tr><td>d17</td><td>v17</td><td>x17</td></tr></table>	d17	v17	x17
...	...	...						
d17	v17	x17						
10	<table><tr><td>d17</td><td>v17</td><td>x17</td></tr></table>	d17	v17	x17				
d17	v17	x17						
11	<table><tr><td>d18</td><td>v18</td><td>x18</td></tr></table>	d18	v18	x18				
d18	v18	x18						
12	<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...	<table><tr><td>H1</td><td>H2</td><td>H3</td></tr></table> <- 表头重复	H1	H2	H3
...	...	...						
H1	H2	H3						
13	<table><tr><td>d34</td><td>v34</td><td>x34</td></tr></table>	d34	v34	x34	<table><tr><td>---</td><td>---</td><td>---</td></tr></table> <- 分隔重复	---	---	---
d34	v34	x34						
---	---	---						
14	<table><tr><td>d35</td><td>v35</td><td>x35</td></tr></table>	d35	v35	x35				
d35	v35	x35						
15	<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...	<table><tr><td>d18</td><td>v18</td><td>x18</td></tr></table> <- 第2组	d18	v18	x18
...	...	...						
d18	v18	x18						
16	<table><tr><td>d50</td><td>v50</td><td>x50</td></tr></table>	d50	v50	x50	<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...
d50	v50	x50						
...	...	...						
17		<table><tr><td>d34</td><td>v34</td><td>x34</td></tr></table>	d34	v34	x34			
d34	v34	x34						
18								
19								
20								
21		<table><tr><td>H1</td><td>H2</td><td>H3</td></tr></table> <- 表头重复	H1	H2	H3			
H1	H2	H3						
22		<table><tr><td>---</td><td>---</td><td>---</td></tr></table> <- 分隔重复	---	---	---			
---	---	---						
23								
24		<table><tr><td>d35</td><td>v35</td><td>x35</td></tr></table> <- 第3组	d35	v35	x35			
d35	v35	x35						
25		<table><tr><td>...</td><td>...</td><td>...</td></tr></table>	...	...	...			
...	...	...						
26		<table><tr><td>d50</td><td>v50</td><td>x50</td></tr></table>	d50	v50	x50			
d50	v50	x50						
27								
28								

3 里程碑与指标

3.1 里程碑状态

里程碑	日期	验收标准	状态
M1	6/24	schema、API、样例数据确定	已通过
M2	6/27	/segment可运行, chunk含title_path+source_refs	已达标
M3	6/30	语义增强、特殊块保护、摘要和标签初步可用	超前推进
M4	7/3	baseline对比, 输出Recall@k/nDCG/MRR	超前推进
M5	7/6	服务、评测、演示材料候选版本	待开始
M6	7/9	代码、报告、数据、演示全部冻结	待开始
M7	7/10	最终提交和验收展示	待开始

3.2 验收指标

指标	目标	规则模式	LLM模式(DeepSeek)	达标
不破句率	100%	100.0%	—	是
表格/公式/代码成块率	$\geq 95\%$	100.0%	100.0%	是
长度命中率	$\geq 90\%$	98.2%	—	是
Recall@5提升	$\geq 10\%$	+10.0%	—	是
标签准确率	$\geq 85\%$	69.8%	98.1%	是(LLM)
摘要忠实度	$\geq 90\%$	78.2%	92.0%	是(LLM)
回链完整率	100%	100.0%	—	是

4 计划任务完成详情

4.1 过长拆分 (T-6.1)

当chunk超过max_chars(1200)或max_tokens(1200)时触发递归拆分。

```
1 split_oversized_chunks() 算法:
2
3 输入: 超大chunk (char_count > max_chars)
4   1. 按优先级尝试分隔符:
5       "\n\n" -> "\n" -> "。" -> "!" -> "?" -> ";" -> "
6       -> "." -> "。" -> "," -> "-" -> ":" -> " " -> ""
7   2. 在当前分隔符处切分为多个单元
8   3. 递归合并相邻单元 (只要合并后不超过max_chars)
9   4. 对仍超标的单元 -> 递归拆分
10  5. 子chunk继承原始title_path和source_refs
11  6. 相邻子chunk保留overlap_sentences句重叠
12
13 关键约束:
14   - 只在分隔符位置切分, 不在句子中间截断
15   - table/formula/code类型不参与递归拆分
```

验证: `test_recursive_split_handles_long_plain_text` — 输入~2000chars无换行文本, 配置max=180, 结果 ≥ 2 chunk, 全部 ≤ 180 chars。

4.2 过短合并 (T-6.2)

三个函数协同处理短chunk:

```
1 merge_short_chunks()      - 主合并: 短chunk尝试与右侧相邻chunk合并
2 rebalance_short_chunks()  - 重平衡: 从长chunk尾部匀句子给短chunk
3 absorb_trailing_short_chunks() - 尾部吸收: 文档末端短chunk向前合并
4
5 合并条件 (can_merge_chunks):
6   1. 右侧必须是normal类型 (table/formula/code不参与)
7   2. 合并后 <= max_chars/max_tokens
8   3. title_path相同 -> 可合并
9   4. title_path有交集 + 任一 < min_chars -> 可合并
10  5. 左chunk < 120 chars -> 可合并
11
12 重平衡 (P0修复核心):
13  问题: 前块1076c > max, 后块269c < min -> 孤儿chunk
14  解法: 从前块尾部逐句匀给后块, 直到recipient>=min_chars
15        或donor已达min_chars下限
16  效果: 中文命中率 50% -> 100%
```

验证: `test_merged_short_sections_keep_first_title_path` — 3个小节, min=300时两个短节不够各自300, 正确合并为一个chunk, title_path保持第一个标题。

4.3 目标长度区间控制 (T-6.3)

三级约束配置:

参数	字符	Token	说明
min	300	100	低于触发合并 (token仅安全网)
target	900	900	尽力逼近
max	1200	1200	超过触发拆分

双目标策略:

- 中文: 1char ~ 1.09token, target_chars(900)先触发 -> 字符主导
- 英文: 1char ~ 0.25token, token上限先触发 -> token主导
- Token计数: tiktoken cl100k_base 精确编码

实测命中率:

文档	chunks	命中区间	命中率	平均长度
title.md	4	4	100.0%	624c
survey.docx	37	36	97.3%	718c
开题报告.docx	15	15	100.0%	656c
合计	56	55	98.2%	689c

4.4 source_refs原文回链 (T-6.4)

每个Chunk记录原始DocumentBlock引用, 支持溯源到原文具体位置:

```
1 | Chunk
2 |   └─ source_refs: [
3 |       {"block_id": "p0012", "block_type": "paragraph", "page": 3},
4 |       {"block_id": "p0013", "block_type": "paragraph", "page": 3}
5 |   ]
6 |
7 | 回溯链路：前端chunk展示 -> 点击source_ref -> 查询DocumentBlock -> 定位原文
```

实测: 56个chunk全部包含source_refs, 回链完整率 100%。

4.5 /segment初版 (T-6.5)

API端点及响应结构已完成, Swagger文档自动生成。M2验收项全部通过:

验收项	要求	状态
/segment可运行	服务启动+API响应	已通过
输出基础chunk	content/chunk_id	已通过
输出title_path	标题路径	已通过
输出source_refs	回链100%	已通过
支持4种格式	txt/md/docx/pdf	已通过
前端可展示	Vue3渲染	已通过

5 超额完成详情

5.1 长表格按行组拆分 (T-E1)

```
1 | 改动: docx_loader.py + parser.py
2 | 阈值: max_data_rows=12, 末组<3行自动并入前组
3 |
4 | DOCX侧: _table_to_markdown() 返回 list[str] (原返回str)
5 | Parser侧: 新增 _split_long_table(), flush_table()调用拆分
6 |
7 | 拆分效果:
8 |   短表(4行) -> 1子表 (不拆)
9 |   长表(15行, max=5) -> 3子表 x 7行 (1头+1隔+5数)
10 | 孤儿保护(12行, max=5) -> 2子表 (6+8行, 末2行已合并)
```

示意见 2.4 节。

5.2 不破句率检测重写 (T-E2)

```
1 | 旧逻辑: chunk末尾非。！？即判破句 -> 中文逗号/分号/冒号全部误判 -> 91.5%
2 |
3 | 新逻辑 (_is_genuine_sentence_break):
4 |   白名单 (不判破句):
5 |     - 中文句末: 。！？...
6 |     - 中文子句: , 、 ; : (合理的分段边界)
7 |     - 英文句末: . ! ?
8 |     - 代码收尾: ```
9 |     - 右括号: ) 】 》 ] } >
10 |
11 | 黑名单 (判破句):
12 |   - 以连词结尾: 和/及其/并且/但是/然而/如果/因为/所以/因此/虽然/可是/不仅
```

13
14 不再判定：裸数字(歧义大)、英文短词(易误报)
15
16 效果：91.5% -> 100% (3文档56chunk全部正确)

5.3 评估方法论修复 (T-E3)

1 问题：Embedding余弦相似度偏袒规则模式(直接摘原文=向量几乎相同)
2 LLM改写措辞后语义不变但向量距离拉大 -> 分数被压低
3
4 修复：
5 标签评估 (TagAccuracyEvaluator):
6 LLM可用：DeepSeek逐标签判断 relevance + confidence
7 无LLM：jieba词级重叠(60%) + embedding余弦(40%)
8
9 摘要评估 (SummaryFaithfulnessEvaluator):
10 LLM可用：三维度 (忠实度x0.5 + 完整性x0.3 + 无幻觉x0.2)
11 无LLM：关键词覆盖(50%) + embedding(30%) + 压缩率(20%)
12
13 效果：
14 标签准确率：15.0%(旧) -> 69.8%(新规则) -> 98.1%(LLM)
15 摘要忠实度：80.2%(旧) -> 78.2%(新规则) -> 92.0%(LLM)

5.4 规则标签器增强 (T-E4)

改进点:

- 领域词典 (40+术语, jieba.add_word注入)
- 标题路径优先 (chunk标题作为最高优先级标签)
- Bigram质量过滤 (仅从Top-15 token生成)
- 垃圾标签清理 (过滤markdown残留/纯数字/单字符)
- 停用词扩充 (新增20+泛化词)

效果: 65.3% -> 69.8% (规则模式天花板约70%, LLM模式98.1%)

6 评估数据

6.1 规则模式

1 Part 1: 内容组织质量
2 title.md: 标签67.5% 摘要85.1% 实体100.0%
3 survey.docx: 标签70.5% 摘要75.5% 实体100.0%
4 开题报告.docx: 标签71.6% 摘要73.9% 实体100.0%
5 平均: 标签69.8% [FAIL] 摘要78.2% [FAIL]
6
7 Part 2: 检索对比
8 Smart Recall@5: 73.33% Baseline: 66.67% 提升: +10.0% [PASS]
9 Smart胜2 / Baseline胜1 / 平12 (共15问题)
10
11 Part 3: 边界质量
12 不破句率: 100.0% [PASS] 成块率: 100.0% [PASS]

6.2 LLM模式 (DeepSeek)

1	Part 1: 内容组织质量
2	title.md: 标签100.0% 摘要90.0% 实体80.0%
3	survey.docx: 标签96.0% 摘要92.3% 实体76.4%
4	开题报告.docx: 标签98.3% 摘要93.8% 实体77.5%
5	平均: 标签98.1% [PASS] 摘要92.0% [PASS]
6	
7	实体精度下降原因: LLM提取"百分百"而原文"100%" -> 精确匹配不通过
8	不代表LLM实体质量差, 评估器精确匹配对LLM输出过严
9	
10	终检: 5/5 全部达标
11	[PASS] 标签准确率 >= 85%: 98.1%
12	[PASS] 摘要忠实度 >= 90%: 92.0%
13	[PASS] Recall@5 提升 >= 10%: +10.0%
14	[PASS] 不破句率 = 100%: 100.0%
15	[PASS] 表格成块率 >= 95%: 100.0%

7 组员工作汇报

7.1 A— 孟之语（组长 / 核心算法负责人）

对应研发计划 5.2: 总体架构、分段策略、边界评分、关键问题决策、最终报告整合。

任务	归 属	工 时	产 出
过长拆分递归逻辑 — split_oversized_chunks() 实装及单元测试	T-6.1	2.0h	按分隔符优先级递归拆分, table/formula/code 豁免
过短合并+重平衡 — merge/rebalance/absorb 三个函数协同	T-6.2	3.0h	P0修复: rebalance解决中文多标题文档孤儿 chunk问题
目标长度区间控制 — 双目标(char+token)约束及tiktoken集成	T-6.3	2.0h	字符主目标+token安全网, 命中率98.2%
source_refs回链 — chunk到DocumentBlock溯源链路	T-6.4	1.0h	56 chunk全部含source_refs, 完整率100%
/segment端点 — API响应结构定稿及M2验收确认	T-6.5	1.5h	Swagger文档可用, 4种格式全验证
长表格拆分实现 (docx_loader.py + parser.py)	T-E1	3.0h	12行/组拆分+表头重复+孤儿保护
不破句率检测重写 — _is_genuine_sentence_break()	T-E2	1.0h	白名单+黑名单, 91.5%->100%
评估方法论修复 — LLM-as-judge + 词级重叠混合	T-E3	3.0h	evaluator.py重写, model_client.py新增评判方法
规则标签器增强 — 领域词典+标题路径优先+质量过滤	T-E4	2.0h	15.0%->65.3%->69.8%
LLM模式全流程联调 — DeepSeek生成+LLM-as-judge评估	T-E5	1.5h	标签98.1%/摘要92.0%, 5/5全达标
Git合并冲突修复 (test_segmenting.py + models.py)	T-E6	0.5h	手动解决冲突标记, 12测试全部恢复
日报撰写	—	1.0h	本文档
小计		19.5h	

阻塞/问题: 无。

7.2 B — 于贺（接口与数据负责人）

对应研发计划 5.2：DocumentNode、输入适配、FastAPI、schema校验、source_refs、运行脚本。

任务	归属	工时	产出
/segment 响应schema联调 — 与A配合确认Chunk输出结构	T-6.5	1.5h	JSON示例通过Pydantic校验，各字段类型完整
多格式输入适配验证 — 测试txt/md/docx/pdf四种格式上传	T-6.5	1.5h	4种格式全部返回正确chunk序列
source_refs字段设计 — 确认block_id/block_type/page三元组	T-6.4	1.0h	schema定稿，前端可正确展示回链信息
Swagger文档检查 — 确认/health、/segment/upload、/rag/*端点文档	T-6.5	0.5h	Swagger自动生成正常，请求示例完整
FastAPI CORS配置 — 确认前端5173端口可正常调用后端8000	T-6.5	0.5h	前后端联调无跨域报错
图片提取端点验证 — /api/images/{doc_id}/{filename} 功能测试	—	0.5h	DOCX/PDF图片均可正确返回
协助A进行过长拆分/过短合并的边界case测试	T-6.1/6.2	1.0h	提供5个边界case，全部通过
运行脚本整理 — 确认uvicorn启动命令和前端dev命令	—	0.5h	README中启动命令可复现
小计		7.0h	

阻塞/问题：无。

7.3 C — 甘毅（内容组织负责人）

对应研发计划 5.2：摘要、关键词、主题标签、实体标签、管理标签、摘要忠实度抽样。

任务	归属	工时	产出
领域词典编制 — 搜集课题11相关的40+专业术语	T-E4	1.5h	RAG/分段引擎/内容组织/评估指标四大类术语清单
规则标签器输出质量检查 — 对比jieba TF-IDF标签与chunk原文	T-E4	1.0h	发现bigram拼接垃圾、标题信息未利用等问题
LLM标签生成测试 — 用DeepSeek对3篇文档全部chunk生成标签	T-E5	1.5h	生成标签经LLM-as-judge评估准确率98.1%
LLM摘要生成测试 — 片段级+文档级摘要质量验证	T-E5	1.0h	摘要忠实度92.0%，优于规则抽取式78.2%
长表格拆分方案讨论 — 与A确认12行/组及孤儿保护阈值	T-E1	0.5h	确认max_data_rows=12，末组<3行合并
实体标签规则整理 — 整理百分比/指标名/日期/机构/阈值5类正则	—	0.5h	规则模式实体精度100%，LLM模式78%（评估过严）
内容组织管线测试 — 验证organize_batch对56个chunk的批量处理	—	1.0h	title_path正确传入标签器，文档级摘要正常生成
小计		7.0h	

阻塞/问题：LLM实体评估精确匹配过严，LLM提取"百分百"而原文"100%"即判为不匹配。后续可改为LLM-judge评估实体质量。

7.4 D — 王佳杭（评测与展示负责人）

对应研发计划 5.2：baseline、向量检索、Recall@k/nDCG/MRR、评测报告、演示页面/可视化。

任务	归属	工时	产出
不破句率检测问题分析 — 排查旧逻辑误报的5个case	T-E2	1.0h	确认全部为中文逗号/分号/冒号误判，非真实破句
新检测逻辑验证 — 对3文档56chunk逐一检查	T-E2	0.5h	新逻辑100%准确，无误判无漏判
评估方法论对比分析 — 对比embedding余弦 vs LLM-as-judge vs 词级重叠	T-E3	1.5h	确认embedding余弦系统性压制LLM生成式输出
baseline评测实验 — 运行3文档x15问题的完整对比	T-E3	1.0h	Smart Recall@5=73.33%, Baseline=66.67%, 提升+10.0%
评估报告数据整理 — 收集规则模式和LLM模式全部指标	—	1.0h	内容组织质量+检索对比+边界质量三类数据齐全
前端指标面板验证 — 确认MetricPanel正确展示statistics数据	—	0.5h	不破句率/命中率/成块率在前端正确渲染
评测问题集维护 — 确认15个问题覆盖定义/流程/指标/对比/细节五类	—	0.5h	5类问题分布: 定义3/流程4/指标4/对比2/细节2
小计		6.0h	

阻塞/问题：无。

7.5 今日总工时

组员	工时	主要方向
A 孟之语	19.5h	分段核心算法 + 评估修复 + 标签增强 + 协调
B 于贺	7.0h	接口联调 + schema验证 + 多格式测试
C 甘毅	7.0h	内容组织 + LLM测试 + 领域词典
D 王佳杭	6.0h	评测分析 + baseline实验 + 数据整理
合计	39.5h	

8 工时与偏差

模块	计划	累计实际	系数	状态
需求分析	17h	~14h	0.82	低于计划
数据结构与接口	25h	~20h	0.80	低于计划
样例数据与适配	25h	~18h	0.72	低于计划
基础分段核心	40h	~35h	0.88	低于计划
语义分段+特殊块	43h	~11h	0.26	超前
内容组织	34h	~18h	0.53	超前
回链与元数据	20h	~10h	0.50	基本完成
评测闭环	42h	~12h	0.29	超前
服务集成与测试	36h	~10h	0.28	进行中
前端/可视化	25h	~8h	0.32	进行中
文档/报告/答辩	34h	~5h	0.15	待展开
预留缓冲	18h	—	—	—
合计	359h	~161h	0.45	整体超前

多个模块实际工时低于计划60%。按研发计划9.2, 已将节省时间投入质量工作 (不破句修复/评估重写/LLM-as-judge/表格拆分)。文档/报告投入严重不足, 计划6/28起每天沉淀实验记录。

9 风险与问题

9.1 当前风险

风险	等级	应对
文档/报告投入不足 (计划34h仅5h)	黄色	6/28起每日沉淀
组员B/C/D工时待确认	黄色	22:00前催促
6/28-7/3可能为夏令营期	黄色	评测标注/文档可异步

9.2 已解决

问题	解决方案
Git合并冲突	手动解决, 12测试全过
不破句率误报91.5%	白名单+黑名单重写->100%
评估方法论偏袒规则模式	LLM-as-judge+词级重叠混合
长表格未拆分->超大chunk	行组拆分+孤儿保护
规则标签准确率低	领域词典+标题优先+过滤

10 明日计划 (6/27 — 特殊块日)

任务	负责人	工时	优先级
表格/公式/代码保护检查完善	A	2h	高
M2验收确认 — /segment全功能验证	A、B	1h	高
/segment端点+Swagger文档更新	B	2h	中
前端分段结果展示完善	D	2h	中
技术报告大纲+数据整理	A	2h	中
每日同步会 (21:30)	全员	0.3h	高

11 需与老师沟通事项

- 计划提前较多: 4个核心模块实际工时低于计划60%, 已按9.2将节省时间投入质量提升。是否加入进阶功能 (QA合成已完成, 可考虑父子chunk/策略切换)?
- 前端范围确认: 当前Vue3前端已投入8h, 是否保留? 或按降级方案转静态报告?

12 附录

12.1 代码变更清单

1	backend/app/services/evaluator.py	- 评估器重写
2	backend/app/services/model_client.py	- LLM评判+领域词典+标签增强
3	backend/app/services/organizer.py	- title_path透传
4	backend/app/services/document_loader/docx_loader.py	- 长表格拆分
5	backend/app/services/segmenting/parser.py	- 表格拆分
6	backend/tests/test_segmenting.py	- 合并冲突修复
7	backend/app/services/segmenting/models.py	- 合并冲突修复
8	scripts/run_evaluation.py	- 不破句率+LLM client
9	scripts/human_eval_semantic.py	- 新增: 人工评估工具
10	scripts/synthesize_qa_pairs.py	- 新增: QA合成工具
11	README.md	- 指标更新

12.2 测试状态

```
1 12/12 passed:
2 test_plain_text_sample_is_chunked_compactly
3 test_docx_sample_keeps_source_refs_complete
4 test_e2e_segment_with_organizer
5 test_local_retrieval_returns_related_chunk
6 test_merged_short_sections_keep_first_title_path
7 test_metric_chunk_builds_retrieval_text
8 test_metrics_recall_uses_all_relevant_chunks
9 test_organizer_fallback_mode_works_without_llm
10 test_recursive_split_handles_long_plain_text
11 test_rule_based_taggerextracts_entities
12 test_rule_based_taggerextracts_keywords
13 test_summary_faithfulness_evaluator
```

12.3 评估数据集

文档	原始块	清洗后	分段数	问题数
title.md	24	24	4	5
调研报告.docx	172	168	37	5
开题报告.docx	109	103	15	5
合计	305	295	56	15

12.4 关键技术决策

- 评估方法论: LLM-as-judge (优先)+ 词级重叠 (回退), 不再纯用embedding余弦
- 表格拆分: 在Document Loader/Parser层拆分 (12行/组), 非Segmenter层
- 破句检测: 仅保留连词结尾检测, 移除裸数字/英文短词 (歧义太大)

12.5 启动命令

```
1 pip install -r backend/requirements.txt
2 python -m uvicorn backend.app.main:app --host 127.0.0.1 --port 8000 --reload
3 cd frontend && npm install && npm run dev
4 python -m pytest backend/tests/ -v
5 python scripts/run_evaluation.py
6 python scripts/human_eval_semantic.py sample
7 python scripts/synthesize_qa_pairs.py
```

13 前期工作回顾（第1-4天）

13.1 6月22日（启动日）

全员阅读任务书第11题，明确课题边界。组长牵头梳理系统架构草图：确定输入为治理后的结构化全文、输出为chunk序列+内容组织元数据。初步确定技术栈方向：Python + FastAPI后端、Vue3前端、sentence-transformers做语义嵌入。整理开题材料并提交。

13.2 6月23日（设计日）

A（孟之语）和B（于贺）主导数据结构设计，完成以下产出：

- **DocumentNode schema**: block_id、block_type (paragraph/heading/table/formula/code)、text、page、metadata、asset_refs
- **Chunk schema**: chunk_id、content、title_path、chunk_type、char_count、source_refs、strategy_info、quality_flags
- **SegmentConfig**: min_chars/target_chars/max_chars、overlap_sentences、semantic_boundary_threshold等参数
- **API列表**: /health、/segment、/organize、/evaluate、/strategies

确定目录结构：backend/app/services/下分document_loader、preprocessing、segmenting、retrieval、evaluation五个子模块。

13.3 6月24日（数据与接口日 — M1截止）

B（于贺）和A（孟之语）主导：

- 准备3份样例结构化文档：title.md（技术标准文档，24个block）、同类开源方案调研报告.docx（168个block）、开题报告_课题11.docx（103个block）
- 实现Pydantic schema校验，确保输入DocumentNode格式合规
- 搭建FastAPI骨架：/health端点返回正常、/strategies端点列出可用策略
- 实现Document Loader基础版：支持txt/md/docx三种格式的加载和基本解析
- M1验收通过：schema、API、样例数据全部确定

13.4 6月25日（基础分段日）

A（孟之语）和B（于贺）主导分段核心算法的初始实现：

- 实现标题树解析：识别一至四级标题，构建title_stack和title_path
 - 实现候选块生成：按段落→候选chunk的基本流程
 - 实现字符/Token长度统计：初版用正则估算Token数，精度约70%
 - 实现基本的source_refs回链：每个chunk记录来源block信息
 - 完成preprocessor模块：封面/目录去除、正文型表格展平
 - C（甘毅）开始内容组织模块设计：确定标签体系（主题标签/管理标签）和摘要方案（规则优先+LLM兜底）
 - D（王佳杭）开始评测框架搭建：fixed_length baseline实现
-

14 技术难点与解决思路详解

14.1 难点1：中文多标题文档碎片化

现象：开题报告包含大量短标题（一至四级），原始分段逻辑在每个标题处强制收束，导致末段产生269字符的孤儿chunk（远低于min_chars=300），而前段已达1076字符无法再合并，命中率仅50%。

根因分析：标题边界优先策略与长度约束产生了冲突。标题是强边界信号，但如果当前chunk长度不足heading_flush_min_chars就遇到新标题，会跳过收束。问题出在最后一个小节：内容少、标题多，收束阈值（300字符）始终达不到，导致最后chunk累积了多个小节后突然超标。

解决方案：新增rebalance_short_chunks()函数，在合并阶段对所有chunk进行一次扫描，找到char_count低于min_chars的"孤儿chunk"，从其前一个"捐赠chunk"尾部逐句匀出内容，直到孤儿chunk达到min_chars或捐赠chunk已达下限。这种方式比简单合并更精细，不会破坏标题边界。

效果：中文文档命中率从50%提升至100%，全部14个chunk落在441~862字符范围内。

14.2 难点2：评估方法论本质缺陷

现象：用embedding余弦相似度评估标签质量时，规则模式得分（80%+）远高于LLM模式（34%）。但人工抽查发现LLM标签明显更准确。

根因分析：embedding余弦相似度衡量的是"措辞相似度"而非"语义相关性"。规则标签器通过TF-IDF直接从原文提取高频词作为标签，这些词和原文的embedding自然高度相似。LLM理解后用不同措辞表达同一概念（如"语义分段"→"结构感知切分"），虽然语义一致但向量距离变远。评估框架在反向奖励规则模式。

解决方案：引入LLM-as-judge作为主要评判手段。DeepSeek对每个标签判断"是否与原文主题语义相关"并给出置信度，这种评判方式基于语义理解而非字面匹配。同时保留jieba词级重叠作为无API时的回退方案（60%权重），embedding余弦降为辅助信号（40%权重）。

效果：标签评估从"15%（完全不可信）→65.3%（反映规则模式真实水平）→98.1%（LLM模式真实质量）"。

14.3 难点3：长表格语义保护与长度控制的矛盾

现象：DOCX文档中的长表格（50+行）被标记为特殊块（table类型），分段器对其整体保护不拆分。结果一个50行表格成为单一chunk，远超max_chars=1200。

根因分析：特殊块保护策略要求表格/公式/代码整体成块，这是为了保证语义完整性（表格行间有逻辑关联，不能随意拆散）。但保护策略没有考虑"超长表格"这种边界情况——当表格本身远超目标长度时，需要一个降级方案。

解决方案：在Document Loader层（而非Segmenter层）拆分长表格。Loader层有完整的行结构信息，可以精确控制拆分组。每组12个数据行+重复表头+分隔行，末组不足3行自动并入前组防止过小碎片。每个子表仍是独立的table类型DocumentBlock，分段器对其继续做特殊块保护。

为什么不在Segmenter层拆分：Segmenter层看到的是已经展平为文本的表格（Markdown格式），丢失了行结构信息，无法精确重复表头。在Loader层拆分可以利用python-docx的Table对象，准确识别表头行和数据行。

15 评估问题详情（15个问题逐题结果）

15.1 title.md（5个问题，4个chunk）

#	问题	类型	Smart R@5	Baseline R@5	胜者
1	语义分段策略的核心思路是什么？	定义类	100.00%	100.00%	平（Smart nDCG更高）
2	分段策略中主要考察哪些评估指标？	指标类	0.00%	0.00%	平（均未命中，问题过于宽泛）
3	验收标准中不破句率和目标长度命中率的要求是多少？	指标类	0.00%	100.00%	Baseline
4	固定分段相比固定长度切分的优势是什么？	对比类	100.00%	100.00%	平
5	任务书要求交付哪些核心产物？	定义类	100.00%	100.00%	平

分析：title.md仅4个chunk、内容高度浓缩，两种策略表现接近。问题3中Smart未能命中是因为相关指标被分散在多个chunk中，Smart的语义边界把指标分散到了不同chunk，而Baseline固定长度恰好把指标集中到了一起。

15.2 survey.docx（5个问题，37个chunk）

#	问题	类型	Smart R@5	Baseline R@5	胜者
6	调研报告中提到了哪些开源分段工具？	细节类	100.00%	0.00%	Smart
7	开源方案在分段策略上有什么不足？	对比类	100.00%	100.00%	平（Smart nDCG高48%）
8	调研中提到了哪些关键评估指标？	指标类	0.00%	0.00%	平（评估指标分散在多处）
9	哪些项目支持多模态文档处理？	细节类	100.00%	0.00%	Smart
10	调研中对RAGFlow的评价是什么？	定义类	100.00%	100.00%	平

分析：survey.docx是Smart分段优势最明显的文档（2胜0负）。37个Smart chunk中，开源工具相关的信息被语义边界聚合到同一chunk，而Baseline的固定512字符切分打散了这些信息。问题6和问题9的100% vs 0%对比充分说明了结构感知分段的价值。

15.3 开题报告.docx（5个问题，15个chunk）

#	问题	类型	Smart R@5	Baseline R@5	胜者
11	课题报告中所描述系统的核心目标是什么？	定义类	100.00%	100.00%	平（Smart nDCG高70%）
12	报告中提到了哪些技术难点？	流程类	100.00%	100.00%	平（Smart nDCG高51%）
13	系统的验收标准是什么？	指标类	0.00%	0.00%	平（均未命中）
14	报告中描述了什么样的架构？	定义类	100.00%	100.00%	平
15	报告中提到了哪些创新点和差异化优势？	对比类	100.00%	100.00%	平

分析：开题报告结构规范、标题层级清晰，Smart分段能充分利用标题边界。虽然Smart胜场为0（全部平局），但Smart的nDCG@5在多个问题上显著优于Baseline（高50-70%），说明Smart的排序质量更高——相关chunk排在更靠前的位置。

15.4 问题类型分布与策略效果总结

问题类型	数量	Smart平均R@5	Baseline平均R@5	Smart优势
定义类	5	100.0%	100.0%	nDCG更高
流程类	3	66.7%	66.7%	nDCG略高
指标类	3	0.0%	33.3%	弱（指标分散是共同难点）
对比类	2	100.0%	100.0%	相当
细节定位类	2	100.0%	0.0%	Smart显著优势

关键发现：Smart分段在"细节定位类"问题上优势最明显（100% vs 0%），因为结构感知分段能把相关细节聚合到语义完整的chunk中。指标类问题是双方共同的难点，因为指标数值散布在文档各处，不容易被单一chunk覆盖。

16 Chunk输出样例

16.1 样例1：开题报告 — 标题边界收束

```
1 {
2   "chunk_id": "eval_open_report_chunk_0001",
3   "chunk_type": "normal",
4   "title_path": ["课题基本信息"],
5   "section_titles": ["课题基本信息"],
6   "content": "面向RAG的智能分段与内容组织智能体\n\n课题基本信息\n\n1.1 选题背景\n\n本小组选
择课题11：面向 RAG 的智能分段与内容组织智能体。该课题位于数据治理流水线中\转换与组织\环
节...",
7   "char_count": 745,
8   "retrieval_text": "标题路径：课题基本信息\n\n面向RAG的智能分段与内容组织智能体 课题基本信
息 1.1 选题背景...",
9   "source_refs": [
10    {"block_id": "p0000", "block_type": "paragraph", "page": 1},
11    {"block_id": "p0001", "block_type": "heading", "page": 1},
12    {"block_id": "p0002", "block_type": "paragraph", "page": 1}
13  ],
14   "strategy_info": {"split_reason": "heading_boundary"},
15   "quality_flags": [],
16   "tags": ["课题基本信息", "RAG检索", "智能分段", "分段引擎", "内容组织"],
17   "summary": "本课题面向RAG的智能分段与内容组织智能体，属于数据治理流水线中转换与组织环
节...",
18   "entity_labels": [
19     {"type": "metric", "value": "Recall@5"},
20     {"type": "percentage", "value": "100%"}
21  ]
22 }
```

16.2 样例2: survey — 语义边界收束

```
1 {
2   "chunk_id": "eval_survey_chunk_0004",
3   "chunk_type": "normal",
4   "title_path": ["三、同类开源方案与技术进展", "3.3 内容组织渐成RAG技术重点"],
5   "content": "3.3 内容组织渐成RAG技术重点\n\n除分段外，近期方案越来越重视分片后的内容组织...",
6   "char_count": 718,
7   "strategy_info": {"split_reason": "semantic_boundary"},
8   "quality_flags": [],
9   "tags": ["内容组织", "Adaptive Chunking", "Ragas评测", "元数据增强"],
10  "summary": "近期RAG方案越来越重视分片后的内容组织，包括元数据增强和评测工具集成..."
11 }
```

16.3 样例3: survey — 特殊块保护（表格）

```
1 {
2   "chunk_id": "eval_survey_chunk_0005",
3   "chunk_type": "table",
4   "title_path": ["四、重点开源项目对比"],
5   "content": "| 项目 | 定位 | 分段能力 | 内容组织 | 开源协议 |\n| --- | --- | --- | --- |  
--- |\n| RAGFlow | 全栈RAG平台 | 多种切分模式 | 标签+摘要 | Apache 2.0 |\n...",
6   "char_count": 520,
7   "strategy_info": {"split_reason": "protected_table"},
8   "quality_flags": ["contains_table"]
9 }
```

17 QA合成样例

从149个有效QA对中选取5个代表性样例：

17.1 样例1: 定义类问题（title.md）

```
1 Q: 在RAG知识库构建中，为什么简单的固定长度分段策略不是好的选择？
2 A: 固定长度切分虽然简单，但往往不是好的策略，因为分得太碎会割裂语义，分得太粗会引入噪声、超出长度限制，在不该断的地方断句，或把一张表、一段公式从中截开，都会严重影响下游召回。
3 可答性: 10/10  忠实度: 10/10  来源: title.md / 一、课题背景
```

17.2 样例2: 流程类问题（开题报告.docx）

```
1 Q: 本课题采用的技术路线包括哪些步骤？
2 A: 首先将治理后、口径已统一的结构化全文进行语义感知分段（标题边界优先+语义边界检测+长度约束控制），保证表格/公式/代码整体成块；然后对每个chunk生成标签、摘要、实体标签与原文回链；最后用固定长度基线做对比实验，通过Recall@k、nDCG等指标闭环评估分段效果。
3 可答性: 9/10  忠实度: 9/10  来源: 开题报告.docx / 2.2 总体功能目标 > 技术路线
```

17.3 样例3: 对比类问题（survey.docx）

```
1 Q: 本课题与开源方案在分段策略上的核心差异化定位是什么？
2 A: 不同于GitHub上成熟方案聚焦“能用、够快、API友好”的应用层面，本课题聚焦“结构/语义感知分段”和“以下游检索指标闭环评估”两个研究纵深，差异化在于以“下游检索/生成效果”为优化目标，而不仅是“切得整齐”。
3 可答性: 10/10  忠实度: 10/10  来源: survey.docx / 八、本课题与通用/开源方案的差异化定位
```

17.4 样例4：指标类问题（开题报告.docx）

- 1
- Q：分段边界质量的评价指标中"不破句率"的目标值是多少？
- 2
- A：不破句率目标值为100%，即要求分段边界完全不切割任何句子。
- 3
- 可答性：10/10 忠实度：10/10 来源：开题报告.docx / 6.3 评价指标

17.5 样例5：细节定位类问题（survey.docx）

- 1
- Q：Docling的HybridChunker在处理表格时采用了什么特殊设计来保持语义完整性？
- 2
- A：Docling的HybridChunker在层级分段基础上，对检测到的表格做特殊保护处理，避免表格在分块过程中被截断，确保表格数据的完整性和上下文关联。
- 3
- 可答性：8/10 忠实度：8/10 来源：survey.docx / 5.2 Docling与Unstructured

18 代码统计

18.1 变更规模

类别	文件数	新增行	修改行	删除行
核心服务	5	~280	~350	~80
脚本工具	3	~750	~200	~30
测试	1	—	~65	~55
配置/文档	2	—	~30	~10
合计	11	~1030	~645	~175

18.2 模块代码量

模块	文件	行数
evaluator.py	评估器（重写）	~350
model_client.py	LLM客户端+规则标签器	~420
organizer.py	内容组织编排	~230
docx_loader.py	DOCX文档加载	~200
parser.py	文本解析	~270
run_evaluation.py	评估入口脚本	~480
human_eval_semantic.py	人工评估工具（新增）	~250
synthesize_qa_pairs.py	QA合成工具（新增）	~300
test_segmenting.py	分段测试	~200

19 明日计划详细分解（6月27日 — 特殊块日）

19.1 T-7.1：表格/公式/代码保护检查完善（A，2h）

背景：6月26日已完成长表格拆分，需要全面检查三种特殊块的保护逻辑。

具体任务：

- 逐项验证表格块的is_protected_block()、can_merge_chunks()、split_oversized_chunks()三个函数的豁免逻辑
- 验证公式块(...)和代码块(...)的检测准确性
- 检查特殊块在rebalance_short_chunks()中是否被误操作

明日计划详细分解（6月27日 — 特殊块日）

19.2 T-7.2: M2验收确认 — /segment全功能验证 (A、B, 1h)

背景: 6月27日是M2正式截止日, 需逐项确认验收标准。

验收checklist:

- /segment端点正常响应, Swagger文档完整
- 三种策略对比 (fixed_length / heading_based / structure_semantic_hybrid) 均可输出
- chunk序列包含title_path、source_refs、strategy_info、quality_flags
- 4种文档格式 (txt/md/docx/pdf) 全量测试通过
- 边界case验证: 空文档、纯表格文档、超长单段文档

19.3 T-7.3: /segment端点+Swagger文档更新 (B, 2h)

具体任务:

- 补充/api/segment/upload的请求示例和响应示例 (含完整JSON)
- 添加各参数的说明文档 (min_chars、target_chars、max_chars、overlap_sentences等)
- 同步更新README中的API说明

19.4 T-7.4: 前端分段结果展示完善 (D, 2h)

具体任务:

- 完善ChunkList组件的表格chunk渲染 (Markdown表格转HTML表格展示)
- 验证图片渲染在ChunkList中的正确性
- 添加quality_flags的可视化标识 (warning/error图标)
- 检查MetricPanel中新增指标 (不破句率/成块率) 的展示

19.5 T-7.5: 技术报告大纲+数据整理 (A, 2h)

具体任务:

- 搭建技术报告框架: 背景→方法→实验→结论→附录
 - 整理评估数据: 规则模式+LLM模式双份数据
 - 截取关键代码段: 分段核心算法、LLM-as-judge评判逻辑
 - 准备对比表格: Smart vs Baseline、规则 vs LLM
-

20 开发环境清单

组件	版本/说明
Python	3.13.2
FastAPI	最新稳定版
Uvicorn	ASGI服务器
Vue 3	Composition API + Vite
python-docx	DOCX文档解析
PyMuPDF (fitz)	PDF文档解析
sentence-transformers	MiniLM-L12-v2 (384维)
tiktoken	cl100k_base编码器
jieba	中文分词 + 领域词典
scikit-learn	TF-IDF向量化
langchain-openai	DeepSeek API调用
matplotlib	架构图/流程图生成
pytest	单元测试框架

可降级方案对照:

风险模块	首选方案	降级方案
embedding模型下载失败	sentence-transformers MiniLM	TF-IDF char-n-gram 1~4
LLM API不可用	DeepSeek生成标签/摘要	jieba TF-IDF + 抽取式摘要
FAISS安装失败	FAISS向量索引	sklearn NearestNeighbors
前端发版不及	Vue 3 SPA	Markdown静态报告