

开发日报

日期: 2026年7月7日 (星期二)

今日定位: 文档日 & 阶段6启动 (研发计划 4.2 — 阶段6第1天 / 共3天)

组长/汇报人: 孟之语

组员: 于贺、甘毅、王佳杭

汇报时间: 2026年7月7日 16:30

1 目录

- [1. 今日总览](#)
- [2. 阶段5回顾与阶段6启动背景](#)
- [3. 晨会记录](#)
- [4. 组员个人进度汇报](#)
 - 4.1 孟之语 (组长/核心算法负责人)
 - 4.2 于贺 (接口与数据负责人)
 - 4.3 甘毅 (内容组织负责人)
 - 4.4 王佳杭 (评测与展示负责人)
- [5. 今日核心工作详解](#)
 - 5.1 README.md 最终版编写
 - 5.2 API 接口文档编写
 - 5.3 数据格式说明文档编写
 - 5.4 部署说明与快速开始文档编写
 - 5.5 内容组织模块文档完善
 - 5.6 文档体系整体规划与一致性检查
- [6. 文档体系全景](#)
 - 6.1 文档结构总览
 - 6.2 文档质量标准
 - 6.3 文档交叉引用关系
 - 6.4 文档与交付物对应关系
- [7. 问题与解决方案](#)
- [8. 晚间同步会记录](#)
- [9. 组长总结](#)
- [10. 关键决策记录](#)
- [11. 明日计划 \(7月8日\)](#)
- [12. 项目整体进度追踪](#)
- [13. 任务状态表](#)
- [14. 里程碑验收状态](#)
- [15. 阶段6文档撰写规范](#)
- [16. 风险评估与缓冲消耗](#)
- [17. 附录: 关键产出物全文](#)

2 今日总览

项目	内容
日期	2026年7月7日（星期二）
阶段	阶段6 — 文档、答辩材料、演示彩排、缓冲修复（第1天 / 共3天）
今日定位	文档日：完成 README、接口文档、部署说明、数据格式说明
里程碑	M6 — 最终可交付版本（目标：7月9日）
全组状态	正常，全员在岗，文档日任务全面展开
今日计划任务	7项，完成7项
累计全组工时	约16小时
阶段6累计进度	约33%（文档日完成，后续待进行）
上次里程碑	M5 — 集成修复完成 + 演示可用（7月6日验收通过）
下次里程碑	M6 — 最终可交付版本（目标：7月9日）

2.1 今日在研发计划中的位置

根据研发计划 4.2 节每日计划，7月7日的定位为：

文档日：完成 README、接口文档、部署说明、数据格式说明
负责人：于贺、甘毅
产出：文档初版

今日是阶段6（7月7日-7月9日）的第1天。阶段6的三天行程：

日期	日程定位	核心任务	负责人	状态
7月7日	文档日	README、接口文档、部署说明、数据格式说明	全员	已完成
7月8日	报告日	技术报告撰写、交叉审阅启动	全员	待进行
7月9日	冻结日	交叉审阅完成、演示彩排、代码/数据/报告冻结	全员	待进行

2.2 今日完成的核心交付

编号	交付物	说明	状态
D-1	README.md 最终版	项目简介、快速开始、API列表、评测结果、演示指南、项目结构、FAQ	已完成
D-2	API 接口文档	11个端点的完整请求/响应示例、错误码说明、认证说明、调用示例	已完成
D-3	数据格式说明文档	DocumentBlock、Chunk、SegmentConfig、OrganizeResult、检索结果等全部数据结构	已完成
D-4	部署说明文档	环境要求、安装步骤、配置说明、启动命令、常见问题排查	已完成
D-5	快速开始文档	从零到运行的5分钟教程、验证步骤、下一步指引	已完成
D-6	内容组织模块文档完善	RuleBasedTagger 参数说明、LLM 模式配置、性能基准、自定义扩展	已完成
D-7	文档体系规划	整体文档结构、交叉引用关系、质量标准、与交付物对应关系	已完成

3.1 阶段5核心成果回顾（7月4日-6日）

代码资产:

资产	状态	说明
分段引擎	稳定	4格式支持、3预设策略、父子块架构、自适应参数
内容组织	稳定	规则/LLM双模式、标签/摘要/实体、静默降级
RAG 存储	稳定	ChromaDB异步初始化、SQLite元数据、写入重试
API 端点	11/11	全部到齐、统一错误格式、参数校验完善
前端界面	就绪	四大区域、预设选择器、ChunkList重构、错误拦截
CLI 工具	就绪	--preset、--parent-child、--output-json、--cache
评测脚本	就绪	三策略对比、评测报告生成、参数搜索框架
测试套件	27/27	全部通过

文档	状态	负责人
演示脚本（800行）	已完成	王佳杭
演示指南（README章节）	初稿	甘毅
部署说明（deployment.md）	初稿	于贺
内容组织文档（organizer.md）	初稿	甘毅

资产	状态	说明
三策略对比指标	最终确认	Recall@5 +18.5%
分段质量统计	全部达标	不破句率100%、表格成块率100%、长度命中率94.4%
内容组织基线	已建立	标签准确率0.70、摘要忠实度100%、实体精确率96.8%
Badcase 分析	已完成	4个badcase，失败模式已分类
Benchmark 数据集	10篇	可加载可分段，ground truth待标注

资产	状态	说明
演示脚本	已完成	5场景完整操作流程
演示预演	已完成	3个问题已修复/规避
前端演示页面	就绪	四大区域数据对接完成

1. **工程文档**：README、API文档、数据格式说明、部署说明、快速开始——这些文档确保项目的可复现性和可维护性。
2. **答辩材料**：演示脚本终稿、演示数据准备、演示彩排——确保7月10日现场演示的顺利进行。

3.3 阶段6的工作节奏

根据7月6日晚间同步会确认的安排：

日期	定位	核心工作	关键产出
7月7日	文档日	工程文档编写	README、API文档、数据格式说明、部署说明、快速开始
7月8日	报告日	技术报告撰写 + 交叉审阅	技术报告全章节
7月9日	冻结日	交叉审阅 + 演示彩排 + 提交包整理	审阅意见处理、演示最终彩排、代码/数据/报告冻结
7月10日	提交日	最终提交 + 现场演示	提交包、现场演示

4 晨会记录（09:30-10:10）

4.1 昨日（7月6日）回顾

孟之语汇报：

- 昨日完成 M5 里程碑验收，10/10 验收标准全部通过。M1-M5 五个里程碑全部按时通过，未动用缓冲天数。
- 阶段5三天（集成修复日、测试日、演示日）全部按计划完成。全组26项计划任务100%完成。
- ChromaDB 异步初始化是阶段5最具影响力的架构改进：服务启动时间从12-30s降至1-2s，向量存储与分段引擎解耦。
- 策略预设系统（RAG/训练/摘要三模式）为演示增加了"一键切换"的亮点功能。
- 昨日晚间同步会确认了阶段6（7月7日-9日）的详细安排。
- 昨日工时约6h，阶段5累计工时约24h（全组）。

于贺汇报：

- 昨日完成全量回归测试最终确认：27个测试全部通过、11端点正常、3文档端到端验证通过、服务30分钟稳定性验证通过。
- 发现并修复了 ChromaDB 并发写入偶发 database is locked 问题（增加3次递增等待重试逻辑）。
- 部署说明文档初稿已写好，今日需要补充完善并新增快速开始文档。
- 昨日工时约5.5h。

甘毅汇报：

- 昨日完成演示指南编写（README新增章节）、内容组织模块开发者文档（docs/organizer.md）、后处理修复验证（实体精确率95.9%提升至96.8%、召回率85.5%提升至93.0%）。
- 参与了演示预演，负责场景4（内容组织）的演示操作。
- 昨日工时约5h。

王佳杭汇报：

- 昨日完成演示脚本（约800行、5个场景）、前端演示页面最终完善、演示预演问题修复。
- ChunkList 重构完成：从580行精简至约300行，提取4个子组件，渲染性能显著改善。
- 演示预演中发现并修复了3个问题：参数锁定状态未及时更新、大chunk数量滚动卡顿、ChromaDB初始化等待时间过长。
- 昨日工时约6h。

4.2 昨日遗留问题追踪

编号	问题描述	状态
P-7.6-1	ChromaDB 并发写入偶发 database is locked	已修复 (retry逻辑)
P-7.6-2	segment_file.py --preset 和 --target 同时指定时静默忽略	已修复 (冲突检测)
P-7.6-3	ChunkList 大chunk数量渲染卡顿	已修复 (v-memo优化)
P-7.6-4	演示预演中 ChromaDB 初始化等待时间过长	已规避 (预先启动)

所有昨日遗留问题已关闭，无遗留问题进入阶段6。

4.3 今日任务分配

编号	任务	负责人	预计工时	优先级	依赖
T-12.1	README.md 最终版：项目简介、快速开始、API列表、评测结果、演示指南、项目结构、FAQ	孟之语	3h	P0	—
T-12.2	API 接口文档 docs/api.md：11个端点的完整请求/响应示例、错误码说明、认证说明	孟之语	2.5h	P0	T-12.1
T-12.3	数据格式说明 docs/data_schema.md：DocumentBlock、Chunk、SegmentConfig、OrganizeResult、检索结果	甘毅	2.5h	P0	—
T-12.4	部署说明 docs/deployment.md 完善：从初稿扩展为完整版（环境要求、安装步骤、配置说明、常见问题）	于贺	2.5h	P0	—
T-12.5	快速开始 docs/quickstart.md：从零到运行的5分钟教程、验证步骤、下一步指引	于贺	1.5h	P1	T-12.4
T-12.6	内容组织文档 docs/organizer.md 完善：RuleBasedTagger 全部参数说明、LLM 模式配置详解、性能基准数据	甘毅	1.5h	P1	—
T-12.7	文档体系规划与一致性检查：确保各文档间的交叉引用正确、术语统一、版本一致	孟之语	1h	P1	T-12.1-T-12.6

4.4 晨会关键决策

决策 1 — 文档撰写规范确认

背景：阶段6需要产出大量文档，为了保证文档质量和一致性，需要确认统一的撰写规范。

讨论过程：

- 孟之语提出：所有工程文档（README、API文档、数据格式说明、部署说明、快速开始）应遵循统一的结构模板——概述、前置条件、核心内容、示例、常见问题、下一步。
- 甘毅补充：数据格式说明应该以"字段表格"的形式呈现每个数据结构的字段名、类型、必填/可选、说明和示例值，方便开发者查阅。
- 于贺建议：所有文档中的代码示例应该经过实际运行验证，确保复制粘贴即可执行。

决议：今日产出的所有文档遵循以下规范：

- 工程文档采用"概述-前置条件-核心内容-示例-常见问题-下一步"六段式结构
- 数据格式说明采用字段表格形式，每个字段包含名称、类型、必填/可选、说明、示例值
- 所有代码示例需经过实际运行验证
- 术语全文档统一：例如统一使用"chunk"而非"片段"和"chunk"混用、统一使用"分段"而非"分块"和"分段"混用

决策 2 — 文档交叉引用策略

背景：多个文档之间存在内容关联。例如 README 中的 API 列表应该链接到 API 文档的详细说明，数据格式说明中的数据结构被 API 文档和内容组织文档同时引用。

讨论过程：

- 孟之语提出：文档间使用相对路径链接（如 `[API 接口文档](docs/api.md)`），确保在本地和 GitHub 上都能正确跳转。
- 甘毅建议：在每份文档的开头增加"相关文档"章节，列出与本文件相关的其他文档的链接。

决议：

1. 工程文档间使用相对路径链接
2. 每份文档开头增加"相关文档"章节
3. 孟之语在今日下班前检查所有文档的交叉引用是否正确

5 组员个人进度汇报

5.1 孟之语（组长 / 核心算法负责人）

今日完成：

1. [T-12.1] README.md 最终版：重新组织为8个章节，约350行，覆盖项目简介、快速开始、API列表、评测结果、演示指南、项目结构、FAQ、贡献指南
2. [T-12.2] API 接口文档 docs/api.md：11个端点的完整文档，每个端点含请求/响应示例、参数说明、错误码、调用示例（curl + Python）
3. [T-12.7] 文档体系规划与一致性检查：绘制了文档结构总览图、交叉引用关系图、文档-交付物对应关系表
4. 协调全组文档产出物，确保格式统一、术语一致、交叉引用正确
5. 审核了甘毅的数据格式说明文档、于贺的部署说明和快速开始文档，提出了修改意见
6. 晚间同步会向全组汇报了文档日完成情况和明日安排

实际工时：约 6 小时

关键产出详情：

产出 1 — README.md 最终版

README.md 从7月3日的简洁版（约50行）扩展为最终版（约350行），包含8个章节：

第1章：项目简介

- 课题11定位（1段）
- 核心能力（6项：结构感知分段、语义边界增强、特殊块保护、内容自动组织、RAG检索评测、多格式支持）
- 技术栈标签

第2章：快速开始（5分钟）

- 前置条件（Python 3.10+、Node.js 18+）
- 后端安装与启动（4步）
- 前端安装与启动（3步）
- 验证步骤（curl /health + 浏览器访问）

- 11个端点的概览表（方法、路径、功能）
- 链接到详细 API 文档

第4章：评测结果

- 三策略对比指标表（6项IR指标 + 增量分析）
- 分段质量统计（4项指标全部达标）
- 内容组织质量基线（3项指标）
- 关键结论：结构信息贡献 +8.9%、语义边界增量 +8.8%、总提升 +18.5%

第5章：演示指南

- 5个演示场景的快速索引
- 每个场景的启动命令和关键操作
- 预期结果和讲解要点摘要

第6章：项目结构

- 完整的目录树（backend/frontend/scripts/data/docs）
- 每个目录和关键文件的说明

第7章：常见问题 (FAQ)

- 8个常见问题及解决方案
- 涵盖安装问题、运行问题、评测问题、ChromaDB问题、LLM配置问题

第8章：贡献指南

- 代码规范
- 提交规范
- 测试要求

README.md 的设计原则：

- 新人友好：5分钟快速开始，每一步都有可执行的命令
- 信息分层：概览→详情→深入，读者可以按需跳转
- 链接丰富：API列表链接到API文档、项目结构链接到源代码、FAQ链接到详细排查文档
- 数据驱动：评测结果用表格呈现，有具体数字和分析

产出 2 — API 接口文档 docs/api.md

API 接口文档约500行，为全部11个端点提供了完整文档。每个端点的文档结构统一为：

```

1 | 端点名称
2 | └─ 概述（1-2句说明端点的功能和使用场景）
3 | └─ 请求
4 |   └─ 方法 + 路径
5 |   └─ 请求头
6 |   └─ 路径参数（如有）
7 |   └─ 查询参数（如有）
8 |   └─ 请求体（如有）
9 |     └─ Content-Type
10 |     └─ 字段说明表（字段名、类型、必填、说明、示例值）
11 |     └─ 请求示例（curl + Python requests）

```

13

14

15

16

17

18

19

20

成功响应

HTTP 状态码

响应体字段说明表

响应示例 (JSON)

错误响应

错误码列表 (错误码、HTTP状态码、说明、触发条件)

错误响应示例

注意事项 (如有特殊说明)

11个端点的文档覆盖情况：

#	端点	请求示例	响应示例	错误码	注 意 事 项
1	GET /health	curl + Python	JSON	—	用于健康检查和就绪探针
2	POST /api/segment/upload	curl (multipart) + Python	JSON	4种	支持4种格式、preset参数说明
3	GET /api/chunks/all	curl + Python	JSON	1种	分页参数说明
4	GET /api/chunks/{doc_id}	curl + Python	JSON	1种	文档ID格式说明
5	POST /api/query	curl + Python	JSON	3种	混合检索模式说明
6	POST /api/synthesize-qa	curl + Python	JSON	2种	LLM依赖说明
7	GET/PUT /api/model-settings	curl + Python	JSON	1种	支持的模型列表
8	GET /api/images/{doc_id}	curl + Python	JSON	1种	图片路径格式说明
9	GET /api/strategies	curl + Python	JSON	—	预设策略列表
10	POST /api/organize	curl + Python	JSON	1种	LLM/规则双模式说明
11	POST /api/evaluate	curl + Python	JSON	2种	评测耗时说明

每个端点都提供了 curl 命令和 Python requests 两种调用示例，确保读者可以直接复制粘贴运行。

错误码体系（7种标准错误码）：

错 误 码	HTTP状态码	说 明	适用端点
VALIDATION_ERROR	422	请求参数校验失败	所有POST/PUT端点
NOT_FOUND	404	请求的资源不存在	chunks/{doc_id}、images/{doc_id}、evaluate
CONFLICT	409	资源冲突（如重复上传）	segment/upload、evaluate
UNSUPPORTED_FORMAT	400	不支持的文件格式	segment/upload
SEGMENTATION_FAILED	500	分段处理失败	segment/upload
CHROMA_UNAVAILABLE	503	向量存储不可用	query
LLM_UNAVAILABLE	200+warning	LLM服务不可用（已降级）	synthesize-qa、organize

遇到的阻塞：

- 无重大阻塞。README.md 在"简洁"和"完整"之间需要反复权衡。最终采用了分层设计：概览层（第1-2章，5分钟可读完）→ 核心层（第3-5章，包含API列表、评测结果、演示指南）→ 参考层（第6-8章，项目结构、FAQ、贡献指南）。读者可以按需跳转，不需要从头读到尾。
- API 文档中的 curl 示例需要确保在 Windows (cmd/PowerShell) 和 Linux/macOS (bash) 上都能运行。Windows 的 curl 对单引号支持和多行命令格式与 bash 有差异。最终决定以 bash 语法为主（项目主要在 Linux/macOS 环境运行），在注意事项中增加了 Windows 环境的说明。

5.2 于贺（接口与数据负责人）

今日完成：

1. [T-12.4] 部署说明 docs/deployment.md 完善：从7月6日的初稿（约80行）扩展为完整版（约280行），新增了环境依赖详解、配置模板、启动验证、常见问题排查
2. [T-12.5] 快速开始 docs/quickstart.md：编写了从零到运行的5分钟教程，每一步都有可执行命令和预期输出
3. 验证了所有文档中的安装命令和启动命令在干净环境下的可执行性
4. 为部署说明编写了完整的常见问题排查章节（7个常见问题 + 解决方案）
5. 整理了技术栈版本清单（Python 3.12.0、Node.js 18+、FastAPI 0.x、ChromaDB 0.x、sentence-transformers 2.x等）
6. 审核了孟之语的 API 文档中的请求示例，确认所有 curl 命令的路径和参数正确

实际工时：约 5.5 小时

关键产出详情：

产出 1 — 部署说明 docs/deployment.md（完整版）

部署说明从初稿的约80行扩展为约280行的完整版，包含6个章节：

第1章：环境要求

- 操作系统：Windows 10+ / macOS 12+ / Ubuntu 20.04+
- Python: 3.10+（推荐 3.12）
- Node.js: 18+（推荐 20 LTS）
- 磁盘空间：至少 2GB（含模型文件约 500MB）
- 内存：至少 2GB（推荐 4GB，ChromaDB 需要额外内存）
- 网络：首次运行需从 Hugging Face 下载 MiniLM 模型（约 120MB）

第2章：安装步骤

后端安装（详细版）：

```
1  # 1. 克隆项目
2  git clone <repository-url>
3  cd zhinengti
4
5  # 2. 创建虚拟环境（推荐）
6  python -m venv venv
7  # Windows: venv\Scripts\activate
8  # Linux/macOS: source venv/bin/activate
9
10 # 3. 安装依赖
11 pip install -r requirements.txt
12
13 # 4. 验证安装
14 python -c "import fastapi, uvicorn, sentence_transformers, chromadb; print('OK')"
```

前端安装（详细版）：

```
1 # 1. 进入前端目录
2 cd frontend
3
4 # 2. 安装依赖
5 npm install
6
7 # 3. 验证安装
8 npx vite --version
```

每个步骤都附带了预期的输出和耗时估算。

第3章：配置说明

.env 文件配置模板：

```
1 # LLM API 配置（可选，不配置则使用规则模式）
2 OPENAI_API_KEY=sk-your-key-here
3 OPENAI_BASE_URL=https://api.deepseek.com/v1
4 OPENAI_MODEL=deepseek-chat
5
6 # 服务配置
7 HOST=0.0.0.0
8 PORT=8000
9
10 # ChromaDB 配置
11 CHROMA_PERSIST_DIR=./data/chromadb
12
13 # 日志级别
14 LOG_LEVEL=INFO
```

每个配置项的说明、默认值、是否必填、影响范围。

第4章：启动服务

```
1 # 终端1：启动后端
2 python -m uvicorn backend.app.main:app --host 0.0.0.0 --port 8000 --reload
3
4 # 终端2：启动前端
5 cd frontend && npm run dev
```

启动后的验证步骤：

- curl <http://localhost:8000/health> → {"status": "ok", "version": "1.0.0"}
- 浏览器打开 <http://localhost:5173> → 看到前端界面

第5章：Docker 部署（可选）

提供了 Dockerfile 和 docker-compose.yml 的示例配置（标注为"可选，非必须"）。

第6章：常见问题排查

#	问题	症状	原因	解决方案
1	端口被占用	[Errno 10048]	8000/5173端口已被使用	<code>netstat -ano findstr :8000</code> 查找并终止占用进程，或更换端口
2	MiniLM模型下载失败	ConnectionError	Hugging Face连接超时	设置镜像 <code>export HF_ENDPOINT=https://hf-mirror.com</code> ，或手动下载模型到 <code>~/.cache/sentence-transformers/</code>
3	ChromaDB初始化超时	日志显示 ChromaDB init failed	onnxruntime版本不兼容	<code>pip install onnxruntime==1.17.1</code> ，或等待后台线程自动重试
4	python-docx安装失败	error: Microsoft Visual C++ 14.0 is required	Windows缺少C++编译工具	安装 Visual Studio Build Tools，或使用预编译wheel
5	PyMuPDF导入错误	ImportError: libfitz.so	Linux缺少系统库	<code>apt-get install libmupdf-dev</code>
6	npm install 失败	ERESOLVE	Node.js版本过低	升级到 Node.js 18+
7	前端白屏	浏览器控制台报错 Failed to fetch	后端未启动或CORS未配置	确认后端已启动 (<code>curl /health</code>)，检查HOST配置

每个问题都附带了详细的排查步骤和验证命令。

产出 2 — 快速开始 docs/quickstart.md

快速开始文档约120行，设计目标是"从零到运行的5分钟教程"。结构如下：

Step 1: 环境检查 (30秒)

```
1 | python --version # 应 >= 3.10
2 | node --version   # 应 >= 18
```

Step 2: 安装依赖 (2分钟)

```
1 | pip install -r requirements.txt
2 | cd frontend && npm install && cd ..
```

Step 3: 启动服务 (1分钟)

```
1 | # 终端1
2 | python -m uvicorn backend.app.main:app --host 0.0.0.0 --port 8000
3 |
4 | # 终端2
5 | cd frontend && npm run dev
```

Step 4: 验证 (30秒)

```
1 | curl http://localhost:8000/health
2 | # 浏览器打开 http://localhost:5173
```

Step 5: 上传第一篇文档 (1分钟)

```
1 | curl -X POST http://localhost:8000/api/segment/upload \
2 |   -F "file=@assets/title.md"
```

Step 6: 查看分段结果

```
1 | curl http://localhost:8000/api/chunks/all | python -m json.tool | head -50
```

Step 7: 下一步

- 查看 [API 接口文档](#) 了解全部11个端点
- 查看 [演示指南](#) 了解5个演示场景
- 查看 [数据格式说明](#) 了解数据结构
- 查看 [部署说明](#) 了解生产环境部署

每一步都附带了预期输出和截图替代文字（实际截图在文档中以文字描述形式存在）。

遇到的阻塞：

- 部署说明中的"常见问题排查"章节需要覆盖 Windows、macOS、Linux 三个平台的差异。例如端口占用问题，Windows 用 `netstat -ano`、Linux/macOS 用 `lsof -i`。解决方案：在排查命令中同时标注三个平台的命令格式，并用平台标签区分。
- MiniLM 模型下载的镜像配置因地区而异。解决方案：在文档中列出了三个常用的 Hugging Face 镜像（hf-mirror.com、hf.xeduapi.com、aliyun），并注明"根据所在网络环境选择可用镜像"。

5.3 甘毅（内容组织负责人）

今日完成：

1. [T-12.3] 数据格式说明 docs/data_schema.md：编写了全部核心数据结构的完整文档，约400行，覆盖6大数据结构
2. [T-12.6] 内容组织文档 docs/organizer.md 完善：从7月6日的约300行初稿扩展为约450行完整版
3. 为数据格式说明中的每个数据结构绘制了字段说明表（字段名、类型、必填/可选、说明、示例值）
4. 为数据格式说明编写了数据流转全景图和数据结构之间的关系图
5. 审核了于贺的快速开始文档，确保数据格式术语与数据格式说明文档一致
6. 为内容组织文档补充了完整的性能基准数据表（基于7月5-6日的人工抽样评测数据）

实际工时：约 5.5 小时

关键产出详情：

产出 1 — 数据格式说明 docs/data_schema.md

数据格式说明文档约400行，覆盖了系统中的全部核心数据结构。设计原则是"开发者友好"——每个字段都有类型、说明和示例值，可以当作 API 开发的参考手册使用。

数据结构全景图：

```

1  文档上传 (UploadedFile)
2  ↓
3  DocumentBlock (文档加载后的原始块)
4  ├── block_id: str          - 块的唯一标识
5  ├── block_type: str        - 类型 (paragraph/heading/table/code/formula/list/image)
6  ├── content: str           - 文本内容
7  ├── page: int              - 所在页码
8  ├── metadata: dict         - 扩展元数据
9  └── image_refs: list[str]   - 关联的图片路径
10 ↓
11 SegmentConfig (分段配置)
12 ├── 长度控制: min_chars, target_chars, max_chars, heading_flush_min_chars
13 ├── 重叠控制: overlap_sentences
14 ├── 语义边界: enable_semantic_boundary, semantic_boundary_threshold
15 ├── 关键词策略: keyword_strategy

```

```

17 | └─ 预设策略: preset
18 | ↓
19 | Chunk (分段结果)
20 |   └─ chunk_id: str          - 全局唯一标识
21 |   └─ doc_id: str           - 所属文档ID
22 |   └─ chunk_index: int      - 在文档中的序号
23 |   └─ content: str          - 正文内容
24 |   └─ retrieval_text: str    - 检索增强文本 (标题路径+正文)
25 |   └─ char_count: int       - 字符数
26 |   └─ token_count: int      - token数 (tiktoken cl100k_base)
27 |   └─ title_path: list[str]  - 标题路径 (如 ["第一章", "1.1 背景"])
28 |   └─ tags: list[str]        - 关键词/主题标签
29 |   └─ summary: str           - 片段摘要
30 |   └─ entity_labels: list[EntityLabel] - 实体标签
31 |   └─ source_refs: list[SourceRef]    - 原文回链
32 |   └─ strategy_info: dict             - 生成策略信息
33 |   └─ quality_flags: list[str]        - 质量标记
34 |   └─ parent_chunk_id: str            - 父块ID (子块专用)
35 |   └─ child_chunk_ids: list[str]      - 子块ID列表 (父块专用)
36 | ↓
37 | OrganizeResult (内容组织结果)
38 |   └─ chunk_id: str
39 |   └─ tags: list[str]
40 |   └─ summary: str
41 |   └─ entity_labels: list[EntityLabel]
42 |   └─ quality_flags: list[str]
43 | ↓
44 | RetrievedChunk (检索结果)
45 |   └─ chunk_id: str
46 |   └─ content: str
47 |   └─ score: float          - 相关性分数
48 |   └─ title_path: list[str]
49 |   └─ source_refs: list[SourceRef]
50 | ↓
51 | EvaluationResult (评测结果)
52 |   └─ doc_id: str
53 |   └─ strategy: str          - 评测策略名
54 |   └─ recall_at_k: dict      - {1: 0.1669, 3: 0.4042, 5: 0.5915}
55 |   └─ precision_at_k: dict
56 |   └─ ndcg_at_k: dict
57 |   └─ mrr: float
58 |   └─ per_question: list     - 逐题详情

```

每个数据结构的文档包含:

以 Chunk 为例:

字段名	类型	必填	说明	示例值
chunk_id	str	是	全局唯一标识，格式 {doc_id}chunk{seq:04d}	"title_md_chunk_0001"
doc_id	str	是	所属文档ID	"title_md"
chunk_index	int	是	在文档中的序号（从0开始）	0
content	str	是	chunk的正文内容	"课题11面向RAG的智能分段..."
retrieval_text	str	是	检索增强文本，格式：标题路径 + "\n" + 正文	"课题11 > 课题背景\n课题11面向RAG..."
char_count	int	是	字符数	548
token_count	int	是	token数（tiktoken cl100k_base）	412
title_path	list[str]	是	标题路径列表	["课题11", "课题背景"]
tags	list[str]	是	关键词/主题标签列表	["智能分段", "RAG", "标题边界"]
summary	str	是	片段摘要（≤80字）	"该系统通过标题边界优先策略..."
entity_labels	list[EntityLabel]	是	实体标签列表	[{"type": "metric", "value": "Recall@5"}]
source_refs	list[SourceRef]	是	原文回链	[{"block_id": "b3", "page": 1}]
strategy_info	dict	是	生成策略信息	{"strategy": "semantic_boundary", "config": {...}}
quality_flags	list[str]	是	质量标记	["sentence_boundary"]
parent_chunk_id	str	否	父块ID（子块专用，父块为空字符串）	"" 或 "title_md_chunk_0001"
child_chunk_ids	list[str]	否	子块ID列表（父块专用，子块为空列表）	[] 或 ["title_md_chunk_0001_child_0001"]

每种数据结构都附带了完整的 JSON 示例。

产出 2 — 内容组织文档 docs/organizer.md（完整版）

内容组织文档从7月6日的约300行初稿扩展为约450行完整版。新增内容包括：

第4章：LLM 模式配置详解

- 支持的模型列表（DeepSeek-V3、DeepSeek-R1、OpenAI GPT-4o、OpenAI GPT-4o-mini）
- API Key 配置方法（环境变量 .env 文件、运行时 API /api/model-settings）
- LLM 提示词模板（标签生成提示词、摘要生成提示词、实体识别提示词）
- LLM 模式的工作原理：发送 chunk 内容 + 提示词 → 解析 JSON 响应 → 提取标签/摘要/实体
- 温度参数设置建议（标签生成 temperature=0.3、摘要生成 temperature=0.5、实体识别 temperature=0.1）

第5章：降级机制详解

- 降级触发条件：API Key 未配置、API 调用超时（30s）、API 返回错误（5xx）、网络不可达
- 降级行为：静默切换到规则模式、在 quality_flags 中添加 "rule_mode" 标记、不影响服务可用性
- 降级验证方法：unset OPENAI_API_KEY → 调用 /api/organize → 检查 quality_flags

第6章：性能基准数据（完整版）

指标	规则模式	LLM 模式 (DeepSeek-V3)	说明
单chunk处理耗时	~0.15s	~1.2s	LLM模式含网络往返时间
标签准确率 (Jaccard 0.5)	0.70	~0.98 (估计值)	基于15 chunk人工标注
摘要忠实度	100% (抽取式)	~95% (估计值)	LLM生成式摘要可能有轻微偏离
实体精确率	96.8%	—	LLM模式不改变实体识别 (实体使用正则)
实体召回率	93.0%	—	同上
批量处理 (20 chunk)	~3s	~24s	LLM模式逐chunk调用API
内存占用	~50MB	~50MB	LLM模式不增加本地内存

第7章：自定义扩展

- 自定义停用词表：修改 `_STOP_WORDS` 集合
- 自定义后缀词表：修改 `_ORG_SUFFIXES` 列表
- 自定义正则模式：修改 `_ENTITY_PATTERNS` 字典
- 自定义摘要长度：修改 `max_summary_chars` 参数
- 自定义标签数量：修改 `max_tags` 参数

遇到的阻塞：

- 数据格式说明中 EntityLabel 的 type 枚举值需要在多处文档保持一致。当前定义的6种实体类型 (percentage/metric/date/org_suffix/version/threshold) 已与代码中的 `_ENTITY_PATTERNS` 字典和 API 文档中的示例值全部对齐。但在检查过程中发现一处不一致：API 文档中的示例写的是 "org"，而代码和数据格式说明中用的是 "org_suffix"。已修正 API 文档中的示例，统一使用 "org_suffix"。
- LLM 模式的标签准确率和摘要忠实度的数值基于估计（因为7月5-6日的正式评测只做了规则模式，LLM 模式做了回归测试但未做系统的人工标注评测）。已在文档中明确标注"估计值"和"基于规则模式的代码分析和初步测试"，避免误导读者。

5.4 王佳杭（评测与展示负责人）

今日完成：

- 整理了全部评测数据的来源和可复现路径（每项指标对应的脚本、参数、输出文件路径）
- 更新了演示脚本中与新版 API 文档对应的端点和参数说明
- 审核了 README.md 中的评测结果章节，确认所有指标数据与 eval_rag.py 实际运行结果一致
- 为 README.md 的演示指南章节补充了实际截图替代文字和操作细节
- 协助甘毅审核数据格式说明中 EvaluationResult 和 RetrievedChunk 数据结构的字段定义
- 整理了评测数据附录：三策略完整指标表、per-document 指标表、per-question 详细结果表

实际工时：约 4.5 小时

关键产出详情：

产出 1 — 评测数据来源全量标注

为全部评测指标建立了"数据来源→脚本→参数→输出文件"的完整追溯链：

指标	脚本	运行参数	输出文件	可复现命令
Recall@5 = 0.5915	scripts/eval_rag.py	默认参数	data/outputs/evaluation_results.json	python scripts/eval_rag.py
不破句率 = 100%	scripts/segment_file.py	默认参数	终端输出	python scripts/segment_file.py assets/title.md
标签准确率 = 0.70	人工抽样评测	15 chunk	评测记录表	—（人工评测）
实体精确率 = 96.8%	人工抽样评测	15 chunk	评测记录表	—（人工评测）

产出 2 — 演示脚本更新

针对今日完成的 API 文档，更新了演示脚本中的以下内容：

- 所有 curl 命令的端点路径与 API 文档保持一致
- 补充了每个演示场景的预期 HTTP 状态码
- 增加了错误场景的演示步骤（无效格式、缺失参数）

产出 3 — README 评测数据审核

逐项核对了 README.md 中评测结果章节的数据：

- 6项IR指标：与 eval_rag.py 实际运行结果一致
- 4项分段质量统计：与 statistics.py 输出一致
- 3项内容组织基线：与人工抽样评测记录一致
- 增量分析数据：与 eval_report.py 输出一致

遇到的阻塞：

- 无重大阻塞。整理评测数据来源时发现 eval_report.py 输出的 JSON 文件中 badcase 详细检索结果与 Markdown 报告中的概要信息存在细微格式差异（JSON 中 score 为浮点数，Markdown 中做了四舍五入）。已记录此差异，并在 README 中引用的指标数据均标注了数据来源文件，确保可追溯。

6 今日核心工作详解

6.1 README.md 最终版编写

README.md 是项目的门面文档，也是大多数用户（包括验收老师）首先阅读的文档。今日孟之语将 README.md 从7月3日的简洁版（约50行）重写为最终版（约350行）。

设计理念：

README.md 采用分层设计，满足不同读者的需求：

1. **过路读者（30秒）**：阅读项目标题、一句话描述和关键指标（M1-M5状态、测试通过率、Recall@5指标），快速了解项目是什么、状态如何。
2. **潜在用户（5分钟）**：阅读快速开始章节，按照步骤安装和启动项目，上传第一篇文档并查看分段结果。目标是在5分钟内从零看到分段结果。
3. **深度用户（15分钟）**：阅读API列表和评测结果章节，了解系统支持的全部功能和性能指标，决定是否在自己的场景中使用。

4. 贡献者/审阅者 (30分钟)：阅读项目结构、FAQ和贡献指南，了解代码组织方式、常见问题和开发规范。

内容组织：

- 第1-2章（项目简介 + 快速开始）：最短、最精炼，确保新人能快速上手
- 第3-5章（API列表 + 评测结果 + 演示指南）：核心信息，用表格呈现，一目了然
- 第6-8章（项目结构 + FAQ + 贡献指南）：参考信息，按需查阅

关键改进（相对于7月3日简洁版）：

1. 新增了"核心能力"章节：6项核心能力用一句话描述，让读者快速了解系统的能力边界
2. 快速开始从3步扩展为7步，每一步都有可执行命令和预期输出
3. API列表从纯表格扩展为表格+链接（链接到详细API文档）
4. 新增了演示指南章节（从甘毅7月6日的演示指南中提取核心内容）
5. 项目结构从四级目录扩展为带注释的完整目录树
6. 新增了FAQ章节（8个常见问题，涵盖安装、运行、评测、ChromaDB、LLM配置）
7. 新增了贡献指南章节（代码规范、提交规范、测试要求）

6.2 API 接口文档编写

API 接口文档（docs/api.md）是开发者使用系统的主要参考文档。今日孟之语编写了约500行的完整API文档。

设计理念：

每个端点的文档遵循"概述-请求-响应-注意事项"四段式结构，确保开发者可以：

1. 快速了解端点的功能（概述）
2. 构造正确的请求（请求参数说明 + curl/Python示例）
3. 理解返回的数据（响应字段说明 + JSON示例）
4. 处理异常情况（错误码说明 + 错误响应示例）
5. 注意特殊限制（注意事项）

关键技术决策：

1. 每个端点的请求示例同时提供 curl 和 Python requests 两种形式。curl 适合快速测试，Python 适合集成开发。
2. 请求体和响应体的字段说明采用表格形式（字段名、类型、必填、说明、示例值），方便开发者查阅。
3. 错误码体系采用7种标准错误码，每种错误码有明确的HTTP状态码、说明和触发条件。
4. 所有示例数据来自实际运行结果（而非手写假数据），确保复制粘贴即可运行。

与代码的一致性保证：

API文档中的所有请求/响应示例均与 `backend/app/api/routes.py` 中的实际实现一致。文档编写过程中逐端点核对了以下内容：

- 请求方法（GET/POST/PUT）
- 请求路径
- 请求参数（路径参数、查询参数、请求体字段）
- 响应状态码
- 响应体字段名和类型
- 错误响应格式

6.3 数据格式说明文档编写

数据格式说明文档（docs/data_schema.md）是开发者理解系统数据模型的参考手册。今日甘毅编写了约400行的完整文档。

设计理念：

数据格式说明的核心价值是"消除歧义"——当开发者在API文档中看到某个字段（如 `entity_labels`）时，可以在数据格式说明中找到该字段的完整定义（类型、结构、示例值、生成逻辑）。

覆盖的数据结构（6大核心结构 + 3个辅助结构）：

1. DocumentBlock — 文档加载后的原始块
2. SegmentConfig — 分段配置
3. Chunk — 分段结果（最核心的数据结构，18个字段）
4. EntityLabel — 实体标签
5. SourceRef — 原文回链
6. OrganizeResult — 内容组织结果
7. RetrievedChunk — 检索结果
8. EvaluationResult — 评测结果
9. StrategyPreset — 策略预设

数据流转关系：

文档中包含了数据流转全景图，展示了从文档上传到检索结果的数据流转过程，以及每个阶段使用的数据结构。这有助于开发者理解系统的整体数据模型，而不是孤立地查看每个数据结构。

6.4 部署说明与快速开始文档编写

部署说明（docs/deployment.md）和快速开始（docs/quickstart.md）是于贺今日的核心产出。两份文档服务于不同的读者：

- 快速开始：面向"想快速体验"的用户，目标是5分钟从零到运行
- 部署说明：面向"想部署到生产环境"的用户，涵盖完整的环境要求、配置说明、常见问题排查

两份文档的关系：

快速开始 → 部署说明（"下一步"链接）

部署说明 → 快速开始（"如果只是想快速体验，请参考快速开始"）

快速开始只包含最小必要步骤，部署说明包含完整的生产级部署指南。

常见问题排查章节的设计：

部署说明中的常见问题排查章节是文档中"投入产出比最高"的部分——7个常见问题覆盖了90%以上的实际使用问题。每个问题包含：

- 症状（用户看到的错误信息）
- 原因（技术层面的根因分析）
- 解决方案（可执行的具体操作步骤）

常见问题排查章节设计

这种"症状-原因-解决-验证"的四段式结构来自于贺在阶段1-5期间积累的实际问题处理经验。

6.5 内容组织模块文档完善

内容组织文档（docs/organizer.md）在7月6日甘毅编写的初稿（约300行）基础上，今日扩展为约450行的完整版。

新增内容的价值：

- 1. LLM 模式配置详解（第4章）：解决了用户"怎么配置LLM模式"的问题。包含了API Key配置方法、支持的模型列表、提示词模板、温度参数建议——这些都是7月6日初稿中缺失的"实操"内容。
- 2. 降级机制详解（第5章）：解决了用户"LLM不可用时会发生什么"的疑虑。详细描述了降级触发条件、降级行为、quality_flags 标记、验证方法。
- 3. 性能基准数据（第6章）：解决了用户"规则模式和LLM模式性能差别多大"的决策问题。基于7月5-6日的人工抽样评测数据，提供了规则模式和LLM模式在耗时、准确率、忠实度、内存占用四个维度的对比。
- 4. 自定义扩展（第7章）：解决了用户"如何修改默认行为"的问题。提供了5个自定义扩展点（停用词表、后缀词表、正则模式、摘要长度、标签数量）的具体修改方法。

6.6 文档体系整体规划与一致性检查

今日孟之语在协调全组文档产出物的同时，进行了文档体系的整体规划与一致性检查。

文档体系全景（详见第六章）：

- 工程文档层（5份）：README.md、API文档、数据格式说明、部署说明、快速开始
- 演示文档层（2份）：演示脚本、演示指南
- 开发者文档层（1份）：内容组织文档

一致性检查清单：

检查项	检查范围	检查方法	结果
术语统一	全部文档	全文搜索关键术语，确保无混用	通过（已修复2处不一致）
API端点名称	README + API文档 + 数据格式说明	逐一核对端点路径和方法	通过
数据结构字段名	API文档 + 数据格式说明 + 内容组织文档	逐一核对字段名、类型	通过（已修复1处不一致）
评测指标数值	README + 评测数据附录	逐一核对6项IR指标 + 增量分析	通过
代码示例可执行性	README + 快速开始 + API文档	实际运行所有curl命令	通过
交叉引用链接	全部文档	逐一检查链接目标文件是否存在	通过（已修复3处死链）
版本号	README + 部署说明	核对版本号一致性	通过
文件路径	全部文档	核对引用的代码路径是否存在	通过

发现并修复的问题：

- 1. API文档中的 entity_labels 示例写的是 "type": "org"，但代码和数据格式说明中使用的是 "type": "org_suffix"。已统一为 "org_suffix"。
- 2. README 中的项目结构树缺少 docs/ 目录（今日新建）。已补充。

- 3. 部署说明中的 Python 版本要求写的是 "3.10+", 但 requirements.txt 中有一个包要求 ">=3.11"。已修正为 "3.11+"。
- 4. 快速开始中引用的是 docs/api_reference.md (旧文件名), 但实际文件名为 docs/api.md (新文件名)。已修正链接。
- 5. 演示脚本中有一处 curl 命令的端点路径使用了旧版 API 路径, 已更新为当前实际路径。

7 文档体系全景

7.1 文档结构总览

今日产出的文档构成了项目的完整工程文档体系。以下是文档结构总览：

1	项目根目录/	
2	├─ README.md	★ 门面文档 (350行)
3	│ └─ 项目简介 + 核心能力	
4	│ └─ 快速开始 (5分钟)	
5	│ └─ API 端点列表 (链接到 docs/api.md)	
6	│ └─ 评测结果	
7	│ └─ 演示指南 (链接到演示脚本)	
8	│ └─ 项目结构	
9	│ └─ FAQ (8个常见问题)	
10	│ └─ 贡献指南	
11		
12	├─ docs/	★ 工程文档目录
13	│ └─ api.md	★ API 接口文档 (500行)
14	│ └─ 11个端点的完整文档 (请求/响应/错误码/示例)	
15	│ └─ data_schema.md	★ 数据格式说明 (400行)
16	│ └─ 9个核心数据结构 (字段表+JSON示例+流转图)	
17	│ └─ deployment.md	★ 部署说明 (280行)
18	│ └─ 环境要求+安装+配置+启动+FAQ排查	
19	│ └─ quickstart.md	★ 快速开始 (120行)
20	│ └─ 7步从零到运行	
21	│ └─ organizer.md	★ 内容组织文档 (450行)
22	│ └─ RuleBasedTagger+LLMClient+降级+性能基准+自定义	
23		
24	├─ 演示脚本.md	★ 演示材料 (7月6日完成)
25	│ └─ 5个场景 (基础分段/预设策略/检索评测/内容组织/鲁棒性)	
26		
27	├─ scripts/	★ 脚本工具 (已随代码提交)
28	│ └─ segment_file.py	– CLI 分段工具
29	│ └─ eval_rag.py	– 三策略评测
30	│ └─ eval_report.py	– 评测报告生成
31	│ └─ tune_segmenting_params.py	– 参数搜索
32	│ └─ human_eval_semantic.py	– 人工评估

7.2 文档质量标准

今日全组确认了文档质量的四条标准：

- 1. **可复现性**：所有代码示例经过实际运行验证，复制粘贴即可执行。所有评测数据标注了数据来源（脚本路径 + 运行参数 + 输出文件路径）。
- 2. **一致性**：术语全文档统一（如统一使用"chunk"、"分段"、"内容组织"等术语）。数据格式字段名与代码实现一致。评测指标数值在不同文档由一致。

3. **完整性**：每个API端点都有完整的错误码说明。每个数据结构都有完整的字段说明表。每个常见问题都有完整的"症状-原因-解决-验证"四段式说明。
4. **分层性**：文档按照读者需求分层组织——过路读者（30秒）→ 潜在用户（5分钟）→ 深度用户（15分钟）→ 贡献者/审阅者（30分钟）。每层读者都能找到适合自己深度的内容。

7.3 文档交叉引用关系

```
1 | README.md
2 | └─ → docs/quickstart.md (快速开始详细步骤)
3 | └─ → docs/api.md (API详细文档)
4 | └─ → docs/data_schema.md (数据结构定义)
5 | └─ → docs/deployment.md (生产环境部署)
6 | └─ → 演示脚本.md (演示场景详情)
7 |
8 | docs/api.md
9 | └─ → docs/data_schema.md (请求/响应中的数据结构定义)
10| └─ → docs/deployment.md (LLM配置说明)
11|
12| docs/data_schema.md
13| └─ → docs/organizer.md (OrganizeResult的生成逻辑)
14|
15| docs/deployment.md
16| └─ → docs/quickstart.md (快速体验入口)
17|
18| docs/quickstart.md
19| └─ → docs/api.md (下一步：了解全部API)
20| └─ → docs/data_schema.md (下一步：了解数据结构)
21| └─ → docs/deployment.md (下一步：生产环境部署)
```

7.4 文档与交付物对应关系

根据研发计划的交付物清单，今日产出的文档对应了以下交付物：

交付物	对应文档	状态
项目说明文档	README.md	已完成
接口文档	docs/api.md	已完成
数据格式说明	docs/data_schema.md	已完成
部署说明	docs/deployment.md	已完成
快速开始指南	docs/quickstart.md	已完成
演示脚本	演示脚本.md	7月6日已完成

8 问题与解决方案

8.1 今日新发现的问题

编号	问题描述	严重程度	发现人	解决方案	状态
P-7.7-1	entity_labels 类型字段名不一致：API文档用"org"，代码用"org_suffix"	低	甘毅	统一为 "org_suffix"，已修正 API 文档和所有引用	已修复
P-7.7-2	requirements.txt 中一个包要求 Python >= 3.11，但部署说明写的是 >= 3.10	低	于贺	修正部署说明为 >= 3.11	已修复

编号	问题描述	严重程度	发现人	解决方案	状态
P-7.7-3	快速开始中引用了旧文件名 <code>api_reference.md</code> ，实际文件为 <code>api.md</code>	低	孟之语	修正链接	已修复
P-7.7-4	README 项目结构树缺少 <code>docs/</code> 目录	低	孟之语	补充 <code>docs/</code> 目录	已修复
P-7.7-5	演示脚本中一处 <code>curl</code> 命令端点路径使用了旧版 API 路径	低	王佳杭	更新为当前实际路径	已修复

8.2 遗留问题追踪（全量更新）

编号	问题描述	发现日期	责任人	当前状态
P-6.28-1	<code>embedding</code> 模型下载可能失败	6月28日	孟之语	降级方案已就绪（字符3-gram），已在部署说明中增加镜像配置指南
P-6.29-1	LLM API 不可用时摘要和标签降级	6月29日	甘毅	LLM→规则降级链路已验证，已写入内容组织文档第5章
P-7.1-1	Smart vs Baseline Recall@5 差距	7月1日	孟之语、王佳杭	已解决：参数调优后 +18.5%
P-7.1-2	<code>heading_based</code> baseline 缺失	7月1日	孟之语	已实现（7月3日）
P-7.2-2	评测数据集规模偏小	7月2日	孟之语	已记录：benchmark 10篇文档待标注
P-7.2-4	<code>eval_rag.py</code> 缺少命令行参数	7月2日	王佳杭	已解决：阶段5已补充
P-7.2-6	<code>retrieval_text</code> 标题路径权重不足	7月2日	于贺	已记录：后续优化方向
P-7.2-7	<code>rag_store/</code> 和 <code>retrieval/</code> 功能重叠	7月2日	于贺	已记录：长期改进项
P-7.3-1	EmbeddingStore 多次调用累积	7月3日	王佳杭	已解决：新增 <code>clear_document()</code>
P-7.3-2	超长文档分段耗时过长	7月3日	于贺	已缓解：新增 <code>--cache</code> 参数
P-7.3-3	<code>org_suffix</code> 实体召回率偏低	7月3日	甘毅	已修复：后缀词表扩充至18项
P-7.3-4	<code>metric</code> 正则未覆盖英文全称	7月3日	甘毅	已修复：新增4个英文指标名
P-7.4-1	ChromaDB 初始化阻塞启动	7月4日	于贺	已解决：异步初始化 + 静默降级
P-7.5-1	<code>test_model_settings</code> mock 路径过期	7月5日	孟之语	已修复
P-7.5-2	<code>test_segmenting</code> <code>chunk_count</code> 断言过严	7月5日	孟之语	已修复
P-7.6-1	ChromaDB 并发写入偶发 <code>database is locked</code>	7月6日	于贺	已修复（retry逻辑）
P-7.6-2	<code>segment_file.py</code> <code>--preset</code> 和 <code>--target</code> 冲突	7月6日	孟之语	已修复（冲突检测）
P-7.6-3	ChunkList 大chunk数量渲染卡顿	7月6日	王佳杭	已修复（v-memo优化）

9 晚间同步会记录（21:30-22:15）

9.1 各成员今日完成总结

孟之语汇报：

今天主要完成了两个核心文档：README.md 最终版（约350行）和 API 接口文档（约500行）。文档体系规划和一致性检查也完成了——发现了5处不一致，全部修复。

README.md 采用了分层设计：概览层（30秒读完）→ 核心层（5分钟）→ 参考层（30分钟）。新人能在5分钟内从零看到分段结果。

API 文档的每个端点都有 `curl` 和 `Python` 两种示例，覆盖了正常请求和全部错误码。7种标准错误码体系已经建立，每个错误码都有明确的触发条件和响应示例。

今天发现了5处文档不一致（术语、版本号、文件名、路径），全部修复。明天需要继续推进后续文档工作。

今日工时约 6h。

于贺汇报：

今天完成了部署说明（约280行）和快速开始（约120行）。部署说明从昨天的初稿大幅扩展，新增了环境依赖详解、配置模板、`Docker` 部署示例（可选）、7个常见问题的详细排查指南。

快速开始的设计目标是"5分钟从零到运行"。7个步骤，每一步都有可执行命令和预期输出。完成后引导读者到 API 文档、数据格式说明等更深入的文档。

验证了所有文档中的安装命令和启动命令——在干净的虚拟环境中运行了一遍，确认全部可执行。

还审核了孟之语的 API 文档中的 `curl` 示例，确认所有路径和参数正确。

今天发现了一个问题：`requirements.txt` 中一个包要求 `Python >= 3.11`，但部署说明写的是 `>= 3.10`。已修正。

今日工时约 5.5h。

甘毅汇报：

今天完成了数据格式说明（约400行）和内容组织文档的完善（从300行扩展到450行）。

数据格式说明覆盖了全部9个核心数据结构。每个数据结构有完整的字段说明表（字段名、类型、必填/可选、说明、示例值）和 `JSON` 示例。还画了数据流转全景图，展示数据在各个阶段使用的数据结构。

内容组织文档新增了4个章节：`LLM`模式配置详解（模型列表、提示词模板、温度参数）、降级机制详解（触发条件、降级行为、验证方法）、性能基准数据（规则 vs `LLM` 的耗时、准确率、忠实度对比）、自定义扩展（5个扩展点）。

今天发现了一处术语不一致：API 文档中的 `entity_labels type` 用的是 `"org"`，但代码和数据格式说明用的是 `"org_suffix"`。已统一为 `"org_suffix"`。

今日工时约 5.5h。

王佳杭汇报：

今天主要做了三件事。一是整理了全部评测数据的来源和可复现路径——每项指标现在都能追溯到具体的脚本、运行参数和输出文件路径。二是更新了演示脚本中与新版 API 文档对应的端点和参数说明，确保演示时使用的命令与文档一致。三是审核了 `README.md` 中的评测结果章节，确认所有指标数据与 `eval_rag.py` 实际运行结果完全一致。

另外协助甘毅审核了数据格式说明中 `EvaluationResult` 和 `RetrievedChunk` 两个数据结构的字段定义，确认与代码中的 `schemas.py` 一致。

今天发现演示脚本中有一处 `curl` 命令使用了旧版 API 路径，已更新。

今日工时约 4.5h。

9.2 全组讨论

讨论 1 — 文档日完成情况确认

孟之语：今天全组按计划完成了文档日的全部 7 项任务。5 份工程文档（README + API文档 + 数据格式说明 + 部署说明 + 快速开始）全部完成。1 份开发者文档（内容组织文档）完善完成。文档体系一致性检查完成。评测数据来源全量标注完成。演示脚本更新完成。

全组确认：文档日任务全部完成，可以进入明天的报告日。

讨论 2 — 明日（7月8日）的详细安排

负责人	交付内容	预计工时
孟之语	技术报告撰写与统稿	6h
于贺	技术报告工程实现章节	3h
甘毅	技术报告核心算法章节	4h
王佳杭	技术报告评测与案例分析章节	4h

特别强调：

1. 明日全组的工作重心在技术报告撰写上。
2. 所有章节完成后，孟之语负责全文统稿——确保章节间的逻辑连贯、术语统一、数据一致。

讨论 3 — 交叉审阅的安排

孟之语：7月9日是冻结日，需要完成全员交叉审阅。建议明天晚上就开始交叉审阅，为7月9日留出充足的修改时间。

交叉审阅分工：

审阅人	审阅重点
于贺	架构描述准确性、技术栈版本正确性、部署说明可执行性
甘毅	算法描述准确性、术语一致性、评测方法学正确性
王佳杭	指标数值正确性、数据来源标注完整性、图表清晰度
孟之语	全文统稿：逻辑连贯性、章节过渡、格式统一

决议：7月8日晚间同步会后启动交叉审阅。7月9日上午集中处理审阅意见。

10 组长总结

10.1 今日整体评价

今天是阶段6（文档+报告）的第1天——文档日。全组完成了全部 7 项计划任务，5 份工程文档 + 1 份开发者文档全部按计划完成。

重大成果：

1. **工程文档体系建成**。README（350行）、API 文档（500行）、数据格式说明（400行）、部署说明（280行）、快速开始（120行）——五份文档构成了完整的工程文档体系。每一份文档都遵循统一的结构模板，术语统一，交叉引用正确。从新人5分钟快速开始到生产环境部署，文档覆盖了全部使用场景。
2. **API 文档完整度达到100%**。全部11个端点都有完整的文档——请求参数说明、响应字段说明、curl + Python 双语言示例、7种标准错误码说明、注意事项。开发者可以完全不看源代码，仅凭 API 文档就能完成集成开发。

- 3. 数据格式说明消除了信息歧义。9个核心数据结构的完整字段说明表，加上数据流转全景图，让开发者能够准确理解系统在各个阶段使用的数据模型。
- 4. 部署说明的常见问题排查覆盖了90%以上的实际问题。7个常见问题的"症状-原因-解决-验证"四段式排查指南，来自于贺在阶段1-5期间积累的实际问题处理经验。
- 5. 内容组织文档达到了"操作手册"级别。LLM模式配置、降级机制、性能基准、自定义扩展——用户可以通过这份文档完全掌握内容组织模块的使用和定制。
- 6. 文档体系一致性检查完成。发现并修复了5处不一致（术语、版本号、文件名、路径、API路径），所有文档的交叉引用链接已验证可正常跳转。

好消息汇总：

- 文档日 7/7 任务全部完成
- 5 份工程文档全部达到"可交付"质量标准
- 文档间交叉引用全部正确，术语全文档统一
- 所有代码示例经过实际运行验证
- 评测数据来源全量标注，可追溯可复现
- 演示脚本已与新版 API 文档同步更新
- 全组士气良好，准备进入报告日

挑战：

- 明日（7月8日）技术报告撰写工作量较大，全组需要高效协作。
- 交叉审阅从明天晚上开始，时间紧凑。如果发现重大问题，修改时间有限。

10.2 项目进度对照

按照研发计划，今天是第 16 天（7月7日）。对照阶段 6 计划：

计划内容	计划状态	实际状态	偏差分析
7月7日 文档日 README + 接口文档 + 数据格式说明 + 部署说明	全部完成	符合计划	

对最终交付的影响评估：

- 工程文档已全部达到可交付质量，明天可以全力投入技术报告撰写
- 当前进度符合研发计划节奏，关键路径无延迟
- 缓冲天数 3天，未使用

10.3 组员今日表现

成员	任务完成	工时	突出贡献
孟之语	3 项	6h	README最终版、API文档完整版、文档体系规划与一致性检查 部署说明完整版（含7个常见问题排查）、快速开始文档、安装命令全量验证 数据格式说明（9个数据结构+流转图）、内容组织文档完善（新增4章）、术语一致性修复
于贺	3 项	5.5h	
甘毅	3 项	5.5h	
王佳杭	4 项	4.5h	评测数据来源全量标注、演示脚本更新、README评测数据审核、数据结构字段审核

全组今日计划完成率 100%。每位成员完成了分配的所有任务。文档质量达到可交付标准，术语统一、交叉引用正确、代码示例可执行。

11 关键决策记录

编号	日期	决策内容	决策人	依据
D-7.7-1	7月7日	工程文档采用"概述-前置条件-核心内容-示例-常见问题-下一步"六段式结构	全组	确保文档一致性，降低读者学习成本
D-7.7-2	7月7日	术语全文档统一：使用"chunk""分段""内容组织"等统一术语	全组	今日检查发现5处不一致，已全部修复
D-7.7-3	7月7日	交叉审阅从7月8日晚间开始：于贺审技术准确性、甘毅审术语+数据、王佳杭审数据一致性、孟之语统稿	全组	为7月9日修改留出充足时间

12 明日计划（7月8日）

12.1 明日定位

7月8日为阶段6第2天，全组集中进行技术报告撰写和交叉审阅启动。

12.2 明日任务分配

编号	任务	负责人	预计工时	优先级
T-13.1	技术报告撰写（按分工各章节）	全员	6h	P0
T-13.2	演示脚本终稿确认	王佳杭	1h	P1
T-13.3	提交包预整理：确认所有文件就位	于贺	1h	P1
T-13.4	晚间交叉审阅启动	于贺、甘毅、王佳杭	2h	P0
T-13.5	今日日报编写	孟之语	1h	P2

13 项目整体进度追踪

13.1 里程碑完成情况

里程碑	内容	计划日期	实际日期	状态
M1	分段引擎初版可用	6月24日	6月24日	通过
M2	PDF/DOCX + 图片提取 + 预处理	6月27日	6月27日	通过
M3	核心智能体闭环初步可用	6月30日	6月30日	通过
M4	能输出对比实验结果	7月3日	7月3日	通过
M5	集成修复完成 + 演示可用	7月6日	7月6日	通过
M6	最终可交付版本	7月9日	—	进行中（文档日完成）
M7	最终提交与验收展示	7月10日	—	待进行

13.2 阶段完成情况

阶段	内容	日期	状态
阶段0	选题确认与开题准备	6月22日	已完成
阶段1	架构、schema、接口、样例数据	6月23-24日	已完成
阶段2	基础分段与回链	6月25-27日	已完成
阶段3	语义增强、特殊块保护、内容组织初版	6月28-30日	已完成
阶段4	baseline、检索评测、指标报告	7月1-3日	已完成
阶段5	集成测试、前端/报告、失败案例	7月4-6日	已完成
阶段6	文档、答辩材料、演示彩排、缓冲修复	7月7-9日	进行中（第1天/共3天）
阶段7	最终提交与展示	7月10日	待进行

13.3 缓冲消耗情况

- 总缓冲天数：3天（研发计划预留）
- 已消耗：0天
- 剩余：3天
- 当前进度与计划一致，未动用缓冲

14 任务状态表

14.1 阶段6 任务完成情况

日期	计划任务数	完成数	完成率
7月7日	7	7	100%
7月8日	5（计划）	—	—
7月9日	—	—	—
累计	7	7	100%

14.2 全项目任务完成情况（截至7月7日）

阶段	计划任务数	完成数	完成率
阶段1	6	6	100%
阶段2	12	12	100%
阶段3	15	15	100%
阶段4	24	24	100%
阶段5	26	26	100%
阶段6（7月7日）	7	7	100%
合计	90	90	100%

15 里程碑验收状态

15.1 已通过里程碑汇总

里程碑	日期	验收项数	通过率
M1	6月24日	5	100%
M2	6月27日	6	100%
M3	6月30日	10	100%
M4	7月3日	10	100%
M5	7月6日	10	100%

15.2 M6 验收标准（7月9日）

#	验收项	具体标准	当前状态
1	README.md 完整	包含项目简介、快速开始、API列表、评测结果、项目结构、FAQ	已完成（7月7日）
2	API 文档完整	11个端点的完整文档（请求/响应/错误码/示例）	已完成（7月7日）
3	数据格式说明完整	全部核心数据结构的字段说明表+示例	已完成（7月7日）
4	部署说明完整	环境要求+安装+配置+启动+常见问题排查	已完成（7月7日）
5	快速开始可用	从零到运行的5分钟教程，每一步可执行	已完成（7月7日）
6	演示脚本终稿	5个场景的最终版本	已完成（7月6日，今日更新）
7	演示彩排通过	全组预演，确认演示流程	待进行（目标7月9日）
8	交叉审阅完成	全组成员交叉审阅，审阅意见处理完毕	待进行（目标7月9日）
9	提交包完整	README + requirements.txt + 示例数据 + 输出样例 + 评测结果	待进行（目标7月9日）
10	代码/数据/报告冻结	所有文件最终版本确认，不再修改	待进行（目标7月9日）

16 阶段6文档撰写规范

16.1 工程文档撰写规范

今日全组确认了工程文档的统一撰写规范：

结构规范：

所有工程文档（README除外）采用六段式结构：

- 概述（1-2句说明文档的目标读者和内容范围）
- 前置条件（阅读本文档前需要了解的知识或完成的步骤）
- 核心内容（文档的主体内容，根据文档类型组织为多个子章节）
- 示例（可执行的代码示例，附带预期输出）
- 常见问题（FAQ，至少覆盖3个高频问题）
- 下一步（推荐读者阅读的相关文档）

格式规范：

- 标题层级：文档标题用 #，一级章节用 ##，二级章节用 ###，最多三级
- 代码块：使用三个反引号标注语言（`bash`、`python`、`json` 等）

- 表格：使用 **Markdown** 表格，表头加粗
- 链接：使用相对路径链接到其他工程文档，使用完整路径链接到源代码
- 术语：统一使用中文术语（**chunk**、分段、内容组织等），首次出现时可括号标注英文

质量标准：

- 可复现性：所有代码示例经过实际运行验证
- 一致性：术语、字段名、版本号在全文档中统一
- 完整性：覆盖正常场景和异常场景
- 分层性：从简单到复杂，读者可以按需跳转

16.2 文档一致性检查清单

全组确认了文档一致性检查清单，用于7月9日冻结前的最终检查：

检查类别	检查项	检查方法
术语	"chunk"/"分段"/"内容组织"等关键术语在全文档中统一	全文搜索
API	API端点路径和方法在 README、API文档、代码中一致	逐一核对
数据	评测指标数值在 README、评测数据附录中一致	交叉比对
字段	数据结构的字段名在 API文档、数据格式说明、代码实现中一致	逐一核对
版本	Python版本要求、依赖包版本在部署说明、requirements.txt、代码中一致	核对
链接	所有文档间的交叉引用链接指向正确的文件	逐一验证
示例	所有代码示例在干净环境中可执行	实际运行
路径	所有引用的文件路径在项目中存在	逐一检查

17 风险评估与缓冲消耗

17.1 当前风险矩阵

风险编号	风险描述	类别	可能性	影响	缓解措施	当前状态
R-1	演示时环境问题	演示	低	中	预演已完成（7月6日）、降级方案已备好	可控
R-2	评测指标在老师环境中无法复现	评测	低	高	依赖版本已固化（requirements.txt）、部署说明详细	可控
R-3	文档交叉审阅时间不足	进度	中	中	审阅从7月8日晚开始、7月9日上午集中处理	可控

17.2 缓冲消耗情况

- 总缓冲天数：3天
- 已消耗：0天
- 剩余：3天

17.3 降级方案

如果在阶段6剩余两天中出现意外，按以下优先级降级：

优先级	内容	降级方案
P0（不可降级）	README、API文档	必须完成，已完成
P1（可精简）	数据格式说明、部署说明、快速开始	已完成，不需要降级
P2（可延后）	内容组织文档、演示脚本	已完成，不需要降级

18 附录：关键产出物全文

18.1 附录A：README.md 最终版（核心章节摘录）

README.md 的完整内容约350行，以下为核心章节的摘录。

第1章：项目简介

```
1 # 课题11：面向RAG的智能分段与内容组织智能体
2
3 面向RAG (Retrieval-Augmented Generation) 文档预处理的智能分段系统。
4 将结构化全文自动转换为语义完整、元数据丰富的分段结果，
5 支持多格式文档（txt/md/docx/pdf），提供完整的RAG检索评测体系。
6
7 核心能力：
8 - 结构感知分段：基于文档标题层级的分段边界优选，chunk边界与文档结构对齐
9 - 语义边界增强：基于embedding语义相似度的智能切分点检测，避免主题断裂
10 - 特殊块保护：表格/公式/代码/列表/图片整体成块，不被切碎
11 - 内容自动组织：每个chunk自动生成关键词标签、抽取式摘要、正则实体标签
12 - RAG检索评测：内置fixed_length/heading_based/smart三策略对比评测框架
13 - 多格式支持：txt/md/docx/pdf 四种常见文档格式的完整加载和分段
```

第4章：评测结果

```
1 ## 评测结果
2
3 ### 三策略对比 (Smart vs Heading vs Fixed)
4
5 默认参数: min=180, target=550, max=800, threshold=0.55, overlap=1
6
7 | 指标 | Smart | Heading | Fixed | S vs F |
8 |-----|-----|-----|-----|-----|
9 | Recall@1 | 0.1669 | 0.1534 | 0.1456 | +14.6% |
10 | Recall@3 | 0.4042 | 0.3895 | 0.3005 | +34.5% |
11 | Recall@5 | 0.5915 | 0.5433 | 0.4990 | **+18.5%** |
12 | Precision@5 | 0.6033 | 0.5567 | 0.5233 | +15.3% |
13 | nDCG@5 | 0.7148 | 0.6568 | 0.6026 | +18.6% |
14 | MRR | 0.7778 | 0.7500 | 0.7500 | +3.7% |
15
16 增量分析：
17 - 结构信息贡献 (Heading vs Fixed): +8.9%
18 - 语义边界增量 (Smart vs Heading): +8.8%
19 - 总提升 (Smart vs Fixed): +18.5% (超过任务书要求的 +10% 目标)
20
21 分段质量统计 (全部达标)：
22 - 不破句率: 100%
23 - 表格/公式/代码整体成块率: 100%
24 - 目标长度区间命中率: 94.4%
25 - 原文内容完整率: 100%
```

```
26
27 内容组织质量基线:
28 - 标签准确率 (词级Jaccard 0.5) : 0.70
29 - 摘要忠实度: 100%
30 - 实体精确率: 96.8%
31 - 实体召回率: 93.0%
```

18.2 附录B: API 文档摘录 (以 `POST /api/segment/upload` 为例)

以下为 API 文档中核心端点的文档示例:

```
1  ### POST /api/segment/upload
2
3  上传文档并执行完整的智能分段流程: 文档加载 → 预处理 → 分段 → 内容组织 → 入库。
4
5  ##### 请求
6
7  - 方法: POST
8  - 路径: /api/segment/upload
9  - Content-Type: multipart/form-data
10
11 | 参数 | 类型 | 必填 | 说明 | 示例值 |
12 |-----|-----|-----|-----|-----|
13 | file | file | 是 | 要上传的文档文件 | @assets/title.md |
14 | keyword_strategy | string | 否 | 关键词提取策略 | tfidf |
15 | preset | string | 否 | 预设策略 (rag/training/summary) | rag |
16 | parent_child | boolean | 否 | 是否启用父子块分段 | false |
17
18 **请求示例 (curl) **:
19
20 curl -X POST http://localhost:8000/api/segment/upload \
21     -F "file=@assets/title.md" \
22     -F "keyword_strategy=tfidf"
23
24 **请求示例 (Python) **:
25
26 import requests
27
28 with open("assets/title.md", "rb") as f:
29     response = requests.post(
30         "http://localhost:8000/api/segment/upload",
31         files={"file": f},
32         data={"keyword_strategy": "tfidf"}
33     )
34 print(response.json())
35
36 ##### 响应
37
38 **成功响应 (200) **:
39
40 {
41     "doc_id": "title_md",
42     "status": "completed",
43     "chunk_count": 5,
44     "statistics": {
45         "chunk count": 5.
```

```

46     "avg_chars": 548.3,
47     "target_length_hit_rate": 1.0,
48     "source_ref_complete_rate": 1.0,
49     "no_break_sentence_rate": 1.0,
50     "table_code_formula_intact_rate": 1.0
51 },
52 "chunks": [
53     {
54         "chunk_id": "title_md_chunk_0001",
55         "doc_id": "title_md",
56         "chunk_index": 0,
57         "content": "课题11面向RAG的智能分段...",
58         "retrieval_text": "课题11 > 课题背景\n课题11面向RAG的智能分段...",
59         "char_count": 548,
60         "token_count": 412,
61         "title_path": ["课题11", "课题背景"],
62         "tags": ["智能分段", "RAG", "标题边界"],
63         "summary": "该系统通过标题边界优先策略实现结构感知分段...",
64         "entity_labels": [
65             {"type": "metric", "value": "Recall@5"},
66             {"type": "percentage", "value": "18.5%"}
67         ],
68         "source_refs": [
69             {"block_id": "b3", "page": 1}
70         ],
71         "strategy_info": {
72             "strategy": "semantic_boundary",
73             "config": {"min_chars": 180, "target_chars": 550, "max_chars": 800}
74         },
75         "quality_flags": ["sentence_boundary"],
76         "parent_chunk_id": "",
77         "child_chunk_ids": []
78     }
79 ]
80 }
81
82 **错误响应**:
83
84 | 错误码 | HTTP状态码 | 说明 | 触发条件 |
85 |-----|-----|-----|-----|
86 | VALIDATION_ERROR | 422 | 请求参数校验失败 | 缺少必填字段、字段类型错误 |
87 | UNSUPPORTED_FORMAT | 400 | 不支持的文件格式 | 上传了 .exe/.zip 等非文档格式 |
88 | CONFLICT | 409 | 文档已存在 | 重复上传同一文档 |
89 | SEGMENTATION_FAILED | 500 | 分段处理失败 | 文档损坏、内存不足等 |
90
91 错误响应示例:
92 {
93     "error": "UNSUPPORTED_FORMAT",
94     "message": "不支持的文件格式: .exe",
95     "detail": "支持的文件格式: .txt, .md, .docx, .pdf"
96 }

```


18.3 附录C：数据格式说明摘录（Chunk 数据结构）

```
1  Chunk (分段结果)
2
3  分段引擎输出的核心数据结构，包含chunk的正文内容、元数据和内容组织结果。
4
5  | 字段名 | 类型 | 必填 | 说明 | 示例值 |
6  |-----|-----|-----|-----|-----|
7  | chunk_id | str | 是 | 全局唯一标识 | "title_md_chunk_0001" |
8  | doc_id | str | 是 | 所属文档ID | "title_md" |
9  | chunk_index | int | 是 | 在文档中的序号 | 0 |
10 | content | str | 是 | chunk正文内容 | "课题11面向RAG的..." |
11 | retrieval_text | str | 是 | 检索增强文本 | "课题11 > 背景\n课题11面向..." |
12 | char_count | int | 是 | 字符数 | 548 |
13 | token_count | int | 是 | Token数 | 412 |
14 | title_path | list[str] | 是 | 标题路径 | ["课题11", "课题背景"] |
15 | tags | list[str] | 是 | 关键词标签 | ["智能分段", "RAG"] |
16 | summary | str | 是 | 片段摘要 | "该系统通过标题边界..." |
17 | entity_labels | list[EntityLabel] | 是 | 实体标签列表 | [{"type": "metric", "value": "Recall@5"}] |
18 | source_refs | list[SourceRef] | 是 | 原文回链 | [{"block_id": "b3", "page": 1}] |
19 | strategy_info | dict | 是 | 分段策略信息 | {"strategy": "semantic_boundary"} |
20 | quality_flags | list[str] | 是 | 质量标记 | ["sentence_boundary"] |
21 | parent_chunk_id | str | 否 | 父块ID | "" |
22 | child_chunk_ids | list[str] | 否 | 子块ID列表 | [] |
23
24 chunk_id格式: {doc_id}_chunk_{seq:04d}
25 - doc_id: 文档上传时自动生成（基于文件名和时间戳）
26 - seq: 4位零填充序号，从0001开始
27
28 title_path: 从文档根标题到当前chunk所在标题的完整路径
29 - 示例: ["第一章 概述", "1.1 背景", "1.1.1 系统目标"]
30 - 使用 " > " 连接后拼接到 retrieval_text 中
31
32 quality_flags 可能的值:
33 - "sentence_boundary": chunk以完整句子结尾
34 - "heading_boundary": chunk边界与标题边界对齐
35 - "oversized_table_split": 超长表格已按逻辑行拆分
36 - "undersized": chunk长度低于min_chars
37 - "rule_mode": 内容组织使用规则模式（非LLM模式）
```

18.4 附录D：评测指标总表（用于文档引用）

三策略对比指标表（最终确认版）：

指标	Smart	Heading	Fixed	S vs H	H vs F	S vs F
Recall@1	0.1669	0.1534	0.1456	+8.8%	+5.4%	+14.6%
Recall@3	0.4042	0.3895	0.3005	+3.8%	+29.6%	+34.5%
Recall@5	0.5915	0.5433	0.4990	+8.9%	+8.9%	+18.5%
Precision@5	0.6033	0.5567	0.5233	+8.4%	+6.4%	+15.3%
nDCG@5	0.7148	0.6568	0.6026	+8.8%	+9.0%	+18.6%
MRR	0.7778	0.7500	0.7500	+3.7%	0.0%	+3.7%

数据来源：`python scripts/eval_rag.py`（默认参数），输出文件

分段质量统计:

指标	目标	实测（3文档加权平均）	判定
不破句率	100%	100%	达标
表格/公式/代码整体成块率	$\geq 95\%$	100%	达标
目标长度区间命中率	$\geq 90\%$	94.4%	达标
原文回链完整率	100%	100%	达标

内容组织质量基线:

指标	值	目标	判定
标签准确率（词级Jaccard 0.5）	0.70	≥ 0.5	达标
摘要忠实度	100%	$\geq 90\%$	达标
实体精确率（规则模式）	96.8%	报告数值	—
实体召回率（规则模式）	93.0%	报告数值	—

18.5 附录E：文档体系交叉引用矩阵

源文档	引用目标	引用目的
README.md	docs/quickstart.md	详细快速开始步骤
README.md	docs/api.md	完整API端点文档
README.md	docs/deployment.md	生产环境部署指南
docs/api.md	docs/data_schema.md	请求/响应中的数据结构定义
docs/quickstart.md	docs/api.md	下一步：了解全部API
docs/quickstart.md	docs/data_schema.md	下一步：了解数据结构
docs/quickstart.md	docs/deployment.md	下一步：生产环境部署
docs/deployment.md	docs/quickstart.md	快速体验入口

18.6 附录F：项目文件结构（阶段6最终版）

1	zhinengti/	
2	├─ README.md	★ 项目说明 (350行, 7月7日完成)
3	├─ requirements.txt	Python 依赖清单
4	├─ .env.example	环境变量模板
5	├─ backend/	
6	│ └─ app/	
7	│ └─ main.py	FastAPI 入口 + startup事件
8	│ └─ api/	
9	│ └─ routes.py	11个API端点
10	│ └─ core/	
11	│ └─ config.py	配置常量
12	│ └─ model_settings.py	LLM配置管理
13	│ └─ models/	
14	│ └─ schemas.py	Pydantic数据模型
15	│ └─ services/	
16	│ └─ document_loader/	多格式文档加载
17	│ └─ document_preprocessor.py	
18	│ └─ embedding.py	MiniLM编码器
19	│ └─ evaluation/	评测框架
20	│ └─ organizer/	内容组织
21	│ └─ preprocessing/	封面/目录去除
22	│ └─ rag_store/	RAG存储 (ChromaDB+SQLite)

23				retrieval/	检索服务
24				segmenting/	核心分段引擎
25				tests/	27个单元测试
26				frontend/	
27				src/	
28				api/	API调用封装
29				components/	Vue组件
30				views/	页面视图
31				scripts/	CLI工具+评测脚本
32				segment_file.py	CLI分段工具
33				eval_rag.py	三策略评测
34				eval_report.py	评测报告生成
35				tune_segmenting_params.py	参数搜索
36				human_eval_semantic.py	人工评估
37				synthesize_qa_pairs.py	QA对合成
38				data/	
39				benchmarks/docs/	10篇评测基准文档
40				images/	提取的文档图片
41				outputs/	评测报告输出
42				docs/	★ 工程文档 (7月7日完成)
43				api.md	API接口文档 (500行)
44				data_schema.md	数据格式说明 (400行)
45				deployment.md	部署说明 (280行)
46				quickstart.md	快速开始 (120行)
47				organizer.md	内容组织文档 (450行)

报告撰写: 孟之语
数据核实: 王佳杭、于贺
文档审阅: 甘毅
审核: 全组